

Estimation et intervalles de crédibilité pour le taux de reproduction de la Covid19 par échantillonnage Monte Carlo Langevin proximal

P. Abry^{1,†}, G. Fort^{2,‡}, B. Pascal³, N. Pustelnik^{1,4}


Colloque GRETSI 2022, Nancy

-
1. CNRS, ENS de Lyon, Laboratoire de Physique, France,
 2. CNRS, Institut de Mathématique de Toulouse, France,
 3. CNRS, Université de Lille, CRISTAL, France
 4. UC Louvain, Belgium

[†] Soutenu partiellement par la bourse 80PRIME-2021 CNRS


[‡] Financé en partie par la *Fondation Simone et Cino Del Duca, Institut de France*

Décompte quotidien du nombre de nouveaux cas



*données collectées
par l'Université Johns Hopkins
auprès des Agences de Santé Publique*

Décompte quotidien du nombre de nouveaux cas



*données collectées
par l'Université Johns Hopkins
auprès des Agences de Santé Publique*


Élaborer des mesures sanitaires adaptées et évaluer leur efficacité nécessite :

- des outils de surveillance performants
- robustes à la mauvaise qualité des données
- accompagnés de niveaux de confiance fiables

*modèle épidémiologique,
gérer les valeurs aberrantes,
intervalles de crédibilité.*

Enjeux principaux de la surveillance épidémiologique

Décompte quotidien du nombre de nouveaux cas



*données collectées
par l'Université Johns Hopkins
auprès des Agences de Santé Publique*

Élaborer des mesures sanitaires adaptées et évaluer leur efficacité nécessite :

- des outils de surveillance performants
- robustes à la mauvaise qualité des données
- accompagnés de niveaux de confiance fiables

*modèle épidémiologique,
gérer les valeurs aberrantes,
intervalles de crédibilité.*

Indicateur clé : taux de reproduction R_0

(Liu et col, 2018, *PNAS*)

“nombre moyen de cas secondaires générés par une personne contagieuse typique”

⇒ relaxé en un **taux de reproduction effectif** R_t au jour t

(Cori et col, 2013, *Am Journal of Epidemiology*)

Modèle bayésien de la propagation de la Covid19

Z_t : nouvelles infections au jour t

$$\mathbb{P}(Z_t | Z_1, \dots, Z_{t-1}) = \text{Poisson}(p_t(\theta)), \quad p_t(\theta) = R_t \sum_{u=1}^{\tau_\phi} \Phi_u Z_{t-u} + O_t$$

$\Phi \Rightarrow$ délai aléatoire entre infections primaire et secondaire

Paramètres à estimer $\theta = (\mathbf{R}, \mathbf{O})$

- $\mathbf{R} = (R_1, \dots, R_T)$ les taux de reproduction ;
- $\mathbf{O} = (O_1, \dots, O_T)$ valeurs aberrantes.

(Pascal et col, 2022, IEEE Trans Sig Process ; Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

Modèle bayésien de la propagation de la Covid19

Z_t : nouvelles infections au jour t

$$\mathbb{P}(Z_t | Z_1, \dots, Z_{t-1}) = \text{Poisson}(p_t(\theta)), \quad p_t(\theta) = R_t \sum_{u=1}^{\tau_\phi} \Phi_u Z_{t-u} + O_t$$

$\Phi \Rightarrow$ délai aléatoire entre infections primaire et secondaire

Paramètres à estimer $\theta = (\mathbf{R}, \mathbf{O})$

- $\mathbf{R} = (R_1, \dots, R_T)$ les taux de reproduction ;
- $\mathbf{O} = (O_1, \dots, O_T)$ valeurs aberrantes.

(Pascal et col, 2022, IEEE Trans Sig Process ; Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

Log-vraisemblance du modèle de Poisson

$$-f(\theta) := \begin{cases} \sum_{t=1}^T (Z_t \ln p_t(\theta) - p_t(\theta)) & \text{si } \theta \in \mathcal{D} = \{\theta | \forall t, p_t(\theta) \geq 0\}, \\ -\infty & \text{sinon.} \end{cases}$$

Modèle bayésien de la propagation de la Covid19

Z_t : nouvelles infections au jour t

$$\mathbb{P}(Z_t | Z_1, \dots, Z_{t-1}) = \text{Poisson}(p_t(\theta)), \quad p_t(\theta) = R_t \sum_{u=1}^{\tau_\phi} \Phi_u Z_{t-u} + O_t$$

$\Phi \Rightarrow$ délai aléatoire entre infections primaire et secondaire

Paramètres à estimer $\theta = (\mathbf{R}, \mathbf{O})$

- $\mathbf{R} = (R_1, \dots, R_T)$ les taux de reproduction ;
- $\mathbf{O} = (O_1, \dots, O_T)$ valeurs aberrantes.

(Pascal et col, 2022, IEEE Trans Sig Process ; Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

Log-vraisemblance du modèle de Poisson

$$-f(\theta) := \begin{cases} \sum_{t=1}^T (Z_t \ln p_t(\theta) - p_t(\theta)) & \text{si } \theta \in \mathcal{D} = \{\theta | \forall t, p_t(\theta) \geq 0\}, \\ -\infty & \text{sinon.} \end{cases}$$

Log-distribution *a priori*

- $R_t - 2R_{t-1} + R_{t-2} \sim \text{Laplace}(\lambda_R)$
- $O_t \sim \text{Laplace}(\lambda_O)$

$$\Rightarrow -g(\mathbf{A}\theta) = -\lambda_R \|\mathbf{D}_2 \mathbf{R}\|_1 - \lambda_O \|\mathbf{O}\|_1, \quad \mathbf{D}_2 \in \mathbb{R}^{T-2 \times T} : \text{matrice du laplacien}$$

Modèle bayésien de la propagation de la Covid19

Z_t : nouvelles infections au jour t

$$\mathbb{P}(Z_t | Z_1, \dots, Z_{t-1}) = \text{Poisson}(p_t(\theta)), \quad p_t(\theta) = R_t \sum_{u=1}^{\tau_\phi} \Phi_u Z_{t-u} + O_t$$

$\Phi \Rightarrow$ délai aléatoire entre infections primaire et secondaire

Paramètres à estimer $\theta = (\mathbf{R}, \mathbf{O})$

- $\mathbf{R} = (R_1, \dots, R_T)$ les taux de reproduction ;
- $\mathbf{O} = (O_1, \dots, O_T)$ valeurs aberrantes.

(Pascal et col, 2022, IEEE Trans Sig Process ; Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

Log-vraisemblance du modèle de Poisson

$$-f(\theta) := \begin{cases} \sum_{t=1}^T (Z_t \ln p_t(\theta) - p_t(\theta)) & \text{si } \theta \in \mathcal{D} = \{\theta | \forall t, p_t(\theta) \geq 0\}, \\ -\infty & \text{sinon.} \end{cases}$$

Log-distribution *a priori*

- $R_t - 2R_{t-1} + R_{t-2} \sim \text{Laplace}(\lambda_R)$
- $O_t \sim \text{Laplace}(\lambda_O)$

$$\Rightarrow -g(\mathbf{A}\theta) = -\lambda_R \|\mathbf{D}_2 \mathbf{R}\|_1 - \lambda_O \|\mathbf{O}\|_1, \quad \mathbf{D}_2 \in \mathbb{R}^{T-2 \times T} : \text{matrice du laplacien}$$

$$\mathbf{A} = \begin{pmatrix} \mathbf{D}_2 & \mathbf{0} \\ \mathbf{0} & \mathbf{I} \end{pmatrix} \in \mathbb{R}^{(2T-2) \times 2T} \Rightarrow \bar{\mathbf{A}} = \begin{pmatrix} \bar{\mathbf{D}}_2 & \mathbf{0} \\ \mathbf{0} & \mathbf{I} \end{pmatrix} \in \mathbb{R}^{2T \times 2T}, \text{ inversible}$$

(Fort et col, 2022, *preprint*)

Formalisme bayésien pour la propagation de la Covid19

estimer $\{R_t, t = 1, \dots, T\} \equiv$ échantillonner sous une loi a posteriori[†] de la forme :

$$\pi(\boldsymbol{\theta}) \propto \exp(-f(\boldsymbol{\theta}) - g(A\boldsymbol{\theta})) \mathbb{1}_{\mathcal{D}}(\boldsymbol{\theta})$$

(Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

[†] π est définie à une constante de normalisation près.

Formalisme bayésien pour la propagation de la Covid19

estimer $\{R_t, t = 1, \dots, T\} \equiv$ échantillonner sous une loi a posteriori[†] de la forme :

$$\pi(\theta) \propto \exp(-f(\theta) - g(A\theta)) \mathbb{1}_{\mathcal{D}}(\theta)$$

- $\theta \in \mathbb{R}^d$ vecteur des paramètres,
- f différentiable,
- $\mathcal{D} \subset \mathbb{R}^d$ domaine admissible,
- g convexe, non différentiable,
- $A \in \mathbb{R}^{c \times d}$ opérateur linéaire, $c \leq d$, A de rang plein.

(Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

[†] π est définie à une constante de normalisation près.

Formalisme bayésien pour la propagation de la Covid19

estimer $\{R_t, t = 1, \dots, T\} \equiv$ échantillonner sous une loi a posteriori[†] de la forme :

$$\pi(\theta) \propto \exp(-f(\theta) - g(A\theta)) \mathbb{1}_{\mathcal{D}}(\theta)$$

- $\theta \in \mathbb{R}^d$ vecteur des paramètres,
- f différentiable,
- $\mathcal{D} \subset \mathbb{R}^d$ domaine admissible,
- g convexe, non différentiable,
- $A \in \mathbb{R}^{c \times d}$ opérateur linéaire, $c \leq d$, A de rang plein.

(Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

Méthode de Monte Carlo par chaîne de Markov

[†] π est définie à une constante de normalisation près.

Formalisme bayésien pour la propagation de la Covid19

estimer $\{R_t, t = 1, \dots, T\} \equiv$ échantillonner sous une loi a posteriori[†] de la forme :

$$\pi(\theta) \propto \exp(-f(\theta) - g(A\theta)) \mathbb{1}_{\mathcal{D}}(\theta)$$

- $\theta \in \mathbb{R}^d$ vecteur des paramètres,
- f différentiable,
- $\mathcal{D} \subset \mathbb{R}^d$ domaine admissible,
- g convexe, non différentiable,
- $A \in \mathbb{R}^{c \times d}$ opérateur linéaire, $c \leq d$, A de rang plein.

(Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

Méthode de Monte Carlo par chaîne de Markov

1) générer une suite aléatoire $\{\theta^n, n \in \mathbb{N}\}$ telle que

- θ^{n+1} ne dépend que de θ^n ,
- à convergence, i.e., lorsque $n \rightarrow +\infty$, $\theta^n \sim \pi$,

[†] π est définie à une constante de normalisation près.

Formalisme bayésien pour la propagation de la Covid19

estimer $\{R_t, t = 1, \dots, T\} \equiv$ échantillonner sous une loi a posteriori[†] de la forme :

$$\pi(\theta) \propto \exp(-f(\theta) - g(A\theta)) \mathbb{1}_{\mathcal{D}}(\theta)$$

- $\theta \in \mathbb{R}^d$ vecteur des paramètres,
- f différentiable,
- $\mathcal{D} \subset \mathbb{R}^d$ domaine admissible,
- g convexe, non différentiable,
- $A \in \mathbb{R}^{c \times d}$ opérateur linéaire, $c \leq d$, A de rang plein.

(Artigas et col, 2022, EUSIPCO ; Fort et col, 2022, *preprint*)

Méthode de Monte Carlo par chaîne de Markov

1) générer une suite aléatoire $\{\theta^n, n \in \mathbb{N}\}$ telle que

- θ^{n+1} ne dépend que de θ^n ,
- à convergence, i.e., lorsque $n \rightarrow +\infty$, $\theta^n \sim \pi$,

2) calculer les estimateurs bayésiens, e.g., les **intervalles de crédibilité**,

à partir des échantillons $\{\theta^n, n \geq N\}$ pour $N \gg 1$

[†] π est définie à une constante de normalisation près.

Algorithme de type Hastings-Metropolis

- 1) proposition gaussienne : $\theta^{n+\frac{1}{2}} = \mu(\theta^n) + \sqrt{2\gamma}\xi^{n+1}$, $\xi^{n+1} \sim \mathcal{N}_d(0, C)$;
affranchie de la contrainte $\theta \in \mathcal{D}$;

Algorithme de type Hastings-Metropolis

1) proposition gaussienne : $\theta^{n+\frac{1}{2}} = \mu(\theta^n) + \sqrt{2\gamma}\xi^{n+1}$, $\xi^{n+1} \sim \mathcal{N}_d(0, C)$;

affranchie de la contrainte $\theta \in \mathcal{D}$;

2) acceptation-rejet : $\theta^{n+1} = \theta^{n+\frac{1}{2}}$ aléatoirement, et seulement si $\theta^{n+\frac{1}{2}} \in \mathcal{D}$;

$\theta^{n+1} = \theta^n$, sinon.

(Kent, 1978, *Adv Appl Probab*)

Algorithme de type Hastings-Metropolis

1) proposition gaussienne : $\theta^{n+\frac{1}{2}} = \mu(\theta^n) + \sqrt{2\gamma}\xi^{n+1}$, $\xi^{n+1} \sim \mathcal{N}_d(0, C)$;

affranchie de la contrainte $\theta \in \mathcal{D}$;

2) acceptation-rejet : $\theta^{n+1} = \theta^{n+\frac{1}{2}}$ aléatoirement, et seulement si $\theta^{n+\frac{1}{2}} \in \mathcal{D}$;

$\theta^{n+1} = \theta^n$, sinon. (Kent, 1978, *Adv Appl Probab*)

Cas π régulière : dynamique de Langevin (Roberts & Tweedie, 1996, *Bernoulli*)

$$\mu(\theta) = \theta + \gamma \nabla \ln \pi(\theta), \quad \gamma > 0$$

\implies déplacement vers les régions de **forte probabilité**

Algorithme de type Hastings-Metropolis

- 1) proposition gaussienne : $\theta^{n+\frac{1}{2}} = \mu(\theta^n) + \sqrt{2\gamma}\xi^{n+1}$, $\xi^{n+1} \sim \mathcal{N}_d(0, C)$;
affranchie de la contrainte $\theta \in \mathcal{D}$;
- 2) acceptation-rejet : $\theta^{n+1} = \theta^{n+\frac{1}{2}}$ aléatoirement, et seulement si $\theta^{n+\frac{1}{2}} \in \mathcal{D}$;
 $\theta^{n+1} = \theta^n$, sinon. (Kent, 1978, *Adv Appl Probab*)

Cas π régulière : dynamique de Langevin (Roberts & Tweedie, 1996, *Bernoulli*)

$$\mu(\theta) = \theta + \gamma \nabla \ln \pi(\theta), \quad \gamma > 0$$

\implies déplacement vers les régions de **forte probabilité**

Cas π non différentiable : Langevin **proximal** $\pi \propto \exp(-f - g(A \cdot)) \mathbb{1}_{\mathcal{D}}$

- f différentiable de gradient ∇f ,
- g non-différentiable, convexe,
d'opérateur proximal $\text{prox}_{\rho g} = (I + \rho \partial g)^{-1}$, $\rho > 0$ connu explicitement.

But : comparaison de différentes approches proximales pour la construction de μ .

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$$\text{prox}_{\gamma g(A\cdot)}(\theta) = \underset{\varphi \in \mathbb{R}^d}{\operatorname{argmin}} \left(\frac{1}{2} \|\theta - \varphi\|_2^2 + \gamma g(A\varphi) \right)$$

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$$\text{prox}_{\gamma g(A\cdot)}(\theta) = \underset{\varphi \in \mathbb{R}^d}{\operatorname{argmin}} \left(\frac{1}{2} \|\theta - \varphi\|_2^2 + \gamma g(A\varphi) \right)$$

Méthodes primales

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$$\text{prox}_{\gamma g(A\cdot)}(\theta) = \underset{\varphi \in \mathbb{R}^d}{\operatorname{argmin}} \left(\frac{1}{2} \|\theta - \varphi\|_2^2 + \gamma g(A\varphi) \right)$$

Méthodes primales

- Dérive de Moreau : *approximation régulière de g par son enveloppe de Moreau*

$$\mu^M(\theta) = \theta - \gamma \nabla f(\theta) - \frac{\gamma}{\rho} A^\top (I - \text{prox}_{\rho g}) A \theta, \quad \rho = \gamma$$

(Durmus et col, 2018, *SIAM J Imaging Sci*; Luu et col, 2020, *Methodol Comput Appl Probab*)

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$$\text{prox}_{\gamma g(A\cdot)}(\theta) = \underset{\varphi \in \mathbb{R}^d}{\operatorname{argmin}} \left(\frac{1}{2} \|\theta - \varphi\|_2^2 + \gamma g(A\varphi) \right)$$

Méthodes primales

- Dérive de Moreau : *approximation régulière de g par son enveloppe de Moreau*

$$\mu^{\text{M}}(\theta) = \theta - \gamma \nabla f(\theta) - \frac{\gamma}{\rho} A^{\top} (I - \text{prox}_{\rho g}) A \theta, \quad \rho = \gamma$$

(Durmus et col, 2018, *SIAM J Imaging Sci* ; Luu et col, 2020, *Methodol Comput Appl Probab*)

- Dérive PGdec : si $AA^{\top} = \nu I$, avec $\nu > 0 \implies$ forme explicite de $\text{prox}_{\gamma g(A\cdot)}$

$$\mu^{\text{PGdec}}(\theta) = \text{prox}_{\gamma g(A\cdot)}(\theta - \gamma \nabla f(\theta))$$

étendu à $g(A\cdot) = \sum_{i=1}^I g_i(A_i\cdot)$, avec $A_i A_i^{\top} = \nu_i I$, $\nu_i > 0$ (Fort et col, 2022, *preprint*)

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$$\text{prox}_{\gamma g(A\cdot)}(\theta) = \underset{\varphi \in \mathbb{R}^d}{\operatorname{argmin}} \left(\frac{1}{2} \|\theta - \varphi\|_2^2 + \gamma g(A\varphi) \right)$$

Méthodes primales

- Dérive de Moreau : *approximation régulière de g par son enveloppe de Moreau*

$$\mu^{\text{M}}(\theta) = \theta - \gamma \nabla f(\theta) - \frac{\gamma}{\rho} A^\top (I - \text{prox}_{\rho g}) A \theta, \quad \rho = \gamma$$

(Durmus et col, 2018, *SIAM J Imaging Sci* ; Luu et col, 2020, *Methodol Comput Appl Probab*)

- Dérive PGdec : si $AA^\top = \nu I$, avec $\nu > 0 \implies$ forme explicite de $\text{prox}_{\gamma g(A\cdot)}$

$$\mu^{\text{PGdec}}(\theta) = \text{prox}_{\gamma g(A\cdot)}(\theta - \gamma \nabla f(\theta))$$

étendu à $g(A\cdot) = \sum_{i=1}^I g_i(A_i\cdot)$, avec $A_i A_i^\top = \nu_i I$, $\nu_i > 0$ (Fort et col, 2022, *preprint*)

- Dérive marche aléatoire : $\mu^{\text{RM}}(\theta) = \theta$

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

Monte Carlo Langevin proximal

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$A \in \mathbb{R}^{c \times d}$, $c \leq d$ de **rang plein** \implies extension **inversible** $\bar{A} \in \mathbb{R}^{d \times d}$

terme de dérive **dual** $\tilde{\mu}(\tilde{\theta})$, $\tilde{\theta} = \bar{A}\theta$, adapté à $\tilde{\pi} \propto \exp\left(-f(\bar{A}^{-1}\cdot) - \bar{g}\right) \mathbb{1}_{\mathcal{D}}(\bar{A}^{-1}\cdot)$

Monte Carlo Langevin proximal

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$A \in \mathbb{R}^{c \times d}$, $c \leq d$ de **rang plein** \implies extension **inversible** $\bar{A} \in \mathbb{R}^{d \times d}$

terme de dérive **dual** $\tilde{\mu}(\tilde{\theta})$, $\tilde{\theta} = \bar{A}\theta$, adapté à $\tilde{\pi} \propto \exp\left(-f(\bar{A}^{-1}\cdot) - \bar{g}\right) \mathbb{1}_{\mathcal{D}}(\bar{A}^{-1}\cdot)$

Méthodes duales

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$A \in \mathbb{R}^{c \times d}$, $c \leq d$ de **rang plein** \implies extension **inversible** $\bar{A} \in \mathbb{R}^{d \times d}$

terme de dérive **dual** $\tilde{\mu}(\tilde{\theta})$, $\tilde{\theta} = \bar{A}\theta$, adapté à $\tilde{\pi} \propto \exp\left(-f(\bar{A}^{-1}\cdot) - \bar{g}\right) \mathbb{1}_{\mathcal{D}}(\bar{A}^{-1}\cdot)$

Méthodes duales

- Dérive de Moreau duale :

$$\tilde{\mu}^M(\tilde{\theta}) = \tilde{\theta} - \gamma \bar{A}^{-\top} \nabla f(\bar{A}^{-1} \tilde{\theta}) - \frac{\gamma}{\rho} (I - \text{prox}_{\rho \bar{g}}) \tilde{\theta}, \quad \rho = \gamma$$

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$A \in \mathbb{R}^{c \times d}$, $c \leq d$ de **rang plein** \implies extension **inversible** $\bar{A} \in \mathbb{R}^{d \times d}$

terme de dérive **dual** $\tilde{\mu}(\tilde{\theta})$, $\tilde{\theta} = \bar{A}\theta$, adapté à $\tilde{\pi} \propto \exp\left(-f(\bar{A}^{-1}\cdot) - \bar{g}\right) \mathbb{1}_{\mathcal{D}}(\bar{A}^{-1}\cdot)$

Méthodes duales

- Dérive de Moreau duale :

$$\tilde{\mu}^M(\tilde{\theta}) = \tilde{\theta} - \gamma \bar{A}^{-\top} \nabla f(\bar{A}^{-1} \tilde{\theta}) - \frac{\gamma}{\rho} (I - \text{prox}_{\rho \bar{g}}) \tilde{\theta}, \quad \rho = \gamma$$

- Dérive PGdual :

$$\tilde{\mu}^{\text{PG}}(\tilde{\theta}) = \text{prox}_{\gamma \bar{g}} \left(\tilde{\theta} - \gamma \bar{A}^{-\top} \nabla f(\bar{A}^{-1} \tilde{\theta}) \right)$$

(Artigas, 2022, *EUSIPCO* ; Fort et col, 2022, *preprint*)

Objectif : terme de dérive $\mu(\theta)$ adapté à $\pi \propto \exp(-f - g(A\cdot)) \mathbb{1}_{\mathcal{D}}$, g non régulière.

$A \in \mathbb{R}^{c \times d}$, $c \leq d$ de **rang plein** \implies extension **inversible** $\bar{A} \in \mathbb{R}^{d \times d}$

terme de dérive **dual** $\tilde{\mu}(\tilde{\theta})$, $\tilde{\theta} = \bar{A}\theta$, adapté à $\tilde{\pi} \propto \exp\left(-f(\bar{A}^{-1}\cdot) - \bar{g}\right) \mathbb{1}_{\mathcal{D}}(\bar{A}^{-1}\cdot)$

Méthodes duales

- Dérive de Moreau duale :

$$\tilde{\mu}^M(\tilde{\theta}) = \tilde{\theta} - \gamma \bar{A}^{-\top} \nabla f(\bar{A}^{-1} \tilde{\theta}) - \frac{\gamma}{\rho} (I - \text{prox}_{\rho \bar{g}}) \tilde{\theta}, \quad \rho = \gamma$$

- Dérive PGdual :

$$\tilde{\mu}^{\text{PG}}(\tilde{\theta}) = \text{prox}_{\gamma \bar{g}} \left(\tilde{\theta} - \gamma \bar{A}^{-\top} \nabla f(\bar{A}^{-1} \tilde{\theta}) \right)$$

(Artigas, 2022, *EUSIPCO* ; Fort et col, 2022, *preprint*)

- Dérive marché aléatoire duale : $\tilde{\mu}^{\text{RM}}(\tilde{\theta}) = \tilde{\theta}$

Exemple : MCMC pour la régression logistique pénalisée

- Modèle**
- $X \in \mathbb{R}^{N \times d}$: matrice des covariables,
 - $\theta^* \in \mathbb{R}^d$: vecteur de régression constant par blocs,
 - $Y \in \{0, 1\}^N$: vecteur de réponses binaires
- $Y_j \sim \text{Bernoulli} \left((1 + \exp(-(X\theta^*)_j))^{-1} \right), \quad \text{indépendantes.}$

Exemple : MCMC pour la régression logistique pénalisée

- Modèle**
- $X \in \mathbb{R}^{N \times d}$: matrice des covariables,
 - $\theta^* \in \mathbb{R}^d$: vecteur de régression constant par blocs,
 - $Y \in \{0, 1\}^N$: vecteur de réponses binaires
- $Y_j \sim \text{Bernoulli} \left((1 + \exp(-(X\theta^*)_j))^{-1} \right)$, indépendantes.

Log-distribution *a posteriori*

$D_1 \in \mathbb{R}^{d-1 \times d}$: gradient discret

$$\ln \pi_t(\theta) = Y^\top X\theta - \sum_{j=1}^N \ln(1 + \exp((X\theta)_j)) - \lambda \|D_1\theta\|_1$$

Exemple : MCMC pour la régression logistique pénalisée

- Modèle**
- $X \in \mathbb{R}^{N \times d}$: matrice des covariables,
 - $\theta^* \in \mathbb{R}^d$: vecteur de régression constant par blocs,
 - $Y \in \{0, 1\}^N$: vecteur de réponses binaires
- $Y_j \sim \text{Bernoulli} \left((1 + \exp(-(X\theta^*)_j))^{-1} \right)$, indépendantes.

Log-distribution *a posteriori*

$D_1 \in \mathbb{R}^{d-1 \times d}$: gradient discret

$$\ln \pi_t(\theta) = Y^\top X\theta - \sum_{j=1}^N \ln(1 + \exp((X\theta)_j)) - \lambda \|D_1\theta\|_1$$

$$\text{PGdec} : \|D_1\theta\|_1 = \underbrace{\|D_{1,p}\theta\|_1}_{\text{lignes paires}} + \underbrace{\|D_{1,i}\theta\|_1}_{\text{lignes impaires}}, \quad D_{1,p}D_{1,p}^\top = D_{1,i}D_{1,i}^\top = \nu I, \nu = 1;$$

Exemple : MCMC pour la régression logistique pénalisée

- Modèle**
- $X \in \mathbb{R}^{N \times d}$: matrice des covariables,
 - $\theta^* \in \mathbb{R}^d$: vecteur de régression constant par blocs,
 - $Y \in \{0, 1\}^N$: vecteur de réponses binaires
- $Y_j \sim \text{Bernoulli} \left((1 + \exp(-(X\theta^*)_j))^{-1} \right)$, indépendantes.

Log-distribution *a posteriori*

$D_1 \in \mathbb{R}^{d-1 \times d}$: gradient discret

$$\ln \pi_t(\theta) = Y^\top X\theta - \sum_{j=1}^N \ln(1 + \exp((X\theta)_j)) - \lambda \|D_1\theta\|_1$$

PGdec : $\|D_1\theta\|_1 = \underbrace{\|D_{1,p}\theta\|_1}_{\text{lignes paires}} + \underbrace{\|D_{1,i}\theta\|_1}_{\text{lignes impaires}}, \quad D_{1,p}D_{1,p}^\top = D_{1,i}D_{1,i}^\top = \nu I, \nu = 1;$

*dual : $\bar{D}_1 = \begin{pmatrix} -1 & 0 & \dots & 0 \\ 0 & & & \\ \vdots & & D_1 & \\ 0 & & & \end{pmatrix} \Rightarrow \text{extension inversible de } D_1.$

Exemple : MCMC pour la régression logistique pénalisée

- Modèle**
- $X \in \mathbb{R}^{N \times d}$: matrice des covariables,
 - $\theta^* \in \mathbb{R}^d$: vecteur de régression constant par blocs,
 - $Y \in \{0, 1\}^N$: vecteur de réponses binaires
- $Y_j \sim \text{Bernoulli} \left((1 + \exp(-(X\theta^*)_j))^{-1} \right)$, indépendantes.

Log-distribution *a posteriori*

$D_1 \in \mathbb{R}^{d-1 \times d}$: gradient discret

$$\ln \pi_t(\theta) = Y^\top X\theta - \sum_{j=1}^N \ln(1 + \exp((X\theta)_j)) - \lambda \|D_1 \theta\|_1$$

PGdec : $\|D_1 \theta\|_1 = \underbrace{\|D_{1,p} \theta\|_1}_{\text{lignes paires}} + \underbrace{\|D_{1,i} \theta\|_1}_{\text{lignes impaires}}, \quad D_{1,p} D_{1,p}^\top = D_{1,i} D_{1,i}^\top = \nu I, \nu = 1;$

*dual : $\bar{D}_1 = \begin{pmatrix} -1 & 0 & \dots & 0 \\ 0 & & & \\ \vdots & & D_1 & \\ 0 & & & \end{pmatrix} \Rightarrow \text{extension inversible de } D_1.$

Données $N = 2.10^3$, $d = 20$
 X : v.a. de Rademacher indépendantes, lignes normalisées à 1.


Exemple jouet : vitesse de convergence des chaînes de Markov

Indicateur de convergence :

$$\text{Log } \pi = \frac{\ln \pi_t(\theta^n) - \ln \pi_t^*}{\ln \pi_t(\theta^1) - \ln \pi_t^*}, \quad \ln \pi_t^* = \max_{\theta \in \mathbb{R}} \ln \pi_t(\theta) \quad \text{régions de grande probabilité}$$

Comparaison des méthodes

primales <i>en traits pleins</i>	duales <i>en pointillés</i>
RW	RWdual
M	Mdual
PGdec	PGdual



- gain à utiliser l'ordre un vs. RW ;
- méthodes primales : les meilleures à λ petit ;
- méthodes duales : les plus rapides pour λ moyen à grand, correctes pour λ petit.

\implies Mdual et PGdual bonnes performances ; robustes au choix de λ

Échantillonneurs duaux pour l'estimation du taux de reproduction

[Mdua1] dérive de type Moreau sur le dual $\gamma = \rho$

$$\mathbf{R}^{n+\frac{1}{2}} = \mathbf{R}^n - \gamma \bar{\mathbf{D}}_2^{-1} \bar{\mathbf{D}}_2^{-\top} \nabla_{\mathbf{R}} f(\boldsymbol{\theta}^n) - \bar{\mathbf{D}}_2^{-1} [0; 0; \mathbf{D}_2 \boldsymbol{\theta}^n - \text{prox}_{\gamma \lambda_{\mathbf{R}} \|\cdot\|_1}(\mathbf{D}_2 \mathbf{R}^n)] + \sqrt{2\gamma} \xi_{\mathbf{R}}^{n+1},$$

$$\mathbf{O}^{n+\frac{1}{2}} = -\gamma_0 \nabla_{\mathbf{O}} f(\boldsymbol{\theta}^n) + \text{prox}_{\gamma_0 \lambda_{\mathbf{O}} \|\cdot\|_1}(\mathbf{O}^n) + \sqrt{2\gamma_0} \xi_{\mathbf{O}}^{n+1};$$

[PGdua1] dérive de type proximal-gradient sur le dual

$$\mathbf{R}^{n+\frac{1}{2}} = \bar{\mathbf{D}}_2^{-1} \text{prox}_{\gamma \lambda_{\mathbf{R}} \|(\cdot)_{3:T}\|_1} \left(\bar{\mathbf{D}}_2 \mathbf{R}^n - \gamma \bar{\mathbf{D}}_2^{-\top} \nabla_{\mathbf{R}} f(\boldsymbol{\theta}^n) \right) + \sqrt{2\gamma} \xi_{\mathbf{R}}^{n+1},$$

$$\mathbf{O}^{n+\frac{1}{2}} = \text{prox}_{\gamma_0 \lambda_{\mathbf{O}} \|\cdot\|_1}(\mathbf{O}^n - \gamma_0 \nabla_{\mathbf{O}} f(\boldsymbol{\theta}^n)) + \sqrt{2\gamma_0} \xi_{\mathbf{O}}^{n+1}.$$

$\nabla_{\mathbf{R}/\mathbf{O}}$: gradient partiel par rapport à \mathbf{R}/\mathbf{O} ;

Échantillonneurs duaux pour l'estimation du taux de reproduction

[M_{dual}] dérive de type Moreau sur le dual $\gamma = \rho$

$$\mathbf{R}^{n+\frac{1}{2}} = \mathbf{R}^n - \gamma \bar{\mathbf{D}}_2^{-1} \bar{\mathbf{D}}_2^{-\top} \nabla_{\mathbf{R}} f(\boldsymbol{\theta}^n) - \bar{\mathbf{D}}_2^{-1} [0; 0; \mathbf{D}_2 \boldsymbol{\theta}^n - \text{prox}_{\gamma \lambda_{\mathbf{R}} \|\cdot\|_1}(\mathbf{D}_2 \mathbf{R}^n)] + \sqrt{2\gamma} \xi_{\mathbf{R}}^{n+1},$$

$$\mathbf{O}^{n+\frac{1}{2}} = -\gamma_0 \nabla_{\mathbf{O}} f(\boldsymbol{\theta}^n) + \text{prox}_{\gamma_0 \lambda_{\mathbf{O}} \|\cdot\|_1}(\mathbf{O}^n) + \sqrt{2\gamma_0} \xi_{\mathbf{O}}^{n+1};$$

[PG_{dual}] dérive de type proximal-gradient sur le dual

$$\mathbf{R}^{n+\frac{1}{2}} = \bar{\mathbf{D}}_2^{-1} \text{prox}_{\gamma \lambda_{\mathbf{R}} \|(\cdot)_{3:T}\|_1} \left(\bar{\mathbf{D}}_2 \mathbf{R}^n - \gamma \bar{\mathbf{D}}_2^{-\top} \nabla_{\mathbf{R}} f(\boldsymbol{\theta}^n) \right) + \sqrt{2\gamma} \xi_{\mathbf{R}}^{n+1},$$

$$\mathbf{O}^{n+\frac{1}{2}} = \text{prox}_{\gamma_0 \lambda_{\mathbf{O}} \|\cdot\|_1}(\mathbf{O}^n - \gamma_0 \nabla_{\mathbf{O}} f(\boldsymbol{\theta}^n)) + \sqrt{2\gamma_0} \xi_{\mathbf{O}}^{n+1}.$$

$\nabla_{\mathbf{R}/\mathbf{O}}$: gradient partiel par rapport à \mathbf{R}/\mathbf{O} ;

Perturbations gaussiennes :

$$- \xi_{\mathbf{R}}^{n+1} \sim \mathcal{N}(0, \bar{\mathbf{D}}_2^{-1} \bar{\mathbf{D}}_2^{-\top}),$$

$$- \xi_{\mathbf{O}}^{n+1} \sim \mathcal{N}(0, \mathbf{I});$$

Paramètres :

$$- (\lambda_{\mathbf{R}}, \lambda_{\mathbf{O}}) = (3.5 \sigma_{\mathbf{Z}} \sqrt{6}/4, 0.05),$$

$$- \gamma_0 = \gamma (\lambda_{\mathbf{R}} / \lambda_{\mathbf{O}})^2,$$

$$- \gamma \text{ ajusté pour accepter 25\% des } \boldsymbol{\theta}^{n+\frac{1}{2}}.$$

Échantillonneurs duaux pour l'estimation du taux de reproduction

[M_{dual}] dérive de type Moreau sur le dual $\gamma = \rho$

$$\mathbf{R}^{n+\frac{1}{2}} = \mathbf{R}^n - \gamma \bar{\mathbf{D}}_2^{-1} \bar{\mathbf{D}}_2^{-\top} \nabla_{\mathbf{R}} f(\boldsymbol{\theta}^n) - \bar{\mathbf{D}}_2^{-1} [0; 0; \mathbf{D}_2 \boldsymbol{\theta}^n - \text{prox}_{\gamma \lambda_{\mathbf{R}} \|\cdot\|_1}(\mathbf{D}_2 \mathbf{R}^n)] + \sqrt{2\gamma} \xi_{\mathbf{R}}^{n+1},$$

$$\mathbf{O}^{n+\frac{1}{2}} = -\gamma_0 \nabla_{\mathbf{O}} f(\boldsymbol{\theta}^n) + \text{prox}_{\gamma_0 \lambda_{\mathbf{O}} \|\cdot\|_1}(\mathbf{O}^n) + \sqrt{2\gamma_0} \xi_{\mathbf{O}}^{n+1};$$

[PG_{dual}] dérive de type proximal-gradient sur le dual

$$\mathbf{R}^{n+\frac{1}{2}} = \bar{\mathbf{D}}_2^{-1} \text{prox}_{\gamma \lambda_{\mathbf{R}} \|\cdot\|_{3,T} \|_1} \left(\bar{\mathbf{D}}_2 \mathbf{R}^n - \gamma \bar{\mathbf{D}}_2^{-\top} \nabla_{\mathbf{R}} f(\boldsymbol{\theta}^n) \right) + \sqrt{2\gamma} \xi_{\mathbf{R}}^{n+1},$$

$$\mathbf{O}^{n+\frac{1}{2}} = \text{prox}_{\gamma_0 \lambda_{\mathbf{O}} \|\cdot\|_1}(\mathbf{O}^n - \gamma_0 \nabla_{\mathbf{O}} f(\boldsymbol{\theta}^n)) + \sqrt{2\gamma_0} \xi_{\mathbf{O}}^{n+1}.$$

$\nabla_{\mathbf{R}/\mathbf{O}}$: gradient partiel par rapport à \mathbf{R}/\mathbf{O} ;

Perturbations gaussiennes :

$$- \xi_{\mathbf{R}}^{n+1} \sim \mathcal{N}(0, \bar{\mathbf{D}}_2^{-1} \bar{\mathbf{D}}_2^{-\top}),$$

$$- \xi_{\mathbf{O}}^{n+1} \sim \mathcal{N}(0, \mathbf{I});$$


Paramètres :

$$- (\lambda_{\mathbf{R}}, \lambda_{\mathbf{O}}) = (3.5 \sigma_{\mathbf{Z}} \sqrt{6}/4, 0.05),$$

$$- \gamma_0 = \gamma (\lambda_{\mathbf{R}} / \lambda_{\mathbf{O}})^2,$$


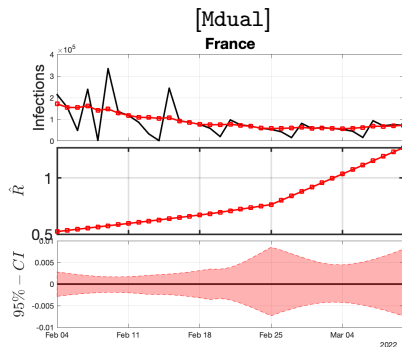
$$- \gamma \text{ ajusté pour accepter 25\% des } \boldsymbol{\theta}^{n+\frac{1}{2}}.$$

Vitesse de convergence des chaînes de Markov



Estimation par intervalles de crédibilité

- Nombre de nouvelles infections débruités $\mathbf{Z}^{(D)} = \mathbf{Z} - \hat{\mathbf{O}}$
- Coefficient de reproduction $\hat{\mathbf{R}}$




\Rightarrow crucial pour appuyer des mesures sanitaires sur l'estimée R_T

Nombre de cas débruité et intervalles de crédibilité de R_t postés quotidiennement

<https://perso.ens-lyon.fr/patrice.abry/>

<https://perso.math.univ-toulouse.fr/gfort/project/opsimore-2/>



Pistes de recherche et perspectives :

- Réglage automatique piloté par les données des hyperparamètres $\gamma_{R/O}$, $\lambda_{R/O}$;
- Gestion de données reportées de moins en moins régulièrement.