

# Segmentation de textures à partir d'attributs fractals par minimisation de fonctionnelle, avec réglage automatique des hyperparamètres.

**Barbara Pascal**

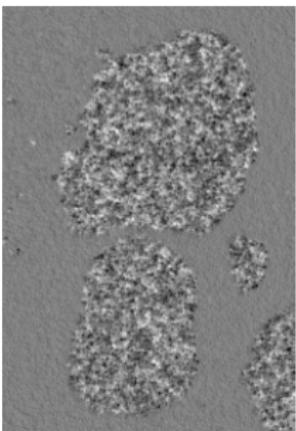
*4 février 2021*

## Séminaire Cristollien d'Analyse Multifractale

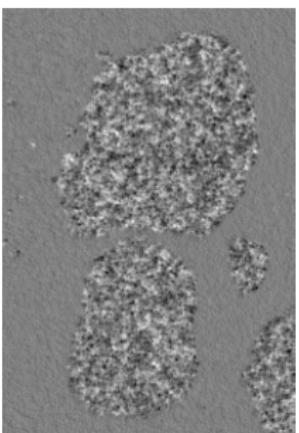
Sous la direction de **Patrice Abry** et **Nelly Pustelnik**

En collaboration avec **Valérie Vidal** et **Samuel Vaïter**

# Segmentation d'image



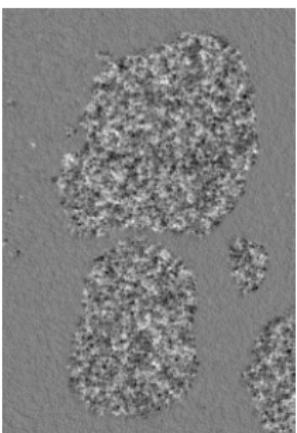
# Segmentation d'image



**Objectif** : obtenir une partition de l'image en  $K$  régions homogènes

$$\Omega = \Omega_1 \sqcup \dots \sqcup \Omega_K$$

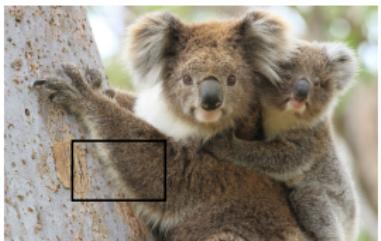
# Segmentation d'image



**Objectif** : obtenir une partition de l'image en  $K$  régions **homogènes**

$$\Omega = \Omega_1 \sqcup \dots \sqcup \Omega_K$$

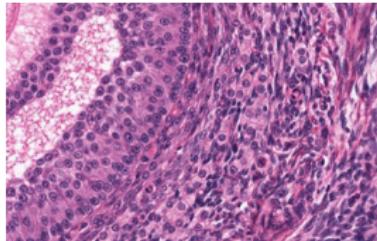
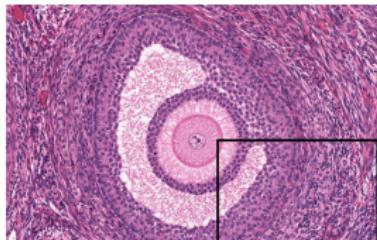
# Textures



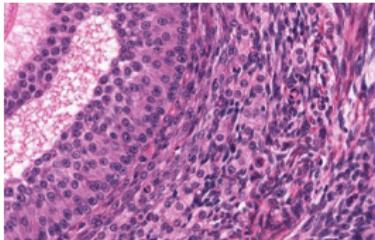
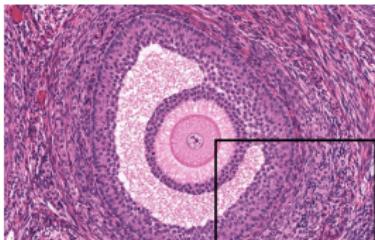
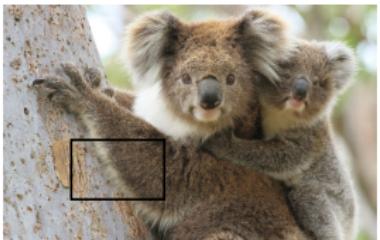
# Textures



# Textures



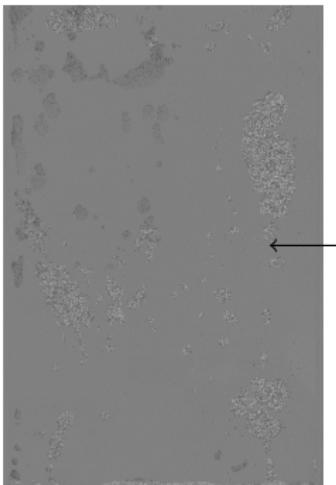
# Textures



Crucial pour décrire les images réelles

# Écoulement multiphasiques en milieu poreux

Laboratoire de Physique, ENS Lyon, V. Vidal, T. Busser, (M. Serres, IFPEN)

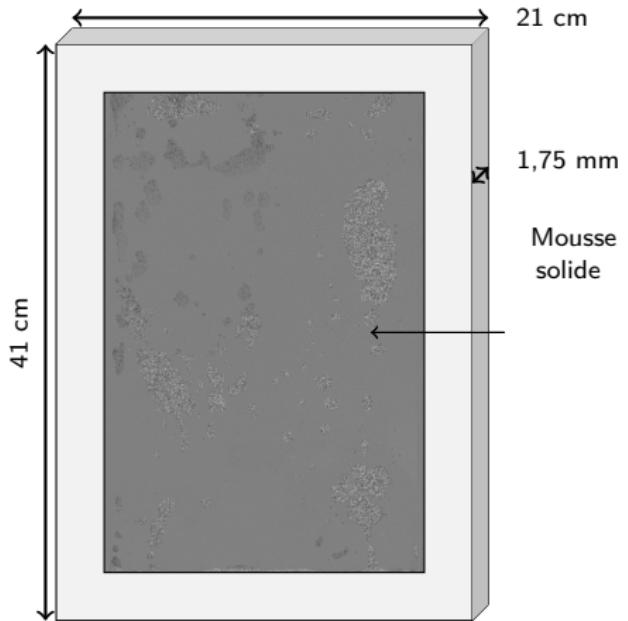


Mousse  
solide



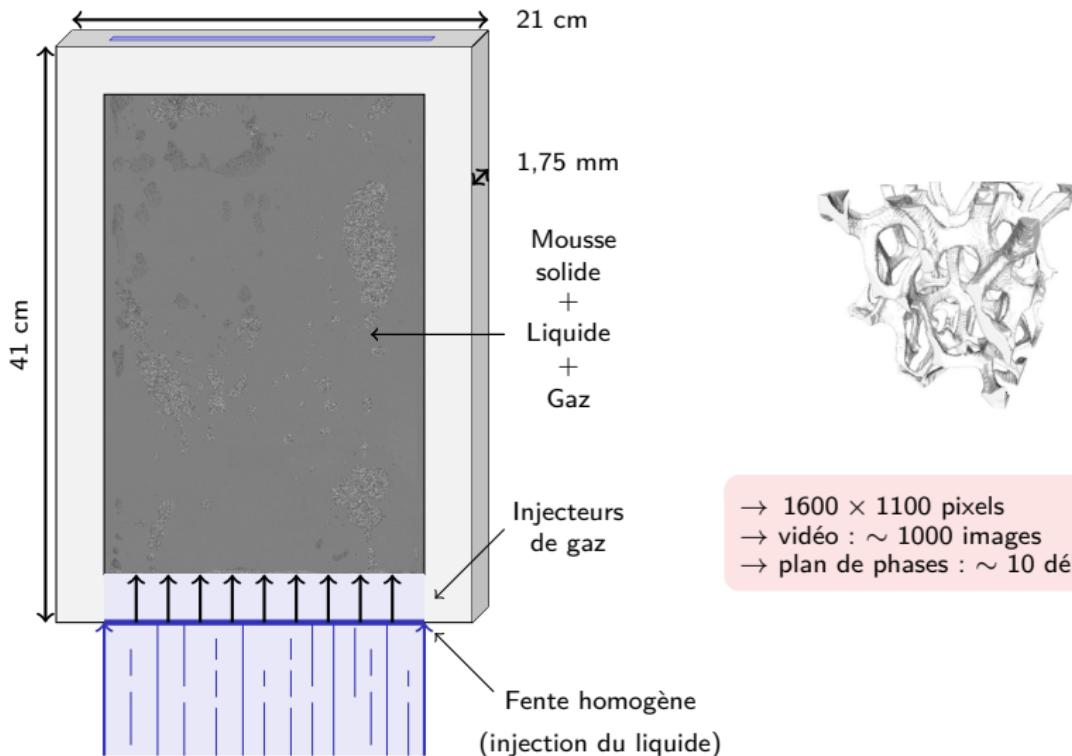
# Écoulement multiphasiques en milieu poreux

Laboratoire de Physique, ENS Lyon, V. Vidal, T. Busser, (M. Serres, IFPEN)



# Écoulement multiphasiques en milieu poreux

Laboratoire de Physique, ENS Lyon, V. Vidal, T. Busser, (M. Serres, IFPEN)



## Plan de l'exposé

## 1. Caractérisation de textures

[Filtres de Gabor (Dunn, 1995)]

[Amplitude et fréquence locales (Havlicek, 1996)]

### [Histogrammes spectraux (Yuan, 2015)]

## Plan de l'exposé

## 1. Caractérisation de textures

→ attributs fractals

- ▶ variance locale  $\sigma^2$
  - ▶ régularité locale  $h$

[Filtres de Gabor (Dunn, 1995)]

[Amplitude et fréquence locales (Havlicek, 1996)]

### [Histogrammes spectraux (Yuan, 2015)]

# Plan de l'exposé

## 1. Caractérisation de textures

→ attributs fractals

- ▶ variance locale  $\sigma^2$
- ▶ régularité locale  $h$

[Filtres de Gabor (Dunn, 1995)]

[Amplitude et fréquence locales (Havlicek, 1996)]

[Histogrammes spectraux (Yuan, 2015)]

## 2. Construction de fonctionnelles

[Champ de Markov (Geman, 1984)]

[Contours actifs (Chan, 2001)]

[Variation Totale et Seuillage (Cai, 2013)]

## Plan de l'exposé

## 1. Caractérisation de textures

- attributs fractals
    - ▶ variance locale  $\sigma^2$
    - ▶ régularité locale  $h$

[Filtres de Gabor (Dunn, 1995)]

[Amplitude et fréquence locales (Havlicek, 1996)]

### [Histogrammes spectraux (Yuan, 2015)]

## 2. Construction de fonctionnelles

- moindres carrés pénalisés
    - ▶ contours libres
    - ▶ contours co-localisés

[Champ de Markov (Geman, 1984)]

[Contours actifs (Chan, 2001)]

[Variation Totale et Seuillage (Cai, 2013)]

## Plan de l'exposé

## 1. Caractérisation de textures

- attributs fractals
    - ▶ variance locale  $\sigma^2$
    - ▶ régularité locale  $h$

[Filtres de Gabor (Dunn, 1995)]

[Amplitude et fréquence locales (Havlicek, 1996)]

### [Histogrammes spectraux (Yuan, 2015)]

## 2. Construction de fonctionnelles

- moindres carrés pénalisés
    - ▶ contours libres
    - ▶ contours co-localisés

[Champ de Markov (Geman, 1984)]

[Contours actifs (Chan, 2001)]

[Variation Totale et Seuillage (Cai, 2013)]

### 3. Algorithme de minimisation accéléré

[Forward-backward (Combettes, 2005)]

[FISTA (Beck, 2009)]

[Primal-dual (Chambolle, 2011)]

# Plan de l'exposé

## 1. Caractérisation de textures

→ attributs fractals

- ▶ variance locale  $\sigma^2$
- ▶ régularité locale  $h$

[Filtres de Gabor (Dunn, 1995)]

[Amplitude et fréquence locales (Havlicek, 1996)]

[Histogrammes spectraux (Yuan, 2015)]

## 2. Construction de fonctionnelles

→ moindres carrés pénalisés

- ▶ contours libres
- ▶ contours co-localisés

[Champ de Markov (Geman, 1984)]

[Contours actifs (Chan, 2001)]

[Variation Totale et Seuillage (Cai, 2013)]

## 3. Algorithme de minimisation accélérée

→ algorithmes proximaux scindés

- ▶ calcul des opérateurs proximaux
- ▶ accélération par forte-convexité

[Forward-backward (Combettes, 2005)]

[FISTA (Beck, 2009)]

[Primal-dual (Chambolle, 2011)]

# Plan de l'exposé

## 1. Caractérisation de textures

→ attributs fractals

- ▶ variance locale  $\sigma^2$
- ▶ régularité locale  $h$

[Filtres de Gabor (Dunn, 1995)]

[Amplitude et fréquence locales (Havlicek, 1996)]

[Histogrammes spectraux (Yuan, 2015)]

## 2. Construction de fonctionnelles

→ moindres carrés pénalisés

- ▶ contours libres
- ▶ contours co-localisés

[Champ de Markov (Geman, 1984)]

[Contours actifs (Chan, 2001)]

[Variation Totale et Seuillage (Cai, 2013)]

## 3. Algorithme de minimisation accélérée

→ algorithmes proximaux scindés

- ▶ calcul des opérateurs proximaux
- ▶ accélération par forte-convexité

[Forward-backward (Combettes, 2005)]

[FISTA (Beck, 2009)]

[Primal-dual (Chambolle, 2011)]

## 4. Réglage des hyperparamètres

[SURE (Stein, 1981)]

[SURE DFMC (Ramani, 2008)]

[GSURE (Eldar, 2008)]

[SUGAR (Deledalle, 2014)]

## Plan de l'exposé

## 1. Caractérisation de textures

- attributs fractals
    - ▶ variance locale  $\sigma^2$
    - ▶ régularité locale  $h$

[Filtres de Gabor (Dunn, 1995)]

[Amplitude et fréquence locales (Havlicek, 1996)]

## [Histogrammes spectraux (Yuan, 2015)]

## 2. Construction de fonctionnelles

- moindres carrés pénalisés
    - ▶ contours libres
    - ▶ contours co-localisés

[Champ de Markov (Geman, 1984)]

[Contours actifs (Chan, 2001)]

[Variation Totale et Seuillage (Cai, 2013)]

### 3. Algorithme de minimisation accéléré

- algorithmes proximaux scindés
    - ▶ calcul des opérateurs proximaux
    - ▶ accélération par forte-convexité

[Forward-backward (Combettes, 2005)]

[FISTA (Beck, 2009)]

[Primal-dual (Chambolle, 2011)]

## 4. Réglage des hyperparamètres

- SURE avec bruit gaussien corrélé
    - ▶ erreur d'estimation projetée
    - ▶ minimisation par quasi-Newton
      - ↪ SUGAR généralisé

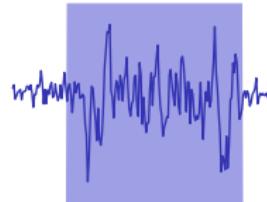
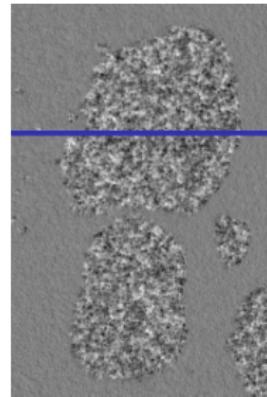
[SURE (Stein, 1981)]

[SURE DFMC (Ramani, 2008)]

[GSURE (Eldar, 2008)]

[SUGAR (Deledalle, 2014)]

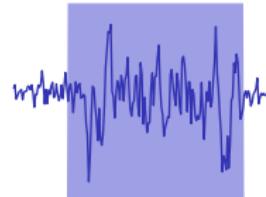
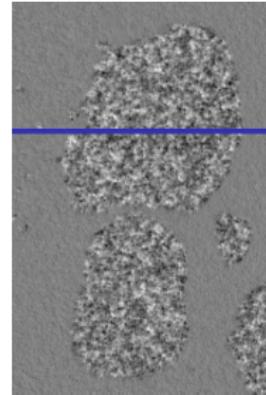
## Modèle monofractal par morceaux



# Modèle monofractal par morceaux

## Attributs fractals

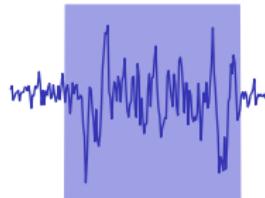
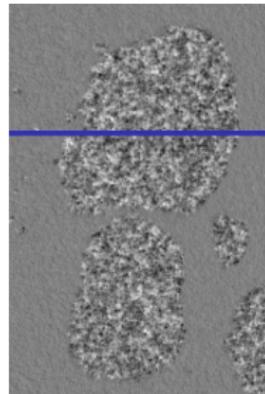
- variance  $\sigma^2$       *amplitude des variations*



## Modèle monofractal par morceaux

## Attributs fractals

- variance  $\sigma^2$       *amplitude des variations*
  - régularité locale  $h$       *invariance d'échelle*

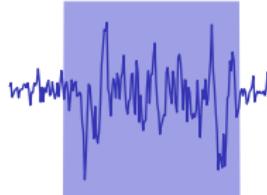
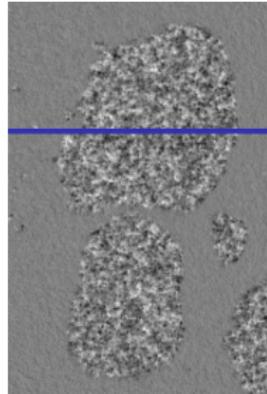


# Modèle monofractal par morceaux

## Attributs fractals

- variance  $\sigma^2$       *amplitude des variations*
- régularité locale  $h$       *invariance d'échelle*

$$|f(x) - f(y)| \leq \sigma(x)|x - y|^{h(x)}$$



# Modèle monofractal par morceaux

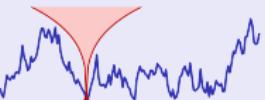
## Attributs fractals

- variance  $\sigma^2$       *amplitude des variations*
- régularité locale  $h$       *invariance d'échelle*

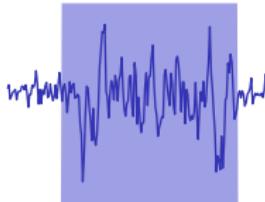
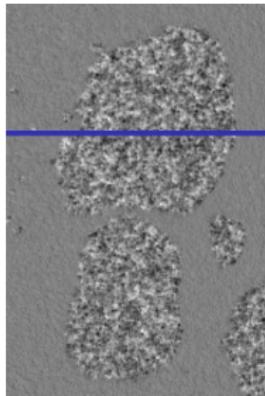
$$|f(x) - f(y)| \leq \sigma(x)|x - y|^{h(x)}$$



$$h(x) \equiv h_1 = 0.9$$



$$h(x) \equiv h_2 = 0.3$$

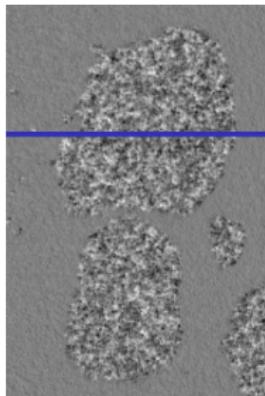


# Modèle monofractal par morceaux

## Attributs fractals

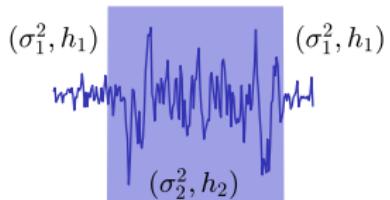
- variance  $\sigma^2$       *amplitude des variations*
- régularité locale  $h$       *invariance d'échelle*

$$|f(x) - f(y)| \leq \sigma(x)|x - y|^{h(x)}$$



## Segmentation

- ▶  $h$  et  $\sigma^2$  constants par morceaux



# Modèle monofractal par morceaux

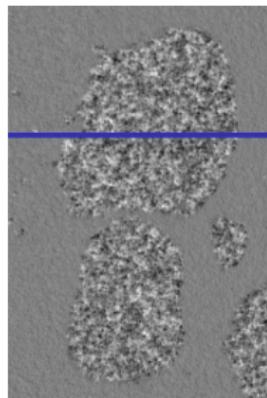
## Attributs fractals

- variance  $\sigma^2$       *amplitude des variations*
- régularité locale  $h$       *invariance d'échelle*

$$|f(x) - f(y)| \leq \sigma(x)|x - y|^{h(x)}$$

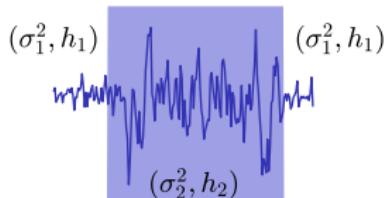


$$h(x) \equiv h_1 = 0.9 \quad h(x) \equiv h_2 = 0.3$$

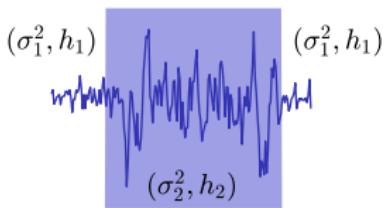
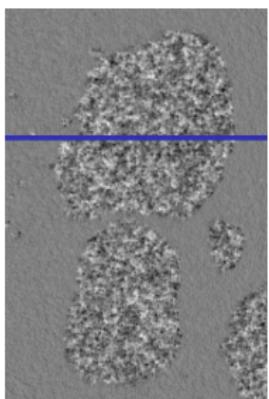


## Segmentation

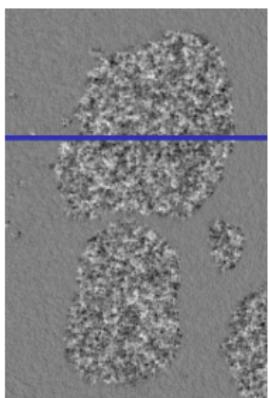
- ▶  $h$  et  $\sigma^2$  constants par morceaux
- ▶ région  $\Omega_k$  caractérisée par  $(h_k, \sigma_k^2)$



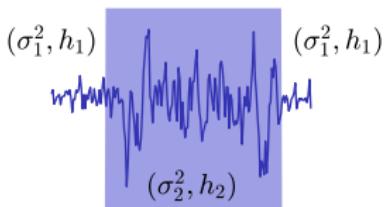
# Intermède : synthèse de texture fractales *par morceaux*



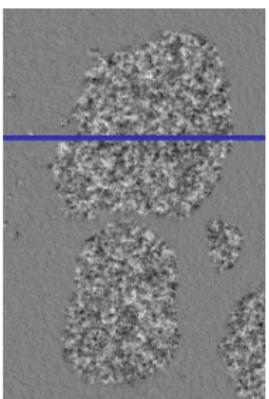
# Intermède : synthèse de texture fractales *par morceaux*



Quel modèle de textures synthétiques

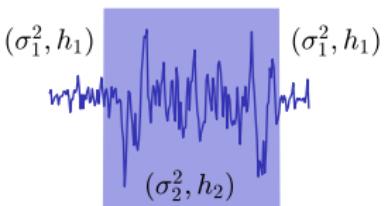


# Intermède : synthèse de texture fractales *par morceaux*

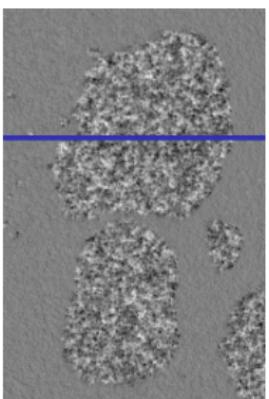


Quel modèle de textures synthétiques

- ressemblant aux textures réelles,

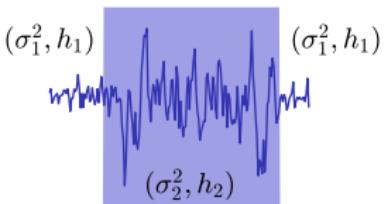


Intermède : synthèse de texture fractales par morceaux

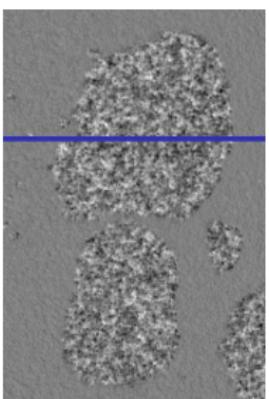


## Quel modèle de textures synthétiques

- ressemblant aux textures réelles,
  - caractérisées par  $(h, \sigma^2)$ ,

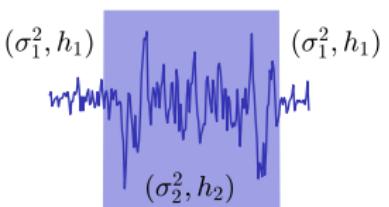


## Intermède : synthèse de texture fractales par morceaux

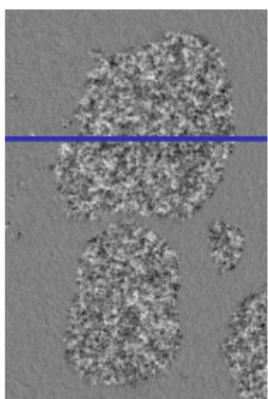


## Quel modèle de textures synthétiques

- ressemblant aux textures réelles,
  - caractérisées par  $(h, \sigma^2)$ ,
  - faciles à « recoller » ?



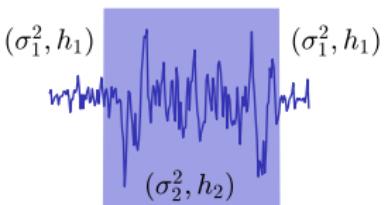
# Intermède : synthèse de texture fractales *par morceaux*



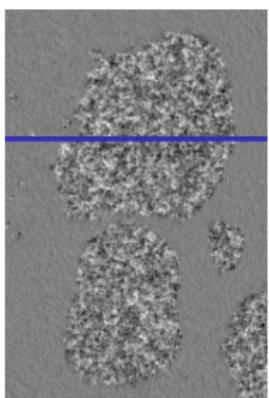
Quel modèle de textures synthétiques

- ressemblant aux textures réelles,
- caractérisées par  $(h, \sigma^2)$ ,
- faciles à « recoller » ?

Proposition d'un champ aléatoire gaussien



## Intermède : synthèse de texture fractales par morceaux

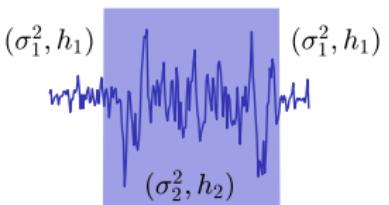


## Quel modèle de textures synthétiques

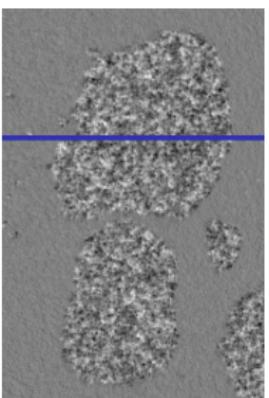
- ressemblant aux textures réelles,
  - caractérisées par  $(h, \sigma^2)$ ,
  - faciles à « recoller » ?

## Proposition d'un champ aléatoire gaussien

- isotrope,



Intermède : synthèse de texture fractales par morceaux

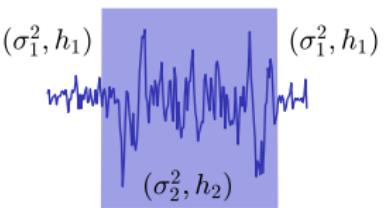


## Quel modèle de textures synthétiques

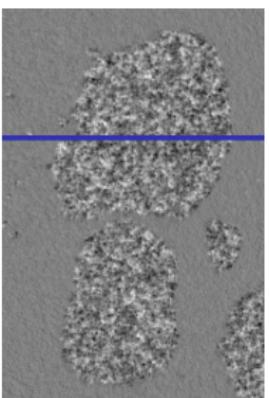
- ressemblant aux textures réelles,
  - caractérisées par  $(h, \sigma^2)$ ,
  - faciles à « recoller » ?

## Proposition d'un champ aléatoire gaussien

- isotrope,
  - autosimilaire, de régularité locale  $h$ ,



Intermède : synthèse de texture fractales par morceaux

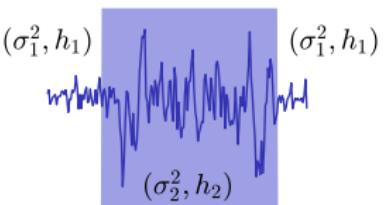


## Quel modèle de textures synthétiques

- ressemblant aux textures réelles,
  - caractérisées par  $(h, \sigma^2)$ ,
  - faciles à « recoller » ?

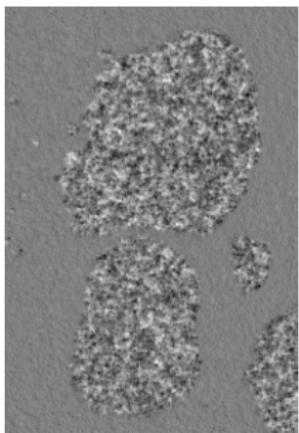
### Proposition d'un champ aléatoire gaussien

- isotrope,
  - autosimilaire, de régularité locale  $h$ ,
  - stationnaire, de variance  $\sigma^2$



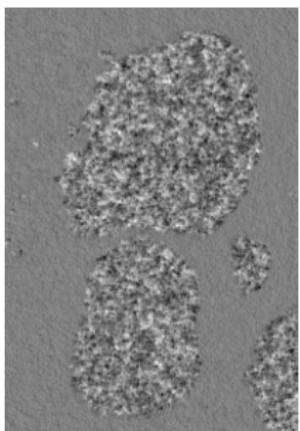
Intermède : synthèse de texture fractales *par morceaux*

### Texture réelle

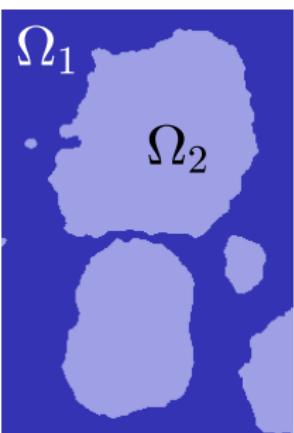


## Intermède : synthèse de texture fractales *par morceaux*

### Texture réelle



## Masque



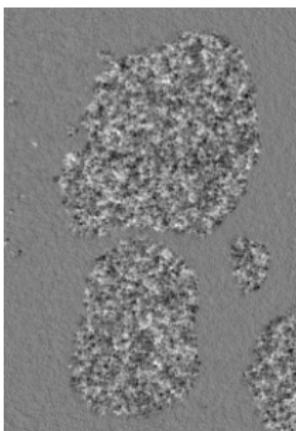
$$\Omega_1 : (\sigma_1^2, h_1) \quad \Omega_2 : (\sigma_2^2, h_2)$$

## Intermède : synthèse de texture fractales par morceaux

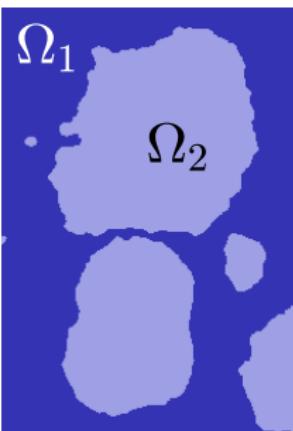
## Champ brownien fractionnaire

$$b_h(\underline{x}) = \sigma \int_{\mathbb{R}^2} \frac{e^{-i\langle \underline{x}, \underline{k} \rangle} - 1}{C_h^{1/2} \|\underline{k}\|^{H+1}} \hat{w}(d\underline{k})$$

## Texture réelle



## Masque



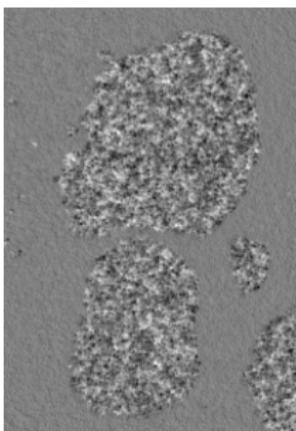
$$\Omega_1 : (\sigma_1^2, h_1) \quad \Omega_2 : (\sigma_2^2, h_2)$$

## Intermède : synthèse de texture fractales *par morceaux*

## Champ brownien fractionnaire

$$b_h(\underline{x}) = \sigma \int_{\mathbb{R}^2} \frac{e^{-i\langle \underline{x}, \underline{k} \rangle} - 1}{C_h^{1/2} \|\underline{k}\|^{H+1}} \hat{w}(d\underline{k})$$

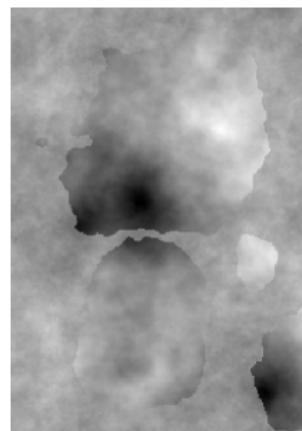
## Texture réelle



## Masque



## Texture synthétique



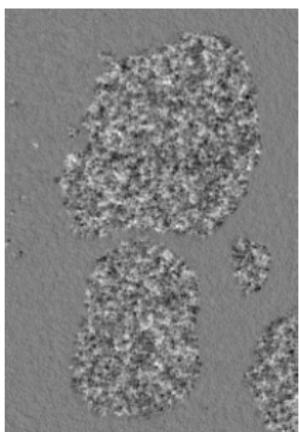
$$\Omega_1 : (\sigma_1^2, h_1) \quad \Omega_2 : (\sigma_2^2, h_2)$$

# Intermède : synthèse de texture fractales par morceaux

Champ gaussien fractionnaire *stationnaire*

$$g_h(\underline{x}) = \frac{1}{2} \underbrace{(b_h(\underline{x} + \underline{e}_1) - b_h(\underline{x}))}_{\text{accroissement horizontal}} + \frac{1}{2} \underbrace{(b_h(\underline{x} + \underline{e}_2) - b_h(\underline{x}))}_{\text{accroissement vertical}}$$

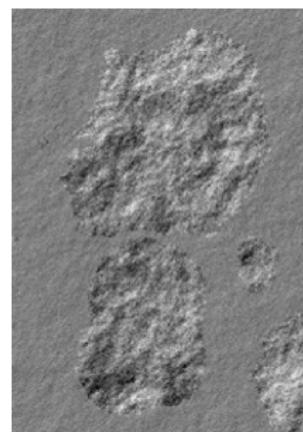
Texture réelle



Masque



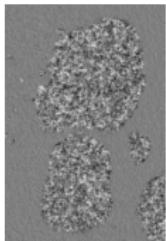
Texture synthétique



$$\Omega_1 : (\sigma_1^2, h_1) \quad \Omega_2 : (\sigma_2^2, h_2)$$

## Analyse multi-échelle

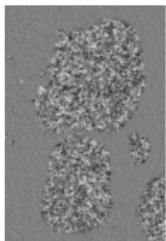
Image texturée



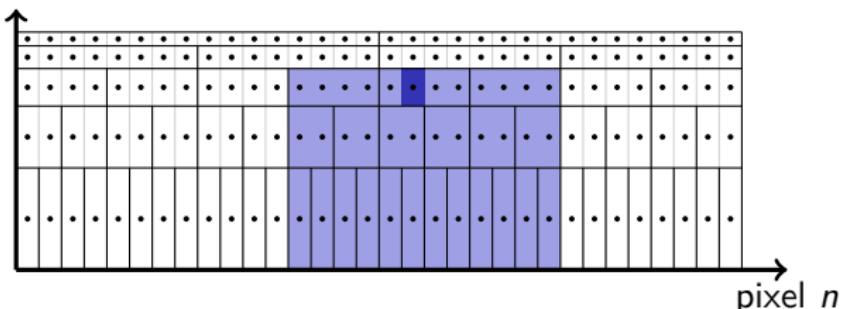
## Analyse multi-échelle

Image texturée

Maximum local des coefficients d'ondelettes :  $\mathcal{L}_{a,:}$



échelle *a*



## Analyse multi-échelle

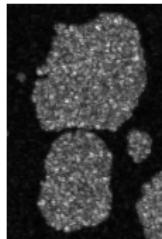
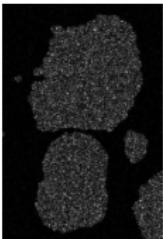
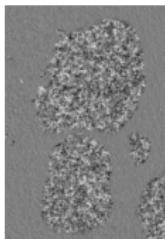
Image texturée

Maximum local des coefficients d'ondelettes :  $\mathcal{L}_a$ .

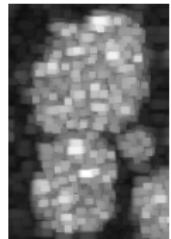
## Échelle

$$a = 2^1$$

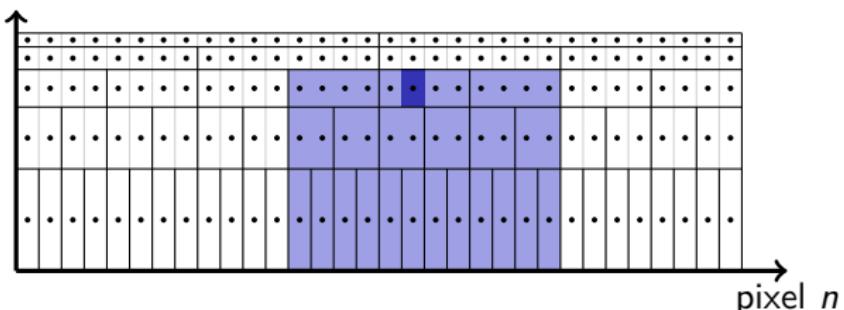
$$a = 2^2$$



• • •



### échelle *a*



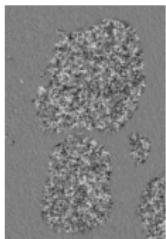
## Analyse multi-échelle

Image texturée

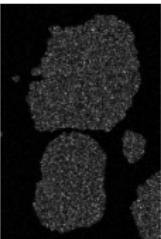
Maximum local des coefficients d'ondelettes :  $\mathcal{L}_{a,:}$

## Échelle

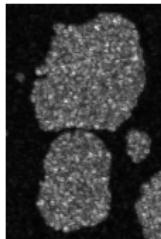
$$a = 2^1$$



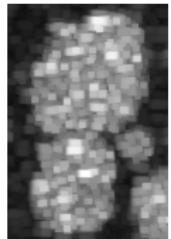
$$a = 2^2$$



$$a = 2^5$$



3

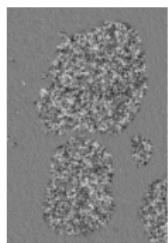


Proposition (*Jaffard, 2004*), (*Wendt, 2008*)

$$\log(\mathcal{L}_{a,\cdot}) \underset{a \rightarrow 0}{\simeq} \log(a) \frac{h}{\text{régularité}} + \frac{\nu}{\alpha \log(\sigma^2)}$$

# Analyse multi-échelle

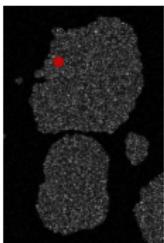
Image texturée



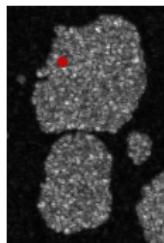
Maximum local des coefficients d'ondelettes :  $\mathcal{L}_{a,\cdot}$

Échelle

$a = 2^1$

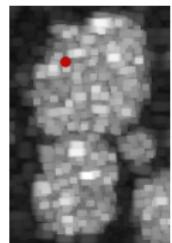


$a = 2^2$



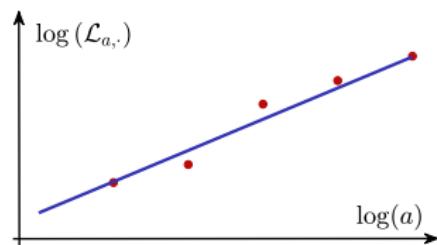
...

$a = 2^5$



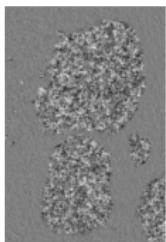
Proposition (Jaffard, 2004), (Wendt, 2008)

$$\log(\mathcal{L}_{a,\cdot}) \underset{a \rightarrow 0}{\simeq} \log(a) h_{\text{régularité}} + v_{\propto \log(\sigma^2) \text{ (variance)}}$$



# Analyse multi-échelle

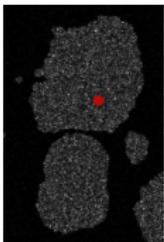
Image texturée



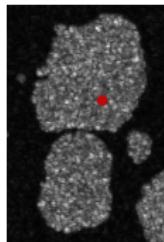
Maximum local des coefficients d'ondelettes :  $\mathcal{L}_{a,\cdot}$

Échelle

$a = 2^1$

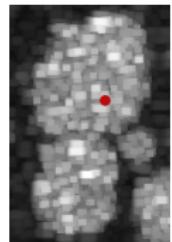


$a = 2^2$



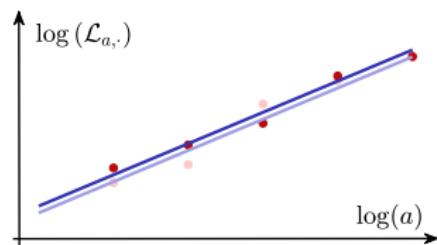
...

$a = 2^5$



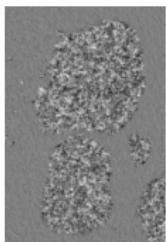
Proposition (Jaffard, 2004), (Wendt, 2008)

$$\log(\mathcal{L}_{a,\cdot}) \underset{a \rightarrow 0}{\simeq} \log(a) h_{\text{régularité}} + v_{\propto \log(\sigma^2) \text{ (variance)}}$$



# Analyse multi-échelle

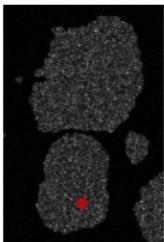
Image texturée



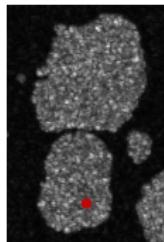
Maximum local des coefficients d'ondelettes :  $\mathcal{L}_{a,\cdot}$

Échelle

$a = 2^1$

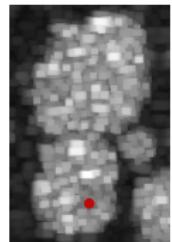


$a = 2^2$



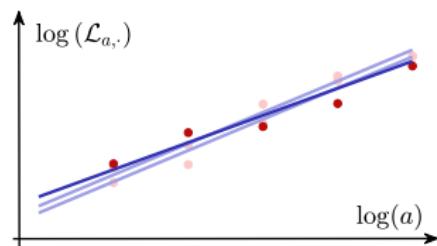
...

$a = 2^5$



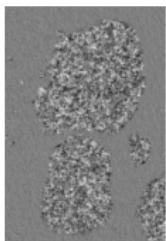
Proposition (Jaffard, 2004), (Wendt, 2008)

$$\log(\mathcal{L}_{a,\cdot}) \underset{a \rightarrow 0}{\simeq} \log(a) h_{\text{régularité}} + v_{\propto \log(\sigma^2) \text{ (variance)}}$$



# Analyse multi-échelle

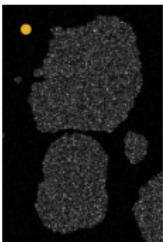
Image texturée



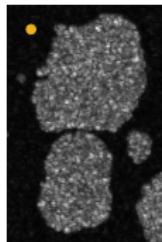
Maximum local des coefficients d'ondelettes :  $\mathcal{L}_{a,\cdot}$

Échelle

$a = 2^1$

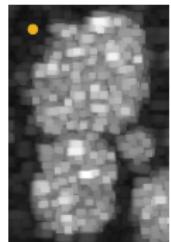


$a = 2^2$



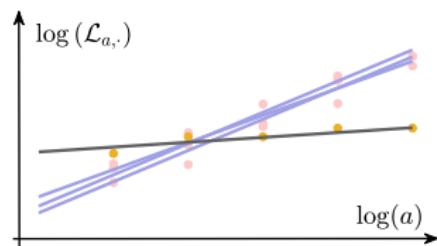
$a = 2^5$

...



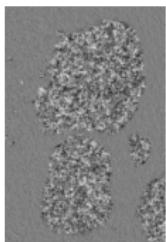
Proposition (Jaffard, 2004), (Wendt, 2008)

$$\log(\mathcal{L}_{a,\cdot}) \underset{a \rightarrow 0}{\simeq} \log(a) h_{\text{régularité}} + v_{\propto \log(\sigma^2) \text{ (variance)}}$$



# Analyse multi-échelle

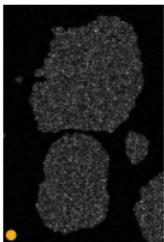
Image texturée



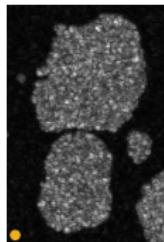
Maximum local des coefficients d'ondelettes :  $\mathcal{L}_{a,\cdot}$

Échelle

$a = 2^1$

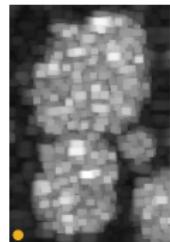


$a = 2^2$



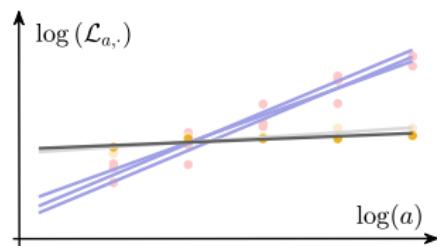
...

$a = 2^5$



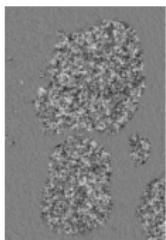
Proposition (Jaffard, 2004), (Wendt, 2008)

$$\log(\mathcal{L}_{a,\cdot}) \underset{a \rightarrow 0}{\simeq} \log(a) h_{\text{régularité}} + v_{\propto \log(\sigma^2) \text{ (variance)}}$$



# Analyse multi-échelle

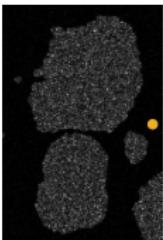
Image texturée



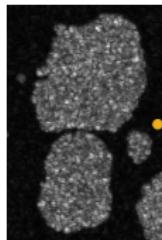
Maximum local des coefficients d'ondelettes :  $\mathcal{L}_{a,\cdot}$

Échelle

$a = 2^1$

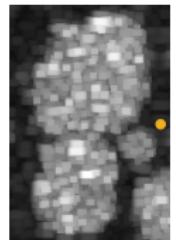


$a = 2^2$



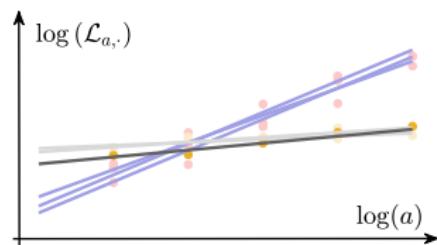
...

$a = 2^5$



Proposition (Jaffard, 2004), (Wendt, 2008)

$$\log(\mathcal{L}_{a,\cdot}) \underset{a \rightarrow 0}{\simeq} \log(a) h_{\text{régularité}} + v_{\propto \log(\sigma^2) \text{ (variance)}}$$

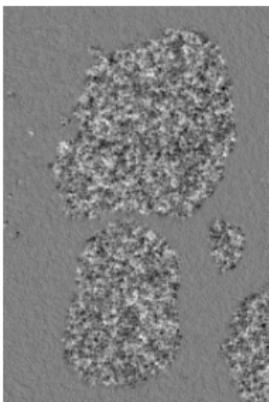


## Estimation directe ponctuelle

## Régression linéaire

$$\log(\mathcal{L}_{a,\cdot}) \simeq \log(a) \frac{\boldsymbol{h}}{\text{régularité}} + \frac{\boldsymbol{v}}{\propto \log(\sigma^2)}$$

Image texturée



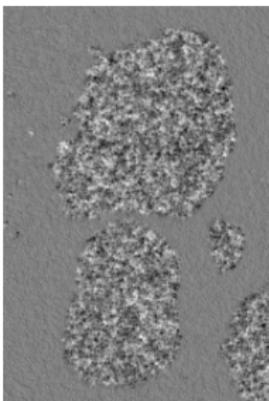
# Estimation directe ponctuelle

Régression linéaire

$$\log(\mathcal{L}_{a,\cdot}) \simeq \log(a) \underbrace{\boldsymbol{h}}_{\text{régularité}} + \underbrace{\boldsymbol{v}}_{\propto \log(\sigma^2)}$$

$$(\hat{\boldsymbol{h}}^{\text{RL}}, \hat{\boldsymbol{v}}^{\text{RL}}) = \underset{\boldsymbol{h}, \boldsymbol{v}}{\operatorname{argmin}} \sum_{a=a_{\min}}^{a_{\max}} \|\log(\mathcal{L}_{a,\cdot}) - \log(a)\boldsymbol{h} - \boldsymbol{v}\|^2$$

Image texturée



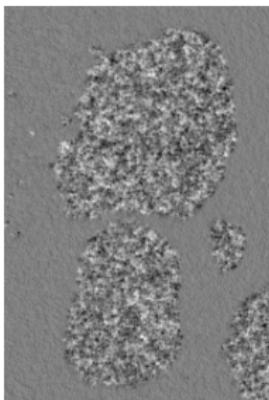
# Estimation directe ponctuelle

Régression linéaire

$$\log(\mathcal{L}_{a,\cdot}) \simeq \log(a) \frac{\boldsymbol{h}}{\text{régularité}} + \frac{\boldsymbol{v}}{\propto \log(\sigma^2)}$$

$$(\hat{\boldsymbol{h}}^{\text{RL}}, \hat{\boldsymbol{v}}^{\text{RL}}) = \underset{\boldsymbol{h}, \boldsymbol{v}}{\operatorname{argmin}} \sum_{a=a_{\min}}^{a_{\max}} \|\log(\mathcal{L}_{a,\cdot}) - \log(a)\boldsymbol{h} - \boldsymbol{v}\|^2$$

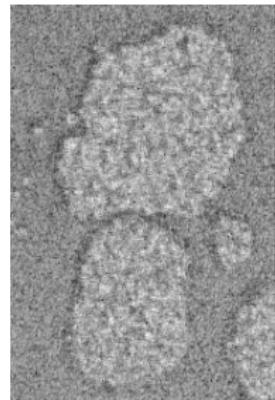
Image texturée



Régularité locale  $\hat{\boldsymbol{h}}^{\text{RL}}$



Puissance locale  $\hat{\boldsymbol{v}}^{\text{RL}}$



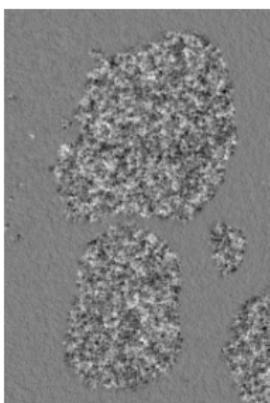
## Estimation directe ponctuelle

## Régression linéaire

$$\frac{\mathbb{E} \log(\mathcal{L}_{a,\cdot})}{\text{espérance}} = \log(a) \bar{h} + \bar{v}_{\infty \log(\sigma^2)}$$

$$\left(\hat{\boldsymbol{h}}^{\text{RL}}, \hat{\boldsymbol{v}}^{\text{RL}}\right) = \underset{\boldsymbol{h}, \boldsymbol{v}}{\operatorname{argmin}} \sum_{a=a_{\min}}^{a_{\max}} \|\log(\mathcal{L}_{a,\cdot}) - \log(a)\boldsymbol{h} - \boldsymbol{v}\|^2$$

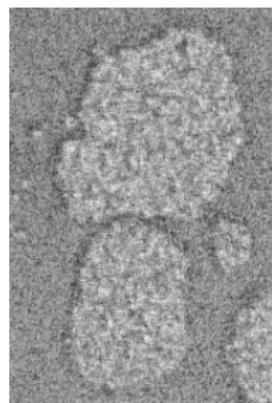
Image texturée



## Régularité locale $\widehat{\mathbf{h}}^{\text{RL}}$



## Puissance locale $\hat{\nu}^{\text{RL}}$



→ variance d'estimation élevée

## Régularisation *a posteriori*

Régression linéaire  $\hat{h}^{\text{RL}}$



## Régularisation *a posteriori*

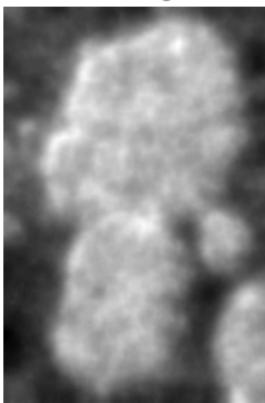
### Lissage par filtrage (linéaire)

$$\left(\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D}\right)^{-1} \hat{\mathbf{h}}^{\text{RL}}$$

Régression linéaire  $\widehat{h}^{\text{RL}}$



## Lissage



# Régularisation *a posteriori*

## Lissage par filtrage (linéaire)

$$\left(\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D}\right)^{-1} \hat{\mathbf{h}}^{\text{RL}}$$

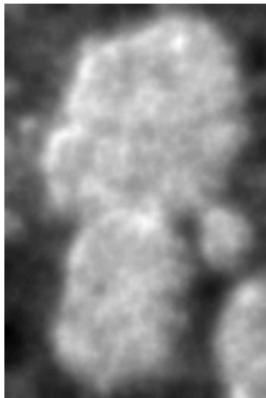
Régression linéaire  $\hat{\mathbf{h}}^{\text{RL}}$



## Débruitage ROF (non linéaire)

$$\operatorname{argmin}_{\mathbf{h}} \|\mathbf{h} - \hat{\mathbf{h}}^{\text{RL}}\|^2 + \lambda \|\mathbf{D}\mathbf{h}\|_{2,1}$$

Lissage



ROF



# Régularisation *a posteriori*

## Lissage par filtrage (linéaire)

$$\left(\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D}\right)^{-1} \hat{\mathbf{h}}^{\text{RL}}$$

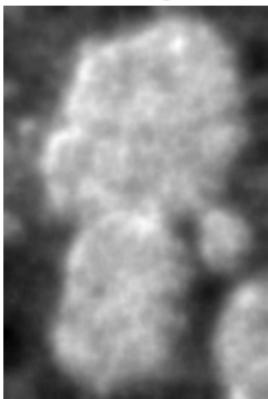
Régression linéaire  $\hat{\mathbf{h}}^{\text{RL}}$



## Débruitage ROF (non linéaire)

$$\operatorname{argmin}_{\mathbf{h}} \|\mathbf{h} - \hat{\mathbf{h}}^{\text{RL}}\|^2 + \lambda \|\mathbf{D}\mathbf{h}\|_{2,1}$$

Lissage



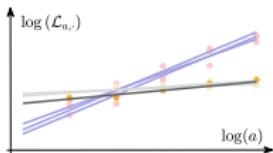
ROF



→ cumul de la variance d'estimation et du biais de régularisation

## Fonctionnelles à contours libres et à contours co-localisés

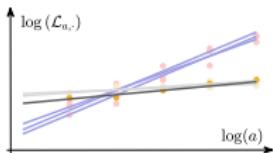
$$\sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} \rightarrow \text{fidélité au modèle log-linéaire}$$



# Fonctionnelles à contours libres et à contours co-localisés

$$\sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

→ fidélité au modèle log-linéaire  
→ favorise la constance par morceaux

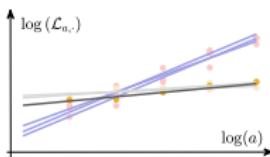


# Fonctionnelles à contours libres et à contours co-localisés

$$\text{minimiser}_{\mathbf{h}, \mathbf{v}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

→ fidélité au modèle log-linéaire

→ favorise la constance par morceaux

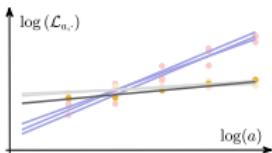


# Fonctionnelles à contours libres et à contours co-localisés

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

→ fidélité au modèle log-linéaire

→ favorise la constance par morceaux



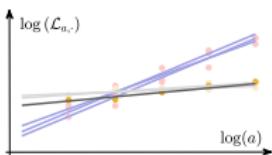
**Différences finies**  $\mathbf{D}_1\mathbf{x}$  (horizontales),  $\mathbf{D}_2\mathbf{x}$  (verticales) en chaque pixel

# Fonctionnelles à contours libres et à contours co-localisés

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

→ fidélité au modèle log-linéaire

→ favorise la constance par morceaux



**Différences finies**  $\mathbf{D}\mathbf{x} = [\mathbf{D}_1\mathbf{x}, \mathbf{D}_2\mathbf{x}]$

libres :  $\mathbf{h}$ ,  $\mathbf{v}$  sont **indépendamment** constantes par morceaux

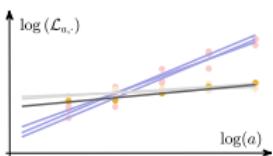
$$\mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha) = \alpha \|\mathbf{D}\mathbf{h}\|_{2,1} + \|\mathbf{D}\mathbf{v}\|_{2,1}$$

# Fonctionnelles à contours libres et à contours co-localisés

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

→ fidélité au modèle log-linéaire

→ favorise la constance par morceaux



**Différences finies**  $\mathbf{D}\mathbf{x} = [\mathbf{D}_1\mathbf{x}, \mathbf{D}_2\mathbf{x}]$

libres :  $\mathbf{h}$ ,  $\mathbf{v}$  sont **indépendamment** constantes par morceaux

$$\mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha) = \alpha \|\mathbf{D}\mathbf{h}\|_{2,1} + \|\mathbf{D}\mathbf{v}\|_{2,1}$$

co-localisés :  $\mathbf{h}$ ,  $\mathbf{v}$  sont **concomitamment** constantes par morceaux

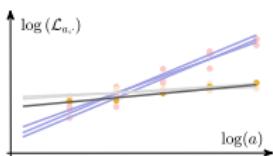
$$\mathcal{Q}_C(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha) = \|[\alpha \mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}]\|_{2,1}$$

# Fonctionnelles à contours libres et à contours co-localisés

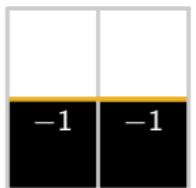
$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

→ fidélité au modèle log-linéaire

→ favorise la constance par morceaux



Contours disjoints

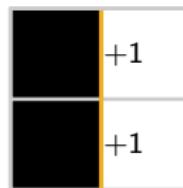


$$\mathbf{h} \in \mathbb{R}^{2 \times 2}$$

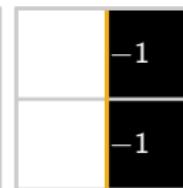


$$\mathbf{v} \in \mathbb{R}^{2 \times 2}$$

Contours communs



$$\mathbf{h} \in \mathbb{R}^{2 \times 2}$$

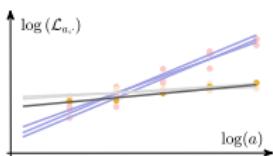


$$\mathbf{v} \in \mathbb{R}^{2 \times 2}$$

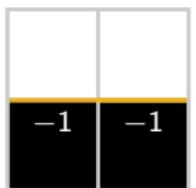
# Fonctionnelles à contours libres et à contours co-localisés

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

→ fidélité au modèle log-linéaire  
→ favorise la constance par morceaux



Contours disjoints



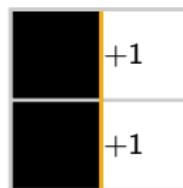
$$\mathbf{h} \in \mathbb{R}^{2 \times 2}$$



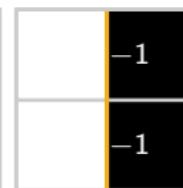
$$\mathbf{v} \in \mathbb{R}^{2 \times 2}$$

$$\mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; 1) = 4$$

Contours communs



$$\mathbf{h} \in \mathbb{R}^{2 \times 2}$$



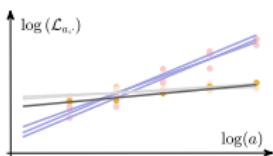
$$\mathbf{v} \in \mathbb{R}^{2 \times 2}$$

$$\mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; 1) = 4$$

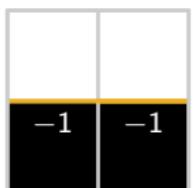
# Fonctionnelles à contours libres et à contours co-localisés

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

→ fidélité au modèle log-linéaire  
→ favorise la constance par morceaux



Contours disjoints



$$\mathbf{h} \in \mathbb{R}^{2 \times 2}$$

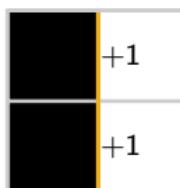


$$\mathbf{v} \in \mathbb{R}^{2 \times 2}$$

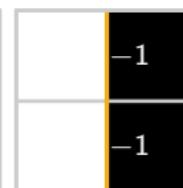
$$\mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; 1) = 4$$

$$\mathcal{Q}_C(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; 1) = 2 + \sqrt{2} \simeq 3,4$$

Contours communs



$$\mathbf{h} \in \mathbb{R}^{2 \times 2}$$



$$\mathbf{v} \in \mathbb{R}^{2 \times 2}$$

$$\mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; 1) = 4$$

$$\mathcal{Q}_C(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; 1) = 2\sqrt{2} \simeq 2,8$$

## Minimisation de fonctionnelle

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} \quad + \quad \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



# Minimisation de fonctionnelle

$$\text{minimiser}_{\mathbf{h}, \mathbf{v}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



- descente de gradient  $\mathbf{x}^{n+1} = \mathbf{x}^n - \tau \nabla \varphi(\mathbf{x}^n)$

# Minimisation de fonctionnelle

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \frac{\lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



- ▶ descente de gradient  $\mathbf{x}^{n+1} = \mathbf{x}^n - \tau \nabla \varphi(\mathbf{x}^n)$
- ▶ descente de sous-gradient implicite : algorithme du point proximal  
$$\mathbf{x}^{n+1} = \mathbf{x}^n - \mathbf{u}^n, \quad \mathbf{u}^n \in \partial \varphi(\mathbf{x}^{n+1}) \Leftrightarrow \mathbf{x}^{n+1} = \text{prox}_{\tau \varphi}(\mathbf{x}^n)$$

# Minimisation de fonctionnelle

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



- ▶ descente de gradient  $\mathbf{x}^{n+1} = \mathbf{x}^n - \tau \nabla \varphi(\mathbf{x}^n)$
- ▶ descente de sous-gradient implicite : algorithme du point proximal  

$$\mathbf{x}^{n+1} = \mathbf{x}^n - \mathbf{u}^n, \quad \mathbf{u}^n \in \partial \varphi(\mathbf{x}^{n+1}) \Leftrightarrow \mathbf{x}^{n+1} = \text{prox}_{\tau \varphi}(\mathbf{x}^n)$$
- ▶ algorithme proximal scindé

$$\mathbf{y}^{n+1} = \text{prox}_{\sigma(\lambda \mathcal{Q})^*} (\mathbf{y}^n + \sigma \mathbf{D} \bar{\mathbf{x}}^n)$$

$$\mathbf{x}^{n+1} = \text{prox}_{\tau \|\mathcal{L} - \Phi \cdot\|_2^2} \left( \mathbf{x}^n - \tau \mathbf{D}^\top \mathbf{y}^{n+1} \right), \quad \Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a$$

$$\bar{\mathbf{x}}^{n+1} = 2\mathbf{x}^{n+1} - \mathbf{x}^n$$

# Minimisation de fonctionnelle

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



- ▶ descente de gradient  $\mathbf{x}^{n+1} = \mathbf{x}^n - \tau \nabla \varphi(\mathbf{x}^n)$
- ▶ descente de sous-gradient implicite : algorithme du point proximal

$$\mathbf{x}^{n+1} = \mathbf{x}^n - \mathbf{u}^n, \quad \mathbf{u}^n \in \partial \varphi(\mathbf{x}^{n+1}) \Leftrightarrow \mathbf{x}^{n+1} = \text{prox}_{\tau \varphi}(\mathbf{x}^n)$$

- ▶ algorithme proximal scindé

$$\text{prox}_{\tau \varphi}(\mathbf{x}) = \operatorname{argmin}_{\mathbf{u}} \frac{1}{2} \|\mathbf{x} - \mathbf{u}\|^2 + \tau \varphi(\mathbf{u})$$

$$\mathbf{y}^{n+1} = \text{prox}_{\sigma(\lambda \mathcal{Q})^*} (\mathbf{y}^n + \sigma \mathbf{D} \bar{\mathbf{x}}^n)$$

$$\mathbf{x}^{n+1} = \text{prox}_{\tau \|\mathcal{L} - \Phi \cdot\|_2^2} \left( \mathbf{x}^n - \tau \mathbf{D}^\top \mathbf{y}^{n+1} \right), \quad \Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a$$

$$\bar{\mathbf{x}}^{n+1} = 2\mathbf{x}^{n+1} - \mathbf{x}^n$$

# Calcul des opérateurs proximaux

$$\text{minimiser}_{\mathbf{h}, \mathbf{v}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



# Calcul des opérateurs proximaux

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} \quad + \quad \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



**Ex. Norme mixte :** pour  $z = [z_1; \dots; z_l]$

$$\mathcal{Q}(\mathbf{z}) = \|\mathbf{z}\|_{2,1} = \sum_{n \in \Omega} \sqrt{\sum_{i=1}^l z_i^2(n)} = \sum_{n \in \Omega} \|\mathbf{z}(n)\|_2$$

## Calcul des opérateurs proximaux

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



**Ex. Norme mixte :** pour  $z = [z_1; \dots; z_l]$

$$\mathcal{Q}(\mathbf{z}) = \|\mathbf{z}\|_{2,1} = \sum_{n \in \Omega} \sqrt{\sum_{i=1}^l z_i^2(n)} = \sum_{n \in \Omega} \|\mathbf{z}(n)\|_2$$

$$\boldsymbol{p} = \text{prox}_{\lambda \|\cdot\|_{2,1}}(\boldsymbol{z}) \quad \Leftrightarrow \quad p_i(\underline{n}) = \max \left( 0, 1 - \frac{\lambda}{\|\boldsymbol{z}(\underline{n})\|_2} \right) z_i(\underline{n})$$

# Calcul des opérateurs proximaux

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



**Moindres carrés :**  $\|\log \mathcal{L} - \Phi(\mathbf{h}, \mathbf{v})\|^2$ ,     $\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a$

# Calcul des opérateurs proximaux

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



**Moindres carrés** :  $\|\log \mathcal{L} - \Phi(\mathbf{h}, \mathbf{v})\|^2$ ,     $\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a$

Proposition (*Pascal, 2019*)

$$(\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = \text{prox}_{\tau \|\mathcal{L} - \Phi\|_F^2}(\mathbf{h}, \mathbf{v}) \iff (\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = (\mathbf{I} + \tau \Phi^\top \Phi)^{-1} ((\mathbf{h}, \mathbf{v}) + \tau \Phi^\top \log \mathcal{L})$$

# Calcul des opérateurs proximaux

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



non lisse



**Moindres carrés** :  $\|\log \mathcal{L} - \Phi(\mathbf{h}, \mathbf{v})\|^2$ ,     $\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a$

Proposition (*Pascal, 2019*)

Soit  $S_m = \sum_a \log^m(a)$ ,  $\mathcal{D} = (1 + \tau S_2)(1 + \tau S_0) - \tau^2 S_1^2$ ,  
 $\mathcal{T} = \sum_a \log \mathcal{L}_a$  et  $\mathcal{G} = \sum_a \log(a) \log \mathcal{L}_a$ , alors

$$\begin{aligned} (\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = & \text{prox}_{\tau \|\mathcal{L} - \Phi\|_2^2}(\mathbf{h}, \mathbf{v}) \iff (\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = (\mathbf{I} + \tau \Phi^\top \Phi)^{-1} ((\mathbf{h}, \mathbf{v}) + \tau \Phi^\top \log \mathcal{L}) \\ \iff & \left\{ \begin{array}{l} \tilde{\mathbf{h}} = \mathcal{D}^{-1} ((1 + \tau S_0)(\tau \mathcal{G} + \mathbf{h}) - \tau S_1(\tau \mathcal{T} + \mathbf{v})) \\ \tilde{\mathbf{v}} = \mathcal{D}^{-1} ((1 + \tau S_2)(\tau \mathcal{T} + \mathbf{v}) - \tau S_1(\tau \mathcal{G} + \mathbf{h})) \end{array} \right. \end{aligned}$$

# Algorithme accéléré par forte-convexité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \frac{\lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



Algorithme primal-dual

non lisse



(Chambolle, 2011)

$$\delta : \text{gap de dualité}, \delta(\mathbf{x}^n, \mathbf{y}^n) \xrightarrow{n \rightarrow +\infty} 0$$

# Algorithme accéléré par forte-convexité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \frac{\lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



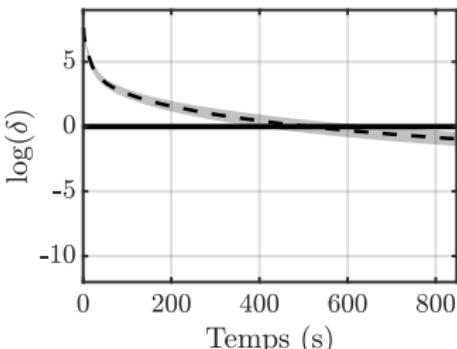
Algorithme primal-dual

non lisse



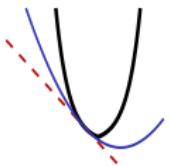
(Chambolle, 2011)

$$\delta : \text{gap de dualité}, \delta(\mathbf{x}^n, \mathbf{y}^n) \xrightarrow{n \rightarrow +\infty} 0$$



# Propriétés de convexité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



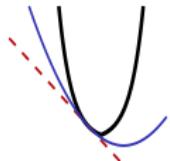
$\mu$ -fortement convexe

non lisse



# Propriétés de convexité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \frac{\lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



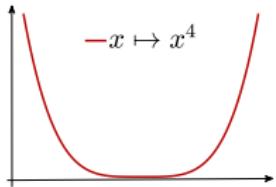
$\mu$ -fortement convexe

non lisse

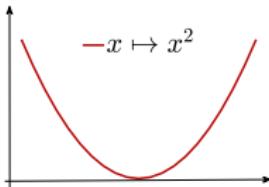


## Forte convexité

- $\varphi$   $\mu$ -fortement convexe ssi  $\varphi - \frac{\mu}{2}\|\cdot\|^2$  convexe



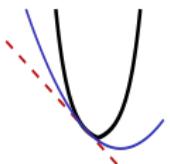
✓ strictement convexe  
✗ non fortement convexe



✓ strictement convexe  
✓ 1-fortement convexe

# Propriétés de convexité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \frac{\lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



$\mu$ -fortement convexe

non lisse

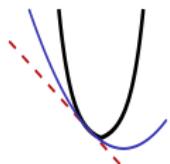


## Forte convexité

- $\varphi$   $\mu$ -fortement convexe ssi  $\varphi - \frac{\mu}{2} \|\cdot\|^2$  convexe
- $\varphi \in \mathcal{C}^2$  de hessienne  $\mathbf{H}\varphi \succeq 0 \implies \mu = \min \text{Sp}(\mathbf{H}\varphi)$

# Propriétés de convexité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



$\mu$ -fortement convexe

non lisse



## Forte convexité

- $\varphi$   $\mu$ -fortement convexe ssi  $\varphi - \frac{\mu}{2}\|\cdot\|^2$  convexe
- $\varphi \in \mathcal{C}^2$  de hessienne  $\mathbf{H}\varphi \succeq 0 \Rightarrow \mu = \min \text{Sp}(\mathbf{H}\varphi)$

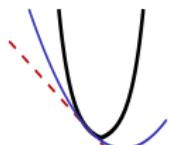
## Proposition (Pascal, 2019)

$\sum_a \|\log \mathcal{L} - \log(a)\mathbf{h} - \mathbf{v}\|^2$  est  $\mu$ -fortement convexe.

$a_{\min} = 2^1, \quad a_{\max}$	$2^2$	$2^3$	$2^4$	$2^5$	$2^6$
$\mu = \min \text{Sp}(\Phi^\top \Phi)$	0.29	<b>0.72</b>	1.20	1.69	2.20

# Algorithme accéléré par forte-convexité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \frac{\lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



$\mu$ -fortement convexe



non lisse

Algorithme primal-dual **accéléré** (*Chambolle, 2011*)

**for**  $n = 0, 1, \dots$   $\mathbf{x} = (\mathbf{h}, \mathbf{v})$

$$\mathbf{y}^{n+1} = \text{prox}_{\sigma_n(\lambda \mathcal{Q})^*}(\mathbf{y}^n + \sigma_n \mathbf{D}\bar{\mathbf{x}}^n)$$

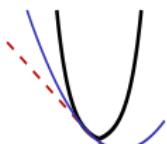
$$\mathbf{x}^{n+1} = \text{prox}_{\tau_n \|\mathcal{L} - \Phi\cdot\|_2^2} \left( \mathbf{x}^n - \tau_n \mathbf{D}^\top \mathbf{y}^{n+1} \right)$$

$$\theta_n = \sqrt{1 + 2\mu\tau_n}, \quad \tau_{n+1} = \tau_n / \theta_n, \quad \sigma_{n+1} = \theta_n \sigma_n$$

$$\bar{\mathbf{x}}^{n+1} = \mathbf{x}^{n+1} + \theta_n^{-1} (\mathbf{x}^{n+1} - \mathbf{x}^n)$$

# Algorithme accéléré par forte-convexité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$



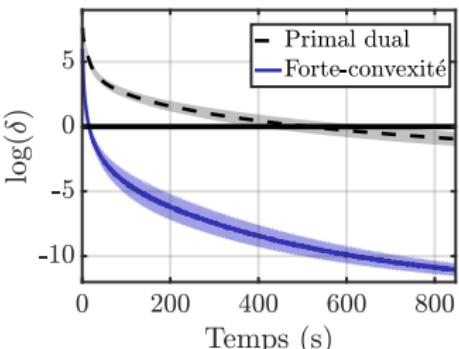
$\mu$ -fortement convexe

non lisse



Algorithme primal-dual **accéléré** (*Chambolle, 2011*)

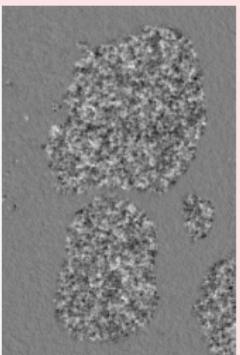
$$\delta : \text{gap de dualité}, \delta(\mathbf{x}^n, \mathbf{y}^n) \xrightarrow{n \rightarrow +\infty} 0$$



# Segmentation par seuillage itératif

$$\text{minimiser}_{\mathbf{h}, \mathbf{v}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

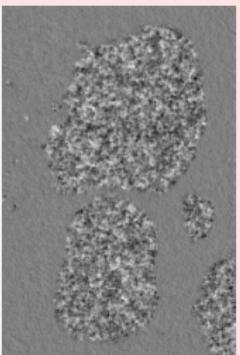
Image texturée



# Segmentation par seuillage itéré

$$\text{minimiser}_{\mathbf{h}, \mathbf{v}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

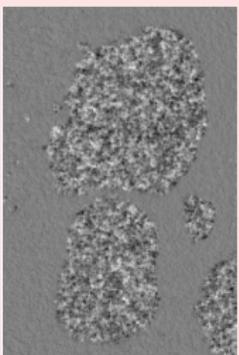
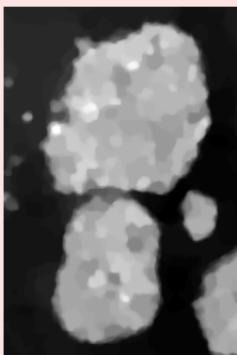
Image texturée      Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$



# Segmentation par seuillage itéré

$$\text{minimiser}_{\mathbf{h}, \mathbf{v}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

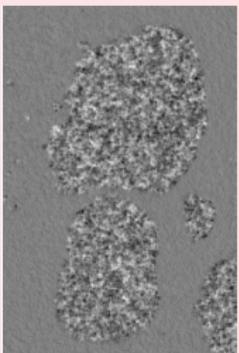
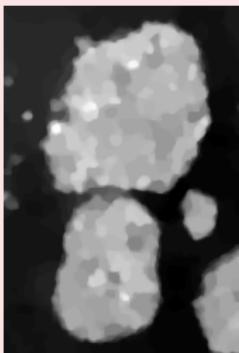
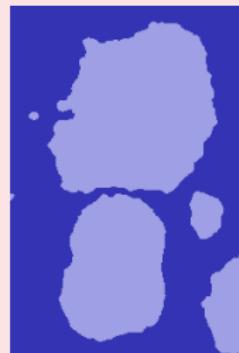
Image texturée

Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$ Contours co-localisés  $\hat{\mathbf{h}}^{\text{C}}$ 

# Segmentation par seuillage itéré

$$\text{minimiser}_{\mathbf{h}, \mathbf{v}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

Image texturée

Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$ Contours co-localisés  $\hat{\mathbf{h}}^{\text{C}}$ Estimée seuillée<sup>†</sup>  $S\hat{\mathbf{h}}^{\text{C}}$ 

<sup>†</sup>(Cai, 2013)

# Méthodes de l'état-de-l'art en segmentation de texture

## ROF-Seuillé sur $\hat{\mathbf{h}}^{\text{RL}}$

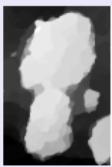
(Naftornita, 2014), (Pustelnik, 2016)

$$\operatorname{argmin}_{\mathbf{h}} \|\mathbf{h} - \hat{\mathbf{h}}^{\text{RL}}\|^2 + \lambda \|\mathbf{D}\mathbf{h}\|_{2,1}$$

Rég. lin.



ROF



Seuillage



S'appuie uniquement sur la régularité  $\mathbf{h}$ .

# Méthodes de l'état-de-l'art en segmentation de texture

## ROF-Seuillé sur $\hat{h}^{\text{RL}}$

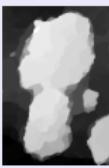
(Naftornita, 2014), (Pustelnik, 2016)

$$\operatorname{argmin}_{\mathbf{h}} \|\mathbf{h} - \hat{\mathbf{h}}^{\text{RL}}\|^2 + \lambda \|\mathbf{D}\mathbf{h}\|_{2,1}$$

Rég. lin.



ROF



Seuillage



S'appuie uniquement sur la régularité  $\mathbf{h}$ .

<sup>†</sup><https://sites.google.com/site/factorizationsegmentation/>

## Segmentation par factorisation matricielle<sup>†</sup> (Yuan, 2015)

(i) histogrammes locaux



(ii) factorisation matricielle

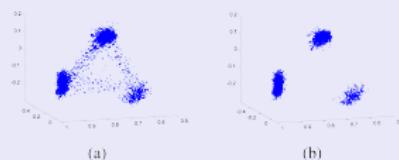
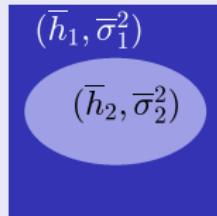


Fig. 2. Scatterplot of features in subspace. (a) Scatterplot of features projected onto the 3-d subspace. (b) Scatterplot after removing features with high edginess.

# Performances comparées sur des textures synthétiques

## Synthèse de texture monofractale par morceaux (*Pascal, 2019*)

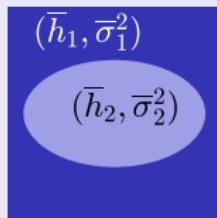
- ▶ masque :  $\Omega = \Omega_1 \sqcup \Omega_2$ ,
- ▶ attributs :  $(\bar{h}_k, \bar{\sigma}_k^2)_{k=1,2}$



# Performances comparées sur des textures synthétiques

## Synthèse de texture monofractale par morceaux (*Pascal, 2019*)

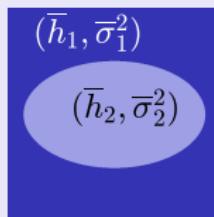
- ▶ masque :  $\Omega = \Omega_1 \sqcup \Omega_2$ ,
  - ▶ attributs :  $(\bar{h}_k, \bar{\sigma}_k^2)_{k=1,2}$
- Ex.**     $\bar{h}_1 = 0,5, \bar{\sigma}_1^2 = 0,6$   
           $\bar{h}_2 = 0,6, \bar{\sigma}_2^2 = 0,7$



# Performances comparées sur des textures synthétiques

## Synthèse de texture monofractale par morceaux (*Pascal, 2019*)

- ▶ masque :  $\Omega = \Omega_1 \sqcup \Omega_2$ ,
  - ▶ attributs :  $(\bar{h}_k, \bar{\sigma}_k^2)_{k=1,2}$
- Ex.**  $\bar{h}_1 = 0,5, \bar{\sigma}_1^2 = 0,6$   
 $\bar{h}_2 = 0,6, \bar{\sigma}_2^2 = 0,7$



## Performances de segmentation moyennées sur 5 réalisations

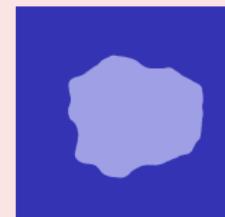
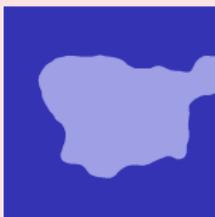
Yuan



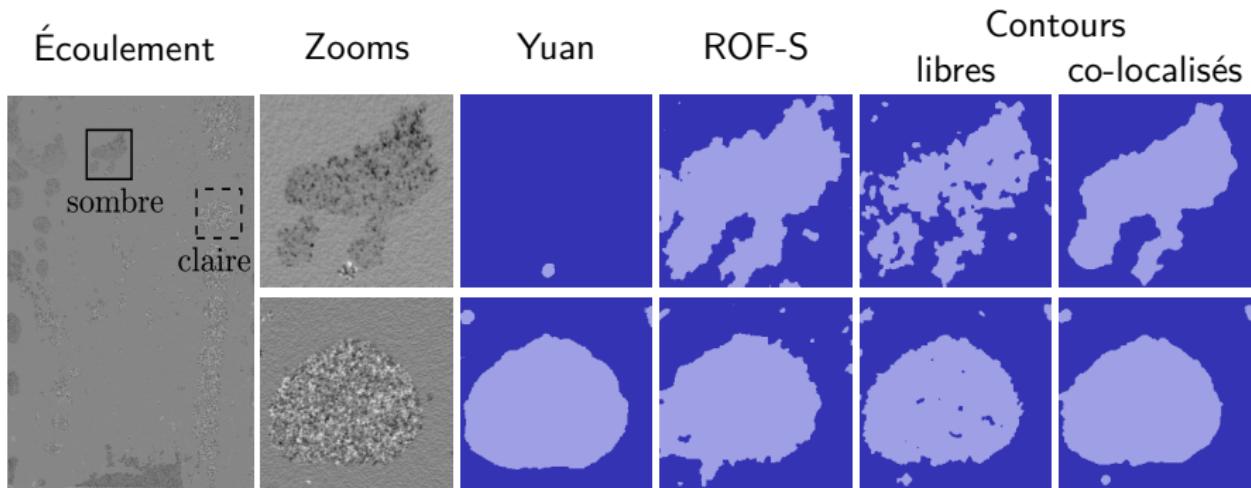
ROF-S



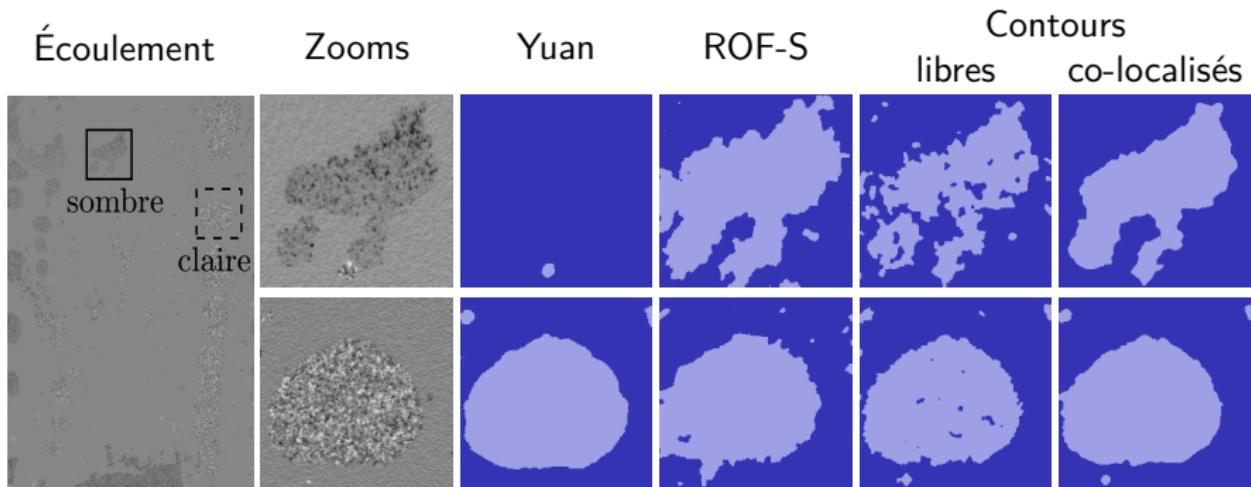
Contours libres co-localisés

 $71,1 \pm 1,3\%$  $78,5 \pm 1,1\%$  $90,2 \pm 1,9\%$  $91,1 \pm 1,5\%$

# Faible activité : $Q_G = 300\text{mL/min}$ - $Q_L = 300\text{mL/min}$



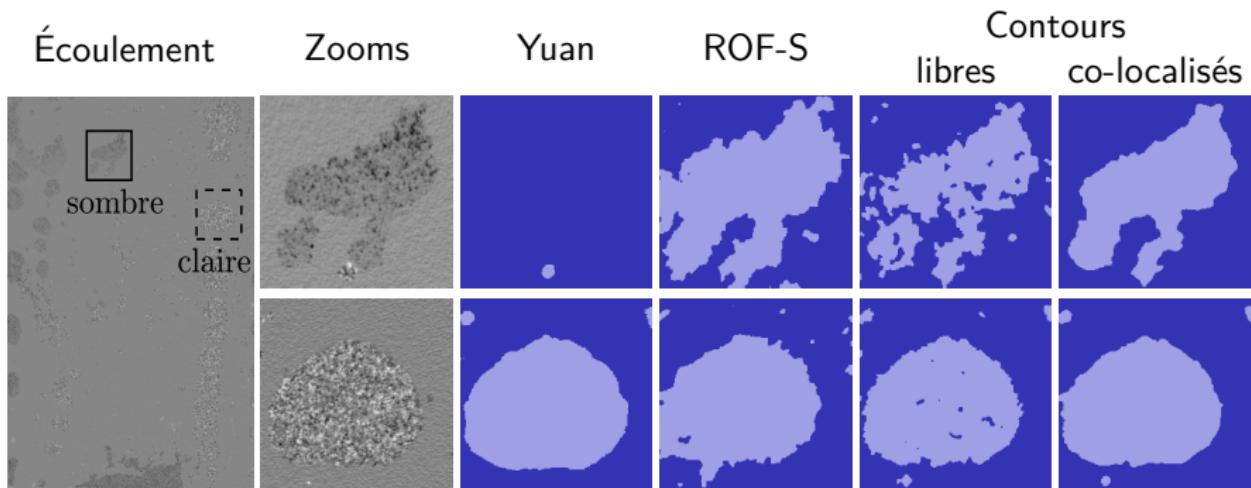
# Faible activité : $Q_G = 300\text{mL/min}$ - $Q_L = 300\text{mL/min}$



Liquide :  $h_L = 0,4$

Gaz :  $h_G = 0,9$

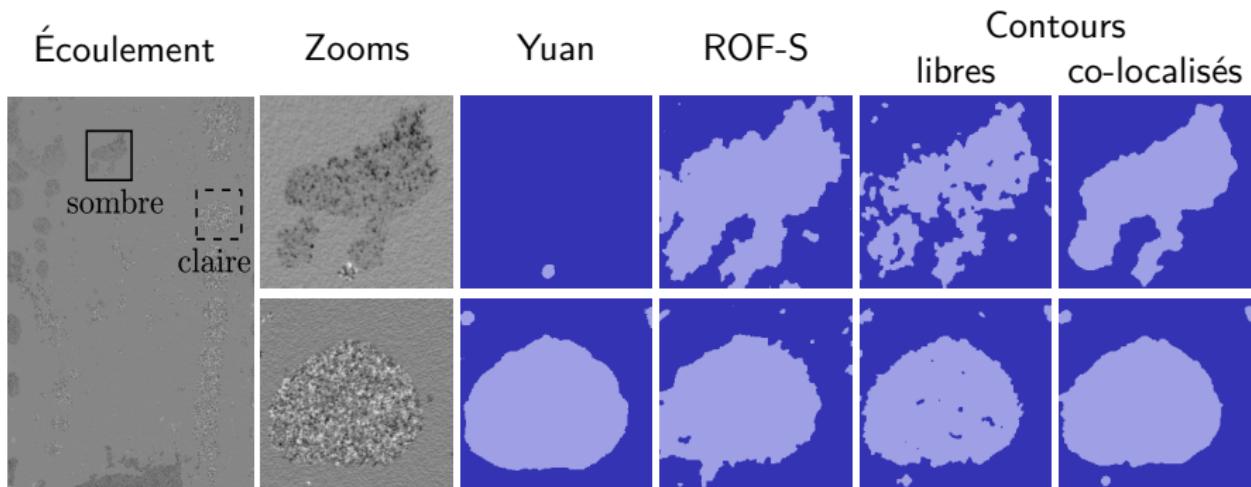
# Faible activité : $Q_G = 300\text{mL/min}$ - $Q_L = 300\text{mL/min}$



Liquide :  $h_L = 0,4$        $\sigma_{\text{sombre}}^2 = 10^{-2}$

Gaz :       $h_G = 0,9$

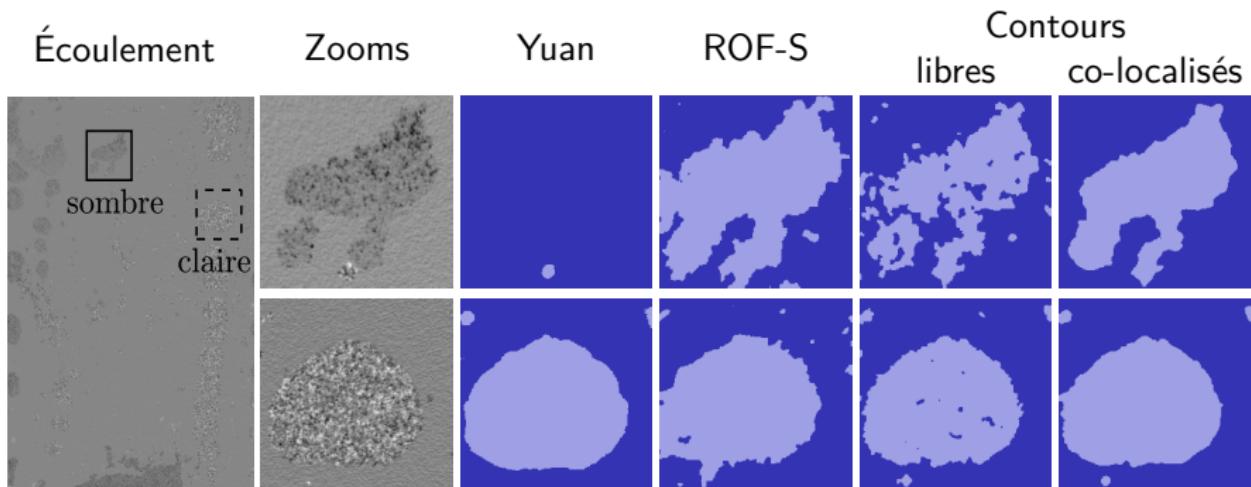
# Faible activité : $Q_G = 300\text{mL/min}$ - $Q_L = 300\text{mL/min}$



Liquide :  $h_L = 0,4$        $\sigma_{\text{sombre}}^2 = 10^{-2}$

Gaz :       $h_G = 0,9$

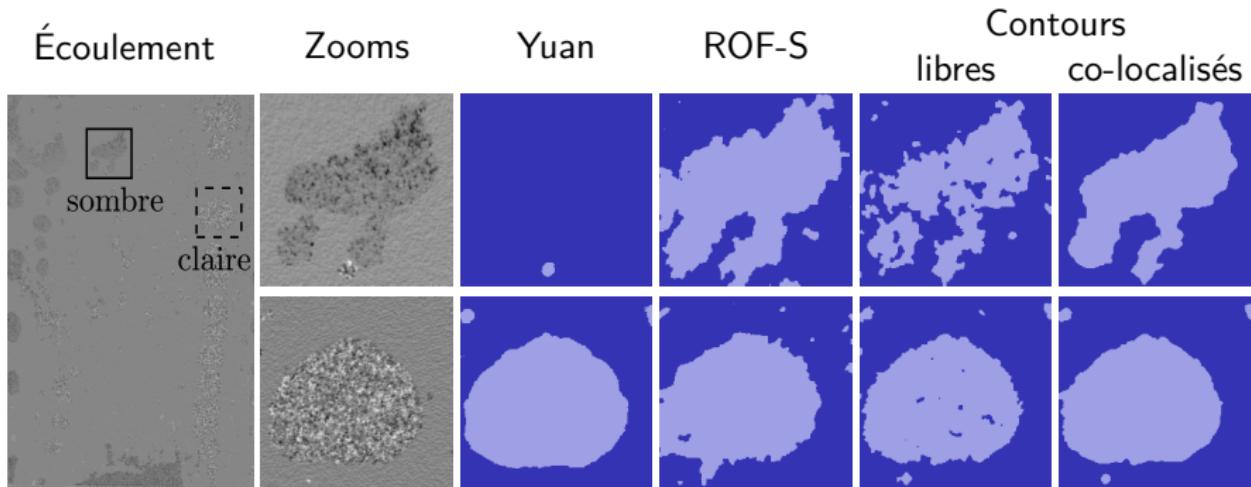
# Faible activité : $Q_G = 300\text{mL/min}$ - $Q_L = 300\text{mL/min}$



Liquide :  $h_L = 0,4$        $\sigma_{\text{sombre}}^2 = 10^{-2}$

Gaz :       $h_G = 0,9$       |     $\sigma_{\text{sombre}}^2 = 10^{-2}$  (bulles sombres)

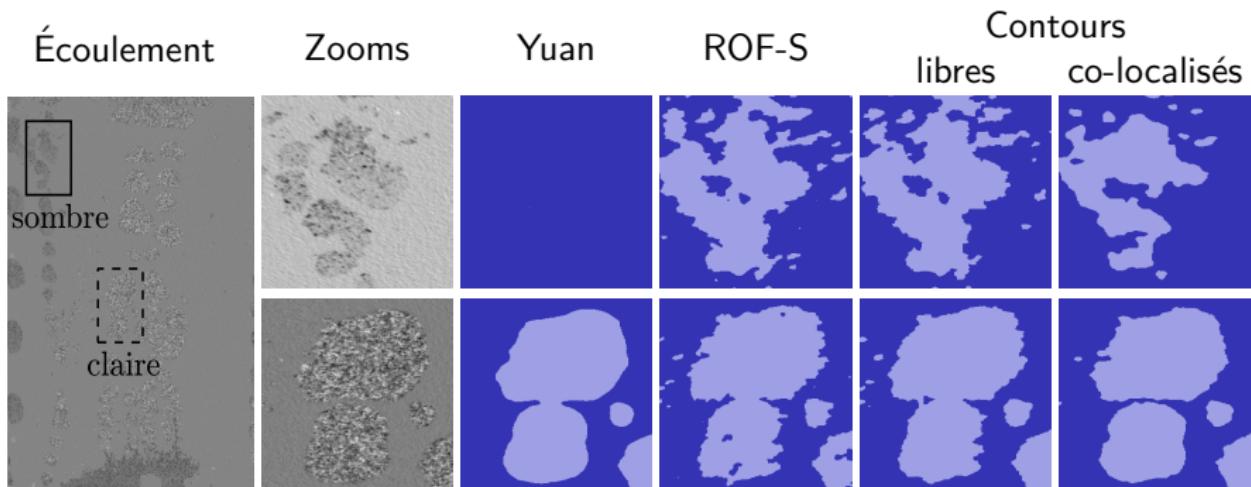
# Faible activité : $Q_G = 300\text{mL/min}$ - $Q_L = 300\text{mL/min}$



Liquide :  $h_L = 0,4$        $\sigma_{\text{sombre}}^2 = 10^{-2}$

Gaz :       $h_G = 0,9$       |       $\sigma_{\text{sombre}}^2 = 10^{-2}$  (bulles sombres)  
                        |       $\sigma_{\text{claire}}^2 = 10^{-1}$  (bulles claires)

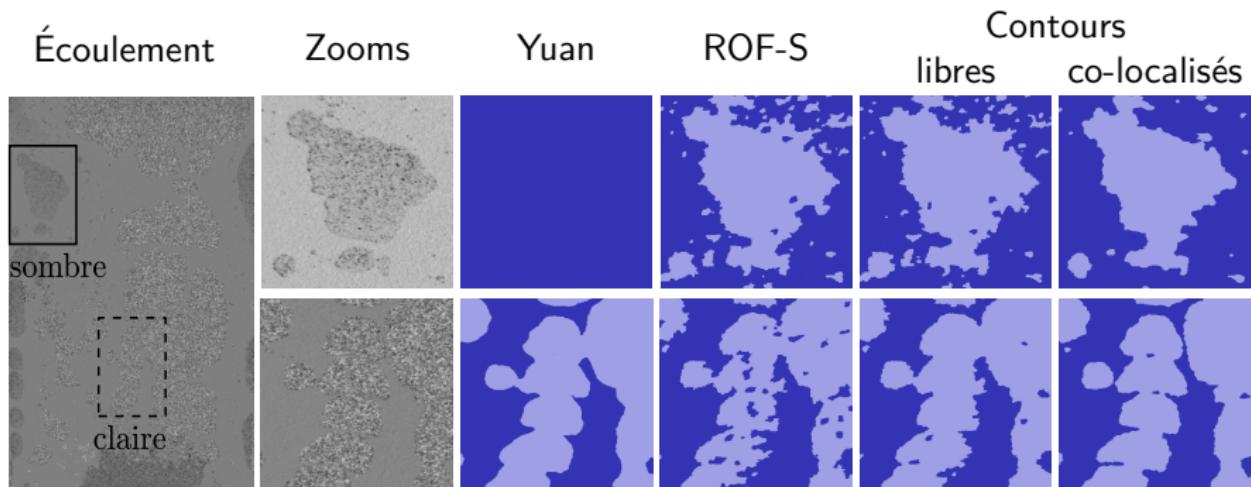
# Transition : $Q_G = 400\text{mL/min}$ - $Q_L = 700\text{mL/min}$



Liquide :  $h_L = 0,4$        $\sigma_{\text{sombre}}^2 = 10^{-2}$

Gaz :       $h_G = 0,9$       |     $\sigma_{\text{sombre}}^2 = 10^{-2}$  (bulles sombres)  
                        |     $\sigma_{\text{claire}}^2 = 10^{-1}$  (bulles claires).

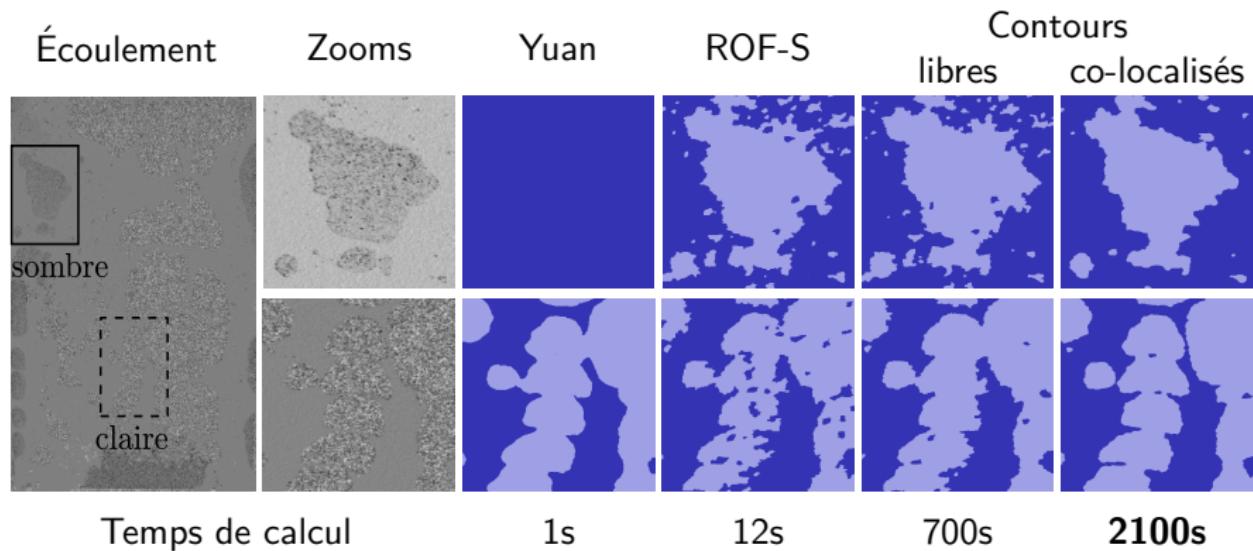
Forte activité :  $Q_G = 1200 \text{mL/min}$  -  $Q_L = 300 \text{mL/min}$



Liquide :  $h_L = 0,4$        $\sigma_{\text{sombre}}^2 = 10^{-2}$

Gaz :       $h_G = 0,9$       |     $\sigma_{\text{sombre}}^2 = 10^{-2}$  (bulles sombres)  
    |     $\sigma_{\text{claire}}^2 = 10^{-1}$  (bulles claires).

Forte activité :  $Q_G = 1200 \text{mL/min}$  -  $Q_L = 300 \text{mL/min}$



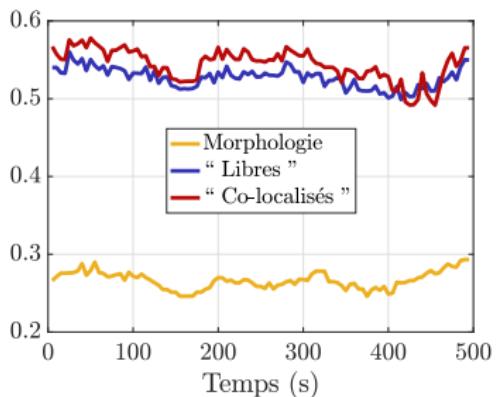
Liquide :  $h_L = 0,4$        $\sigma_{\text{sombre}}^2 = 10^{-2}$

Gaz :       $h_G = 0,9$       |       $\sigma_{\text{sombre}}^2 = 10^{-2}$  (bulles sombres)  
                        |       $\sigma_{\text{claire}}^2 = 10^{-1}$  (bulles claires).

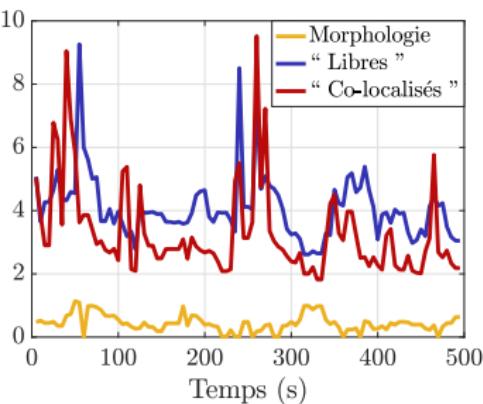
# Écoulement multiphasiques en milieu poreux

Laboratoire de Physique, ENS Lyon, V. Vidal, T. Busser, (M. Serres, IFPEN)

Fraction de gaz dans la cellule



Périmètre d'interface



# Réglage des paramètres de régularisation

$$\left(\hat{\boldsymbol{h}}, \hat{\boldsymbol{v}}\right) (\mathcal{L}; \lambda, \alpha) = \operatorname{argmin}_{\boldsymbol{h}, \boldsymbol{v}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \boldsymbol{h} - \boldsymbol{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\boldsymbol{h}, \mathbf{D}\boldsymbol{v}; \alpha)$$

# Réglage des paramètres de régularisation

$$\left(\hat{\mathbf{h}}, \hat{\mathbf{v}}\right) (\mathcal{L}; \lambda, \alpha) = \operatorname{argmin}_{\mathbf{h}, \mathbf{v}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$

$$(\lambda; \alpha) = (0; 0)$$

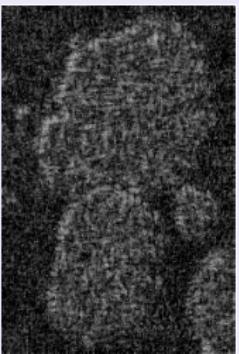


# Réglage des paramètres de régularisation

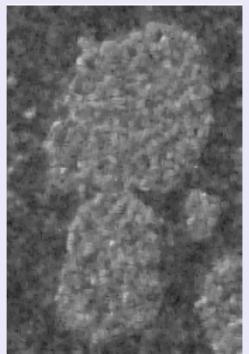
$$\left(\hat{\mathbf{h}}, \hat{\mathbf{v}}\right) (\mathcal{L}; \lambda, \alpha) = \operatorname{argmin}_{\mathbf{h}, \mathbf{v}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$

$$(\lambda; \alpha) = (0; 0) \quad (\lambda, \alpha) = (0,5; 0,5)$$



Estimée  $\hat{\mathbf{h}}^{\text{C}}$  à contours co-localisés



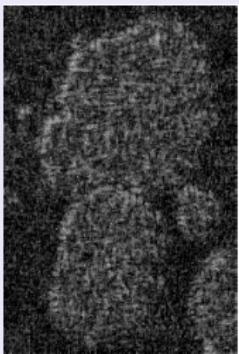
trop faible

# Réglage des paramètres de régularisation

$$\left(\hat{\mathbf{h}}, \hat{\mathbf{v}}\right) (\mathcal{L}; \lambda, \alpha) = \operatorname{argmin}_{\mathbf{h}, \mathbf{v}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

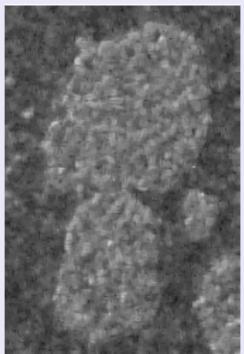
Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$

$$(\lambda; \alpha) = (0; 0) \quad (\lambda, \alpha) = (0,5; 0,5)$$



Estimée  $\hat{\mathbf{h}}^{\text{C}}$  à contours co-localisés

$$(\lambda; \alpha) = (500; 500)$$



trop faible



trop grand

# Réglage des paramètres de régularisation

$$\left(\hat{\mathbf{h}}, \hat{\mathbf{v}}\right) (\mathcal{L}; \lambda, \alpha) = \operatorname{argmin}_{\mathbf{h}, \mathbf{v}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

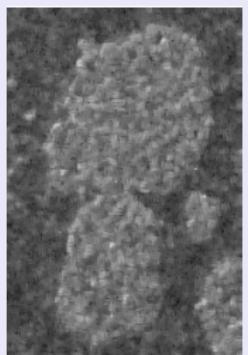
Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$

$$(\lambda; \alpha) = (0; 0)$$

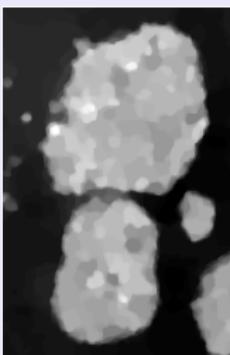
$$(\lambda, \alpha) = (0,5; 0,5) \quad (\lambda^\dagger, \alpha^\dagger) = (11,5; 0,8) \quad (\lambda; \alpha) = (500; 500)$$



trop faible



optimal



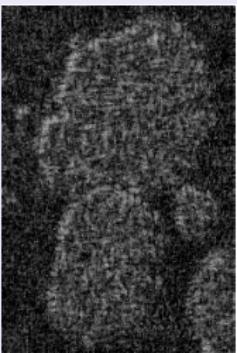
trop grand

# Réglage des paramètres de régularisation

$$\left(\hat{\mathbf{h}}, \hat{\mathbf{v}}\right) (\mathcal{L}; \lambda, \alpha) = \operatorname{argmin}_{\mathbf{h}, \mathbf{v}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

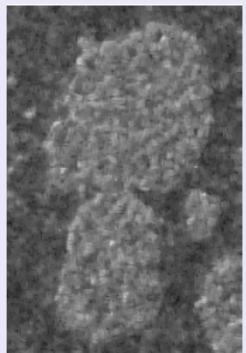
Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$

$$(\lambda; \alpha) = (0; 0)$$

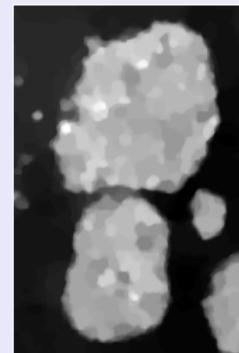


Estimée  $\hat{\mathbf{h}}^C$  à contours co-localisés

$$(\lambda, \alpha) = (0,5; 0,5)$$



$$(\lambda^\dagger, \alpha^\dagger) = (11,5; 0,8)$$



$$(\lambda; \alpha) = (500; 500)$$



trop faible

optimal

trop grand

Que signifie *optimal* ?

# Réglage des paramètres de régularisation

$$\left(\hat{\mathbf{h}}, \hat{\mathbf{v}}\right) (\mathcal{L}; \lambda, \alpha) = \operatorname{argmin}_{\mathbf{h}, \mathbf{v}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

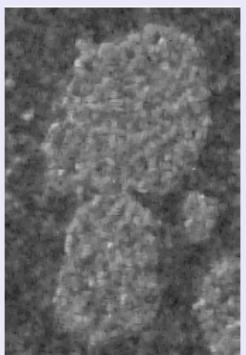
Rég. lin.  $\hat{\mathbf{h}}^{\text{RL}}$

$$(\lambda; \alpha) = (0; 0)$$

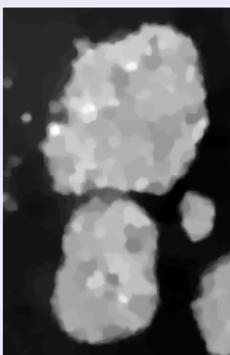
$$(\lambda, \alpha) = (0,5; 0,5) \quad (\lambda^\dagger, \alpha^\dagger) = (11,5; 0,8) \quad (\lambda; \alpha) = (500; 500)$$



trop faible



optimal



trop grand

Que signifie *optimal*? Comment déterminer  $\lambda^\dagger$  et  $\alpha^\dagger$ ?

## Réglage des paramètres (Recherche systématique)

$$\left(\hat{\mathbf{h}}, \hat{\mathbf{v}}\right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

$\mathbf{h}$  : discriminant,  $\mathbf{v}$  : auxiliaire

# Réglage des paramètres (Recherche systématique)

$$\left(\hat{\mathbf{h}}, \hat{\mathbf{v}}\right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

$\mathbf{h}$  : discriminant,  $\mathbf{v}$  : auxiliaire

$\bar{\mathbf{h}}$  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$

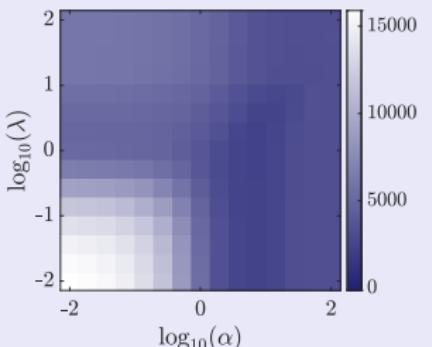
# Réglage des paramètres (Recherche systématique)

$$\left( \hat{\mathbf{h}}, \hat{\mathbf{v}} \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

**$\mathbf{h}$**  : discriminant,  **$\mathbf{v}$**  : auxiliaire

**$\bar{\mathbf{h}}$**  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



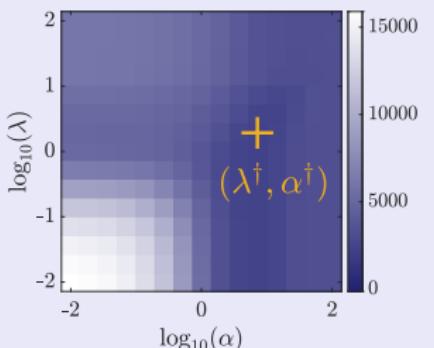
# Réglage des paramètres (Recherche systématique)

$$\left( \hat{\mathbf{h}}, \hat{\mathbf{v}} \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

**$\mathbf{h}$**  : discriminant,  **$\mathbf{v}$**  : auxiliaire

**$\bar{\mathbf{h}}$**  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



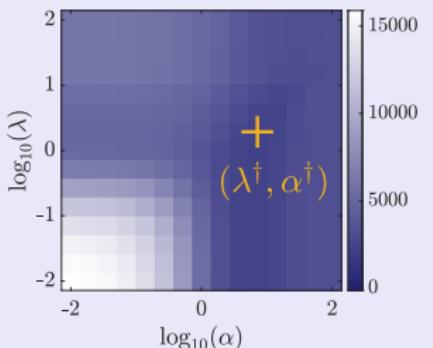
# Réglage des paramètres (Recherche systématique)

$$\left( \hat{\mathbf{h}}, \hat{\mathbf{v}} \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

$\mathbf{h}$  : discriminant,  $\mathbf{v}$  : auxiliaire

$\bar{\mathbf{h}}$  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



$\bar{\mathbf{h}}$  : inconnue !

?

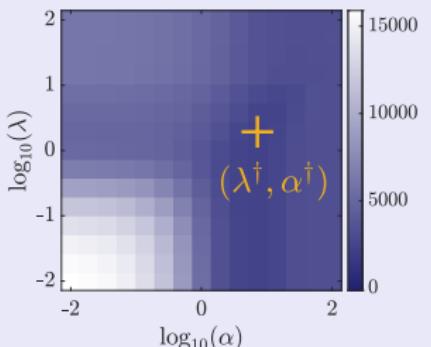
# Réglage des paramètres (Recherche systématique)

$$\left( \hat{\mathbf{h}}, \hat{\mathbf{v}} \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

$\mathbf{h}$  : discriminant,  $\mathbf{v}$  : auxiliaire

$\bar{\mathbf{h}}$  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



$\bar{\mathbf{h}}$  : inconnue !

?

*Stein Unbiased Risk Estimate  
(SURE)*

# Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \boldsymbol{\zeta} \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

# Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \boldsymbol{\zeta} \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

Ex.  $\hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$

# Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \boldsymbol{\zeta} \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

**Ex.**  $\hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_{\boldsymbol{\zeta}} \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 \stackrel{?}{=} \mathbb{E}_{\boldsymbol{\zeta}} \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

# Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \boldsymbol{\zeta} \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_{\boldsymbol{\zeta}} \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 \stackrel{?}{=} \mathbb{E}_{\boldsymbol{\zeta}} \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

## Théorème (Stein, 1981)

Soit  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$  un estimateur de  $\bar{\mathbf{x}}$

- différentiable au sens faible par rapport à  $\mathbf{y}$ ,
- tel que  $\boldsymbol{\zeta} \mapsto \langle \hat{\mathbf{x}}(\bar{\mathbf{x}} + \boldsymbol{\zeta}; \lambda), \boldsymbol{\zeta} \rangle$  est intégrable par rapport à  $\mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$ .

$$\begin{aligned} \widehat{R}(\mathbf{y}; \lambda) &\triangleq \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\rho^2 \operatorname{tr}(\partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \lambda)) - \rho^2 P \\ &\implies R(\lambda) = \mathbb{E}_{\boldsymbol{\zeta}} [\widehat{R}(\mathbf{y}; \lambda)]. \end{aligned}$$

# Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

## Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

Ex. des estimateurs  $\hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a$$

# Stein Unbiased Risk Estimate généralisé

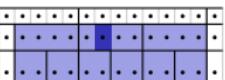
**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

Ex. des estimateurs  $\hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta$$

$$\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a$$



# Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

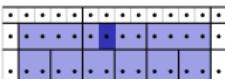
Ex. des estimateurs  $\hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta$$

$$\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$$

$$\mathcal{R} = \|\hat{\mathbf{h}} - \bar{\mathbf{h}}\|^2$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a$$



$$\Pi : (\mathbf{h}, \mathbf{v}) \mapsto (\mathbf{h}, \mathbf{0})$$

# Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

Ex. des estimateurs  $\hat{h}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta \quad \zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S}) \quad \mathcal{R} = \|\hat{\mathbf{h}} - \bar{\mathbf{h}}\|^2$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a \quad \begin{array}{|c|c|c|c|c|c|c|c|c|c|} \hline & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \end{array} \quad \Pi : (\mathbf{h}, \mathbf{v}) \mapsto (\mathbf{h}, \mathbf{0})$$

Erreur d'estimation projetée  $R_\Pi(\Lambda) \triangleq \mathbb{E}_\zeta \|\Pi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \Pi \bar{\mathbf{x}}\|^2$

## Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

Ex. des estimateurs  $\hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta \quad \zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S}) \quad \mathcal{R} = \|\hat{\mathbf{h}} - \bar{\mathbf{h}}\|^2$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a \quad \begin{array}{|c|c|c|c|c|c|c|c|c|c|c|c|} \hline & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \end{array} \quad \Pi : (\mathbf{h}, \mathbf{v}) \mapsto (\mathbf{h}, \mathbf{0})$$

**Erreur d'estimation projetée**  $R_\Pi(\Lambda) \triangleq \mathbb{E}_\zeta \|\Pi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \Pi \bar{\mathbf{x}}\|^2$

**Théorème** (Pascal, 2020)

Soit  $\mathbf{A} \triangleq \Pi(\Phi^\top \Phi)^{-1} \Phi^\top$  et  $(\mathbf{y}; \Lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \Lambda)$  un estimateur de  $\bar{\mathbf{x}}$

# Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

Ex. des estimateurs  $\hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta \quad \zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S}) \quad \mathcal{R} = \|\hat{\mathbf{h}} - \bar{\mathbf{h}}\|^2$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a \quad \begin{array}{|c|c|c|c|c|c|c|c|c|c|c|c|} \hline & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \end{array} \quad \Pi : (\mathbf{h}, \mathbf{v}) \mapsto (\mathbf{h}, \mathbf{0})$$

**Erreur d'estimation projetée**  $R_\Pi(\Lambda) \triangleq \mathbb{E}_\zeta \|\Pi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \Pi \bar{\mathbf{x}}\|^2$

**Théorème** (Pascal, 2020)

Soit  $\mathbf{A} \triangleq \Pi(\Phi^\top \Phi)^{-1} \Phi^\top$  et  $(\mathbf{y}; \Lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \Lambda)$  un estimateur de  $\bar{\mathbf{x}}$

- différentiable au sens faible par rapport à  $\mathbf{y}$ ,
- tel que  $\zeta \mapsto \langle \Pi \hat{\mathbf{x}}(\bar{\mathbf{x}} + \zeta; \lambda), \mathbf{A} \zeta \rangle$  est intégrable par rapport à  $\mathcal{N}(\mathbf{0}, \mathcal{S})$ .

# Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

Ex. des estimateurs  $\hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta \quad \zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S}) \quad \mathcal{R} = \|\hat{\mathbf{h}} - \bar{\mathbf{h}}\|^2$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a \quad \begin{array}{|c|c|c|c|c|c|c|c|c|c|c|c|} \hline & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \end{array} \quad \Pi : (\mathbf{h}, \mathbf{v}) \mapsto (\mathbf{h}, \mathbf{0})$$

**Erreur d'estimation projetée**  $R_\Pi(\Lambda) \triangleq \mathbb{E}_\zeta \|\Pi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \Pi \bar{\mathbf{x}}\|^2$

**Théorème** (Pascal, 2020)

Soit  $\mathbf{A} \triangleq \Pi(\Phi^\top \Phi)^{-1} \Phi^\top$  et  $(\mathbf{y}; \Lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \Lambda)$  un estimateur de  $\bar{\mathbf{x}}$

- différentiable au sens faible par rapport à  $\mathbf{y}$ ,
- tel que  $\zeta \mapsto \langle \Pi \hat{\mathbf{x}}(\bar{\mathbf{x}} + \zeta; \lambda), \mathbf{A} \zeta \rangle$  est intégrable par rapport à  $\mathcal{N}(\mathbf{0}, \mathcal{S})$ .

$$\widehat{R}(\Lambda) \triangleq \|\mathbf{A}(\Phi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \mathbf{y})\|^2 + 2\text{tr}(\mathcal{S} \mathbf{A}^\top \Pi \partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \Lambda)) - \text{tr}(\mathbf{A} \mathcal{S} \mathbf{A}^\top)$$

# Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

Ex. des estimateurs  $\hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta \quad \zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S}) \quad \mathcal{R} = \|\hat{\mathbf{h}} - \bar{\mathbf{h}}\|^2$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a \quad \begin{array}{|c|c|c|c|c|c|c|c|c|c|c|c|} \hline & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \end{array} \quad \Pi : (\mathbf{h}, \mathbf{v}) \mapsto (\mathbf{h}, \mathbf{0})$$

**Erreur d'estimation projetée**  $R_\Pi(\Lambda) \triangleq \mathbb{E}_\zeta \|\Pi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \Pi \bar{\mathbf{x}}\|^2$

**Théorème** (Pascal, 2020)

Soit  $\mathbf{A} \triangleq \Pi(\Phi^\top \Phi)^{-1} \Phi^\top$  et  $(\mathbf{y}; \Lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \Lambda)$  un estimateur de  $\bar{\mathbf{x}}$

- différentiable au sens faible par rapport à  $\mathbf{y}$ ,
- tel que  $\zeta \mapsto \langle \Pi \hat{\mathbf{x}}(\bar{\mathbf{x}} + \zeta; \lambda), \mathbf{A} \zeta \rangle$  est intégrable par rapport à  $\mathcal{N}(\mathbf{0}, \mathcal{S})$ .

$$\begin{aligned} \widehat{R}(\Lambda) &\triangleq \|\mathbf{A}(\Phi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \mathbf{y})\|^2 + 2\text{tr}(\mathcal{S} \mathbf{A}^\top \Pi \partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \Lambda)) - \text{tr}(\mathbf{A} \mathcal{S} \mathbf{A}^\top) \\ &\implies R_\Pi(\Lambda) = \mathbb{E}_\zeta[\widehat{R}(\Lambda)]. \end{aligned}$$

# Stein Unbiased Risk Estimate généralisé

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

Ex. des estimateurs  $\hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha)$  à contours libres ou co-localisés

$$\log \mathcal{L} = \Phi(\bar{\mathbf{h}}, \bar{\mathbf{v}}) + \zeta \quad \zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S}) \quad \mathcal{R} = \|\hat{\mathbf{h}} - \bar{\mathbf{h}}\|^2$$

$$\Phi : (\mathbf{h}, \mathbf{v}) \mapsto \{\log(a)\mathbf{h} + \mathbf{v}\}_a \quad \begin{array}{|c|c|c|c|c|c|c|c|c|c|c|} \hline & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \cdot & \cdot \\ \hline \end{array} \quad \Pi : (\mathbf{h}, \mathbf{v}) \mapsto (\mathbf{h}, \mathbf{0})$$

**Erreur d'estimation projetée**  $R_\Pi(\Lambda) \triangleq \mathbb{E}_\zeta \|\Pi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \Pi \bar{\mathbf{x}}\|^2$

**Théorème** (*Pascal, 2020*)

Soit  $\mathbf{A} \triangleq \Pi(\Phi^\top \Phi)^{-1} \Phi^\top$  et  $(\mathbf{y}; \Lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \Lambda)$  un estimateur de  $\bar{\mathbf{x}}$

- différentiable au sens faible par rapport à  $\mathbf{y}$ ,
- tel que  $\zeta \mapsto \langle \Pi \hat{\mathbf{x}}(\bar{\mathbf{x}} + \zeta; \lambda), \mathbf{A} \zeta \rangle$  est intégrable par rapport à  $\mathcal{N}(\mathbf{0}, \mathcal{S})$ .

$$\begin{aligned} \widehat{R}(\Lambda) &\triangleq \|\mathbf{A}(\Phi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \mathbf{y})\|^2 + 2\text{tr}(\mathcal{S} \mathbf{A}^\top \Pi \partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \Lambda)) - \text{tr}(\mathbf{A} \mathcal{S} \mathbf{A}^\top) \\ &\implies R_\Pi(\Lambda) = \mathbb{E}_\zeta[\widehat{R}(\Lambda)]. \end{aligned}$$

# Calcul des degrés de liberté

Degrés de liberté

$$\text{dof} \triangleq \text{tr} \left( \mathbf{S} \mathbf{A}^\top \mathbf{\Pi} \partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) \right)$$

# Calcul des degrés de liberté

Degrés de liberté

$$\text{dof} \triangleq \text{tr} \left( \mathbf{S} \mathbf{A}^\top \mathbf{\Pi} \partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) \right)$$

- Stratégie de Monte Carlo (MC)       $\mathbf{M} \in \mathbb{R}^{P \times P}$  de grande taille  
 $\text{tr}(\mathbf{M}) = \mathbb{E}_{\boldsymbol{\varepsilon}} \langle \mathbf{M} \boldsymbol{\varepsilon}, \boldsymbol{\varepsilon} \rangle, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_P)$

# Calcul des degrés de liberté

**Degrés de liberté**  $\text{dof} \triangleq \text{tr} \left( \mathbf{S} \mathbf{A}^\top \mathbf{\Pi} \partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) \right)$

- **Stratégie de Monte Carlo** (MC)  $\mathbf{M} \in \mathbb{R}^{P \times P}$  de grande taille  
 $\text{tr}(\mathbf{M}) = \mathbb{E}_{\boldsymbol{\varepsilon}} \langle \mathbf{M} \boldsymbol{\varepsilon}, \boldsymbol{\varepsilon} \rangle, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_P)$

- **Différences Finies** (DF) Jacobienne inaccessible

$$\partial_{\mathbf{y}} \hat{\mathbf{x}} [\boldsymbol{\varepsilon}] \underset{\nu \rightarrow 0}{\simeq} \frac{1}{\nu} (\hat{\mathbf{x}}(\mathbf{y} + \nu \boldsymbol{\varepsilon}; \boldsymbol{\Lambda}) - \hat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}))$$

# Calcul des degrés de liberté

**Degrés de liberté**  $\text{dof} \triangleq \text{tr} \left( \mathcal{S} \mathbf{A}^\top \mathbf{\Pi} \partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) \right)$

- **Stratégie de Monte Carlo** (MC)  $\mathbf{M} \in \mathbb{R}^{P \times P}$  de grande taille  
 $\text{tr}(\mathbf{M}) = \mathbb{E}_\varepsilon \langle \mathbf{M} \varepsilon, \varepsilon \rangle, \quad \varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_P)$

- **Différences Finies** (DF) Jacobienne inaccessible

$$\partial_{\mathbf{y}} \hat{\mathbf{x}} [\varepsilon] \underset{\nu \rightarrow 0}{\simeq} \frac{1}{\nu} (\hat{\mathbf{x}}(\mathbf{y} + \nu \varepsilon; \boldsymbol{\Lambda}) - \hat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}))$$

## Proposition (Pascal, 2020)

Soit  $(\mathbf{y}; \boldsymbol{\Lambda}) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda})$  un estimateur de  $\bar{\mathbf{x}}$

- uniformément lipschitzien par rapport à  $\mathbf{y}$ ,
- tel que  $\forall \boldsymbol{\Lambda} \in \mathbb{R}^L, \hat{\mathbf{x}}(\mathbf{0}_P; \boldsymbol{\Lambda}) = \mathbf{0}_N$ . Alors

$$\mathbb{E}_\zeta [\text{dof}] = \lim_{\nu \rightarrow 0} \mathbb{E}_{\zeta, \varepsilon} \left[ \frac{1}{\nu} \left\langle \mathcal{S} \mathbf{A}^\top \mathbf{\Pi} (\hat{\mathbf{x}}(\mathbf{y} + \nu \varepsilon; \boldsymbol{\Lambda}) - \hat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda})), \varepsilon \right\rangle \right]$$

# Stein Unbiased Risk Estimate (Calcul)

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$

**Erreur d'estimation projetée**  $R_{\Pi}(\Lambda) \triangleq \mathbb{E}_{\zeta} \|\Pi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \Pi \bar{\mathbf{x}}\|^2$

## SURE généralisé Différences Finies Monte Carlo

$$\begin{aligned} \widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) &\triangleq \|\mathbf{A}(\Phi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \mathbf{y})\|^2 + \\ &\frac{2}{\nu} \left\langle \mathcal{S} \mathbf{A}^\top \Pi (\hat{\mathbf{x}}(\mathbf{y} + \nu \epsilon; \Lambda) - \hat{\mathbf{x}}(\mathbf{y}; \Lambda)), \epsilon \right\rangle - \text{tr}(\mathbf{A} \mathcal{S} \mathbf{A}^\top) \end{aligned}$$

## Stein Unbiased Risk Estimate (Calcul)

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$

**Erreur d'estimation projetée**  $R_{\Pi}(\Lambda) \triangleq \mathbb{E}_{\zeta} \|\Pi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \Pi \bar{\mathbf{x}}\|^2$

### SURE généralisé Différences Finies Monte Carlo

$$\begin{aligned} \widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) &\triangleq \|\mathbf{A}(\Phi \hat{\mathbf{x}}(\mathbf{y}; \Lambda) - \mathbf{y})\|^2 + \\ &\frac{2}{\nu} \left\langle \mathcal{S} \mathbf{A}^\top \Pi(\hat{\mathbf{x}}(\mathbf{y} + \nu \epsilon; \Lambda) - \hat{\mathbf{x}}(\mathbf{y}; \Lambda)), \epsilon \right\rangle - \text{tr}(\mathbf{A} \mathcal{S} \mathbf{A}^\top) \end{aligned}$$

### Théorème (Pascal, 2020)

Soit  $(\mathbf{y}; \Lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \Lambda)$  un estimateur de  $\bar{\mathbf{x}}$

- uniformément lipschitzien par rapport à  $\mathbf{y}$ ,
- tel que  $\forall \Lambda \in \mathbb{R}^L$ ,  $\hat{\mathbf{x}}(\mathbf{0}_P; \Lambda) = \mathbf{0}_N$ . Alors

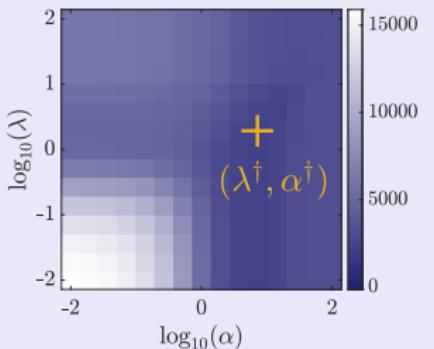
$$R_{\Pi}(\Lambda) = \lim_{\nu \rightarrow 0} \mathbb{E}_{\zeta, \epsilon} \left[ \widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) \right]$$

# Réglage des paramètres (Recherche systématique)

$$\left( \hat{\mathbf{h}}, \hat{\mathbf{v}} \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

$\bar{\mathbf{h}}$  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



$\bar{\mathbf{h}}$  : inconnue !

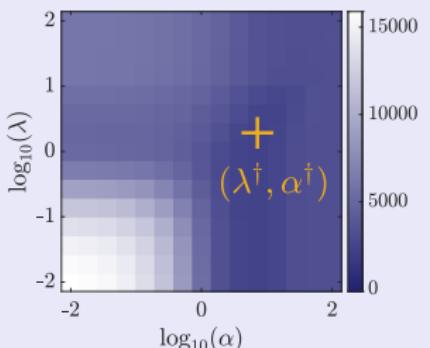
$$\widehat{R}_{\nu, \epsilon}(\mathcal{L}; \lambda, \alpha | \mathcal{S})$$

# Réglage des paramètres (Recherche systématique)

$$\left( \hat{\mathbf{h}}, \hat{\mathbf{v}} \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

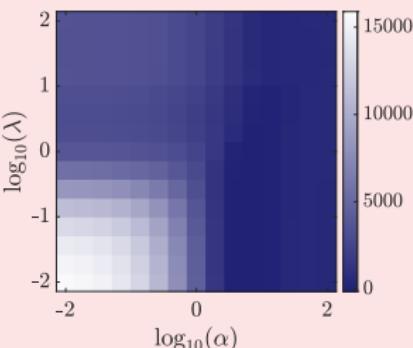
$\bar{\mathbf{h}}$  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



$\bar{\mathbf{h}}$  : inconnue !

$$\widehat{R}_{\nu, \epsilon}(\mathcal{L}; \lambda, \alpha | \mathcal{S})$$

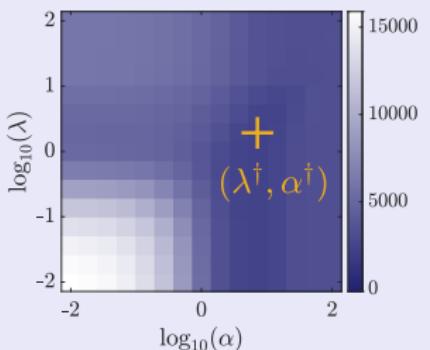


# Réglage des paramètres (Recherche systématique)

$$\left( \widehat{\mathbf{h}}, \widehat{\mathbf{v}} \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

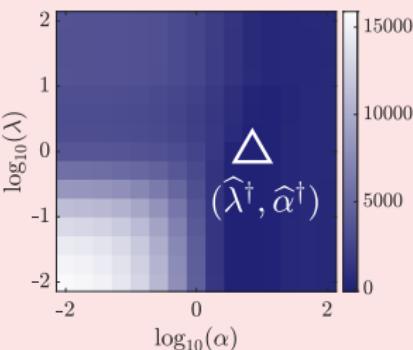
$\bar{\mathbf{h}}$  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \widehat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



$\bar{\mathbf{h}}$  : inconnue !

$$\widehat{\mathcal{R}}_{\nu, \epsilon}(\mathcal{L}; \lambda, \alpha | \mathcal{S})$$

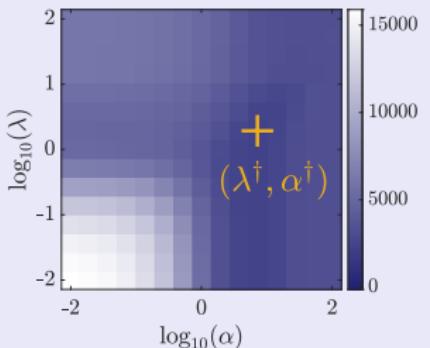


# Réglage des paramètres (Recherche systématique)

$$\left( \widehat{\mathbf{h}}^*, \widehat{\mathbf{v}}^* \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

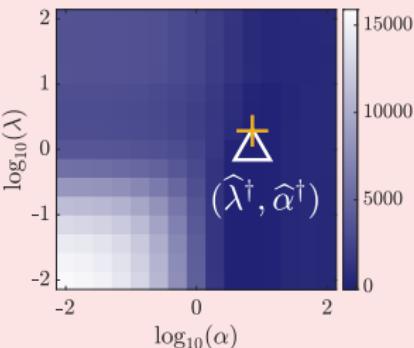
$\bar{\mathbf{h}}$  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \widehat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



$\bar{\mathbf{h}}$  : inconnue !

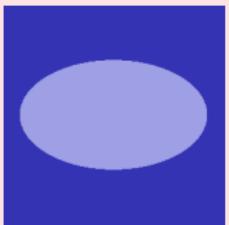
$$\widehat{\mathcal{R}}_{\nu, \epsilon}(\mathcal{L}; \lambda, \alpha | \mathcal{S})$$



# Recherche systématique des paramètres de régularisation

$$\left( \hat{\mathbf{h}}^L, \hat{\mathbf{v}}^L \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

## Exemple



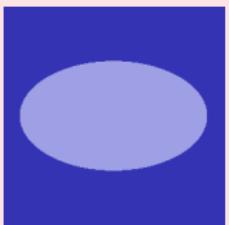
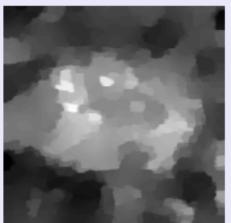
# Recherche systématique des paramètres de régularisation

$$\left( \hat{\mathbf{h}}^L, \hat{\mathbf{v}}^L \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

## Exemple



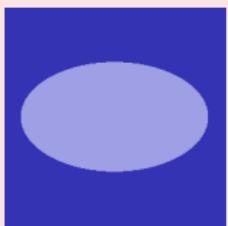
$\hat{\mathbf{h}}^L(\mathcal{L}; \lambda^\dagger, \alpha^\dagger)$   
(grille)



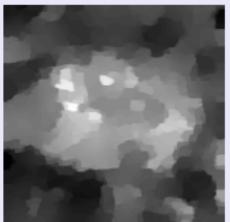
# Recherche systématique des paramètres de régularisation

$$\left( \hat{\mathbf{h}}^L, \hat{\mathbf{v}}^L \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

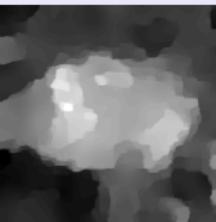
Exemple



$\hat{\mathbf{h}}^L(\mathcal{L}; \lambda^\dagger, \alpha^\dagger)$   
(grille)



$\hat{\mathbf{h}}^L(\mathcal{L}; \hat{\lambda}^\dagger, \hat{\alpha}^\dagger)$   
(grille)



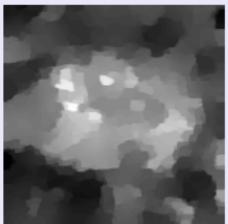
# Recherche systématique des paramètres de régularisation

$$\left(\hat{\mathbf{h}}^L, \hat{\mathbf{v}}^L\right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

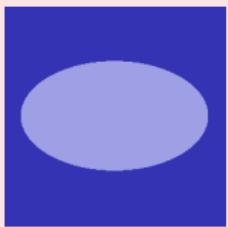
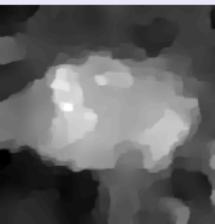
Exemple



$\hat{\mathbf{h}}^L(\mathcal{L}; \lambda^\dagger, \alpha^\dagger)$   
(grille)



$\hat{\mathbf{h}}^L(\mathcal{L}; \hat{\lambda}^\dagger, \hat{\alpha}^\dagger)$   
(grille)



$15 \times 15 = 225$  paramètres  $\rightarrow$  recherche sur grille très coûteuse

# Minimisation automatique de l'estimateur SURE

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

**SURE généralisé DFMC**  $\lim_{\nu \rightarrow 0} \mathbb{E}_{\zeta, \epsilon} \widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) = R_{\Pi}(\Lambda)$

# Minimisation automatique de l'estimateur SURE

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

**SURE généralisé DFMC**  $\lim_{\nu \rightarrow 0} \mathbb{E}_{\zeta, \epsilon} \widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) = R_{\Pi}(\Lambda)$

**But** : minimiser  $\widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S})$  pour  $\mathbf{y}, \mathcal{S}$  donnés

# Minimisation automatique de l'estimateur SURE

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

**SURE généralisé DFMC**  $\lim_{\nu \rightarrow 0} \mathbb{E}_{\zeta, \epsilon} \widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) = R_{\Pi}(\Lambda)$

**But** : minimiser  $\underset{\Lambda}{\widehat{R}_{\nu, \epsilon}}(\mathbf{y}; \Lambda | \mathcal{S}) \equiv \widehat{R}(\Lambda)$  pour  $\mathbf{y}$ ,  $\mathcal{S}$  donnés

# Minimisation automatique de l'estimateur SURE

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

**SURE généralisé DFMC**  $\lim_{\nu \rightarrow 0} \mathbb{E}_{\zeta, \epsilon} \widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) = R_{\Pi}(\Lambda)$

**But** : minimiser  $\widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) \equiv \widehat{R}(\Lambda)$  pour  $\mathbf{y}$ ,  $\mathcal{S}$  donnés

Quasi-Newton de Broyden-Fletcher-Goldfarb-Shanno (*Nocedal, 2006*)

**for**  $t = 0, 1, \dots$

$$\mathbf{d}^{[t]} = -\mathbf{H}^{[t]} \partial_{\Lambda} \widehat{R}(\Lambda^{[t]}) \quad \text{direction de descente}$$

$$\alpha^{[t]} \in \underset{\alpha \in \mathbb{R}}{\operatorname{Argmin}} \widehat{R}(\Lambda^{[t]} + \alpha \mathbf{d}^{[t]}) \quad \text{recherche sur une ligne}$$

$$\Lambda^{[t+1]} = \Lambda^{[t]} + \alpha^{[t]} \mathbf{d}^{[t]}$$

$$\mathbf{u}^{[t]} = \partial_{\Lambda} \widehat{R}(\Lambda^{[t+1]}) - \partial_{\Lambda} \widehat{R}(\Lambda^{[t]}) \quad \text{variation du gradient}$$

$$\mathbf{H}^{[t+1]} = \text{BFGS}(\mathbf{H}^{[t]}, \mathbf{d}^{[t]}, \mathbf{u}^{[t]}) \quad \text{mise à jour "hessienne inverse"}$$

# Minimisation automatique de l'estimateur SURE

**Observations**  $\mathbf{y} = \Phi \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}} \in \mathbb{R}^N$ ,  $\Phi : \mathbb{R}^{P \times N}$  et  $\zeta \sim \mathcal{N}(\mathbf{0}, \mathcal{S})$

**SURE généralisé DFMC**  $\lim_{\nu \rightarrow 0} \mathbb{E}_{\zeta, \epsilon} \widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) = R_{\Pi}(\Lambda)$

**But** : minimiser  $\widehat{R}_{\nu, \epsilon}(\mathbf{y}; \Lambda | \mathcal{S}) \equiv \widehat{R}(\Lambda)$  pour  $\mathbf{y}$ ,  $\mathcal{S}$  donnés

Quasi-Newton de Broyden-Fletcher-Goldfarb-Shanno (*Nocedal, 2006*)

**for**  $t = 0, 1, \dots$

$$\mathbf{d}^{[t]} = -\mathbf{H}^{[t]} \partial_{\Lambda} \widehat{R}(\Lambda^{[t]}) \quad \text{direction de descente}$$

$$\alpha^{[t]} \in \underset{\alpha \in \mathbb{R}}{\operatorname{Argmin}} \widehat{R}(\Lambda^{[t]} + \alpha \mathbf{d}^{[t]}) \quad \text{recherche sur une ligne}$$

$$\Lambda^{[t+1]} = \Lambda^{[t]} + \alpha^{[t]} \mathbf{d}^{[t]}$$

$$\mathbf{u}^{[t]} = \partial_{\Lambda} \widehat{R}(\Lambda^{[t+1]}) - \partial_{\Lambda} \widehat{R}(\Lambda^{[t]}) \quad \text{variation du gradient}$$

$$\mathbf{H}^{[t+1]} = \text{BFGS}(\mathbf{H}^{[t]}, \mathbf{d}^{[t]}, \mathbf{u}^{[t]}) \quad \text{mise à jour "hessienne inverse"}$$

## Stein Unbiased GrAdient Risk estimate

### SURE généralisé DFMC

$$\begin{aligned}\widehat{R}_{\nu,\varepsilon}(\mathbf{y}; \boldsymbol{\Lambda} | \mathcal{S}) &= \|\mathbf{A}(\Phi \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) - \mathbf{y})\|^2 + \\ \frac{2}{\nu} \left\langle \mathcal{S} \mathbf{A}^\top \Pi(\widehat{\mathbf{x}}(\mathbf{y} + \nu\varepsilon; \boldsymbol{\Lambda}) - \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda})), \varepsilon \right\rangle - \text{tr}(\mathbf{A} \mathcal{S} \mathbf{A}^\top)\end{aligned}$$

# Stein Unbiased GrAdient Risk estimate

## SURE généralisé DFMC

$$\begin{aligned}\widehat{R}_{\nu,\varepsilon}(\mathbf{y}; \boldsymbol{\Lambda} | \mathcal{S}) &= \|\mathbf{A}(\Phi \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) - \mathbf{y})\|^2 + \\ \frac{2}{\nu} \left\langle \mathcal{S} \mathbf{A}^\top \boldsymbol{\Pi} (\widehat{\mathbf{x}}(\mathbf{y} + \nu\varepsilon; \boldsymbol{\Lambda}) - \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda})) , \varepsilon \right\rangle &- \text{tr}(\mathbf{A} \mathcal{S} \mathbf{A}^\top)\end{aligned}$$

## SUGAR généralisé Différences Finies Monte Carlo

$$\begin{aligned}\partial_{\boldsymbol{\Lambda}} \widehat{R}_{\nu,\varepsilon}(\mathbf{y}; \boldsymbol{\Lambda} | \mathcal{S}) &= 2(\mathbf{A} \Phi \partial_{\boldsymbol{\Lambda}} \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}))^\top \mathbf{A}(\Phi \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) - \mathbf{y}) \\ &+ \frac{2}{\nu} \left\langle \mathcal{S} \mathbf{A}^\top \boldsymbol{\Pi} (\partial_{\boldsymbol{\Lambda}} \widehat{\mathbf{x}}(\mathbf{y} + \nu\varepsilon; \boldsymbol{\Lambda}) - \partial_{\boldsymbol{\Lambda}} \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda})) , \varepsilon \right\rangle\end{aligned}$$

## Stein Unbiased GrAdient Risk estimate

### SURE généralisé DFMC

$$\widehat{R}_{\nu,\varepsilon}(\mathbf{y}; \boldsymbol{\Lambda} | \mathcal{S}) = \|\mathbf{A}(\Phi \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) - \mathbf{y})\|^2 + \frac{2}{\nu} \left\langle \mathcal{S} \mathbf{A}^\top \boldsymbol{\Pi} (\widehat{\mathbf{x}}(\mathbf{y} + \nu \varepsilon; \boldsymbol{\Lambda}) - \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda})), \varepsilon \right\rangle - \text{tr}(\mathbf{A} \mathcal{S} \mathbf{A}^\top)$$

### SUGAR généralisé Différences Finies Monte Carlo

$$\begin{aligned} \partial_{\boldsymbol{\Lambda}} \widehat{R}_{\nu,\varepsilon}(\mathbf{y}; \boldsymbol{\Lambda} | \mathcal{S}) &= 2(\mathbf{A} \Phi \partial_{\boldsymbol{\Lambda}} \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}))^\top \mathbf{A}(\Phi \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda}) - \mathbf{y}) \\ &\quad + \frac{2}{\nu} \left\langle \mathcal{S} \mathbf{A}^\top \boldsymbol{\Pi} (\partial_{\boldsymbol{\Lambda}} \widehat{\mathbf{x}}(\mathbf{y} + \nu \varepsilon; \boldsymbol{\Lambda}) - \partial_{\boldsymbol{\Lambda}} \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda})), \varepsilon \right\rangle \end{aligned}$$

### Théorème (Pascal, 2020)

Soit  $(\mathbf{y}; \boldsymbol{\Lambda}) \mapsto \widehat{\mathbf{x}}(\mathbf{y}; \boldsymbol{\Lambda})$  un estimateur de  $\bar{\mathbf{x}}$

- uniformément lipschitzien par rapport à  $\mathbf{y}$
- tel que  $\forall \boldsymbol{\Lambda} \in \mathbb{R}^L$ ,  $\widehat{\mathbf{x}}(\mathbf{0}_P; \boldsymbol{\Lambda}) = \mathbf{0}_N$ ,
- uniformément  $L$ -lipschitzien par rapport à  $\boldsymbol{\Lambda}$ ,  $L$  indép. de  $\mathbf{y}$ . Alors

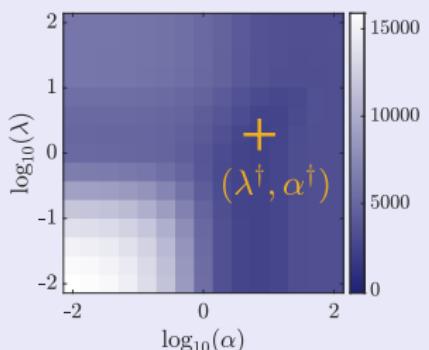
$$\partial_{\boldsymbol{\Lambda}} R_{\boldsymbol{\Pi}}(\boldsymbol{\Lambda}) = \lim_{\nu \rightarrow 0} \mathbb{E}_{\zeta, \varepsilon} \left[ \partial_{\boldsymbol{\Lambda}} \widehat{R}_{\nu, \varepsilon}(\mathbf{y}; \boldsymbol{\Lambda} | \mathcal{S}) \right]$$

# Réglage des paramètres (Recherche automatique)

$$\left( \hat{\mathbf{h}}, \hat{\mathbf{v}} \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

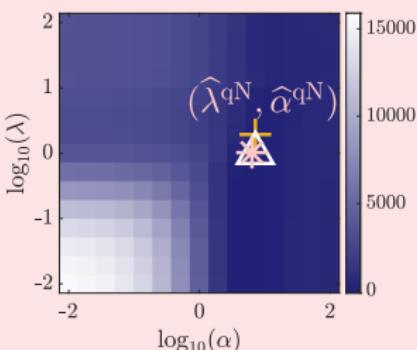
$\bar{\mathbf{h}}$  : vraie régularité

$$\mathcal{R}(\lambda, \alpha) = \left\| \hat{\mathbf{h}}(\mathcal{L}; \lambda, \alpha) - \bar{\mathbf{h}} \right\|^2$$



$\bar{\mathbf{h}}$  : inconnue !

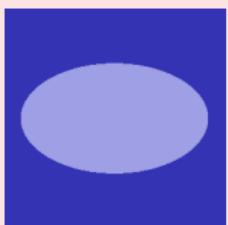
$$\widehat{R}_{\nu, \epsilon}(\mathcal{L}; \lambda, \alpha | \mathcal{S})$$



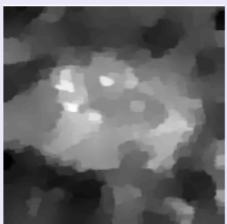
# Recherche automatique des paramètres de régularisation

$$\left( \hat{\mathbf{h}}^L, \hat{\mathbf{v}}^L \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

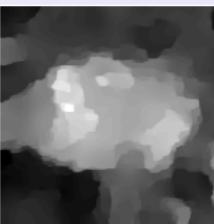
## Exemple



$\hat{\mathbf{h}}^L(\mathcal{L}; \lambda^\dagger, \alpha^\dagger)$   
(grille)



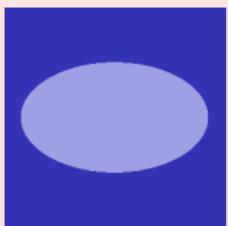
$\hat{\mathbf{h}}^L(\mathcal{L}; \hat{\lambda}^\dagger, \hat{\alpha}^\dagger)$   
(grille)



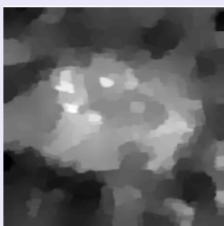
# Recherche automatique des paramètres de régularisation

$$\left( \hat{\mathbf{h}}^L, \hat{\mathbf{v}}^L \right) (\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a) \mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

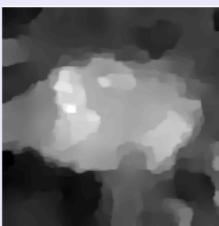
## Exemple



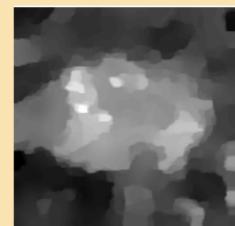
$\hat{\mathbf{h}}^L(\mathcal{L}; \lambda^\dagger, \alpha^\dagger)$   
(grille)



$\hat{\mathbf{h}}^L(\mathcal{L}; \hat{\lambda}^\dagger, \hat{\alpha}^\dagger)$   
(grille)



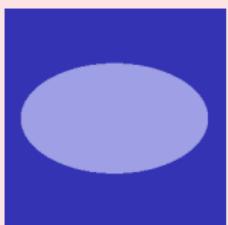
$\hat{\mathbf{h}}^L(\mathcal{L}; \hat{\lambda}^{qN}, \hat{\alpha}^{qN})$   
(quasi-Newton)



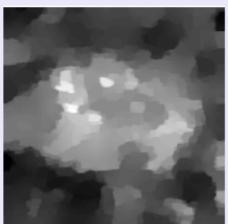
# Recherche automatique des paramètres de régularisation

$$\left(\hat{\mathbf{h}}^L, \hat{\mathbf{v}}^L\right)(\mathcal{L}; \lambda, \alpha) = \underset{\mathbf{h}, \mathbf{v}}{\operatorname{argmin}} \sum_a \|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2 + \lambda \mathcal{Q}_L(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)$$

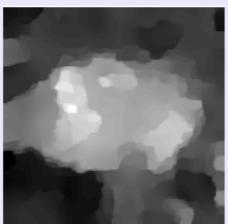
Exemple



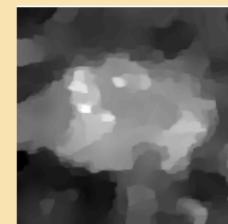
$\hat{\mathbf{h}}^L(\mathcal{L}; \lambda^\dagger, \alpha^\dagger)$   
(grille)



$\hat{\mathbf{h}}^L(\mathcal{L}; \hat{\lambda}^\dagger, \hat{\alpha}^\dagger)$   
(grille)



$\hat{\mathbf{h}}^L(\mathcal{L}; \hat{\lambda}^{qN}, \hat{\alpha}^{qN})$   
(quasi-Newton)



40 appels de l'estimateurs v.s. 225 sur une grille

39

Introduction  
○○○○

Caractérisation de texture  
○○○○○○

Construction de fonctionnelles  
○○

Algorithme de minimisation accéléré  
○○○○○○○○○○○○○○○○

Réglage des hyperparamètres  
○○○○○○○○○○○○○○○○

Conclusion  
●○○

## Bilan de la présentation

- Régularité et variance locale [ICIP, 2018]

## Bilan de la présentation

- Régularité et variance locale [ICIP, 2018]
  - ▶ aptes à caractériser des textures réelles

## Bilan de la présentation

- Régularité et variance locale [ICIP, 2018]
  - ▶ aptes à caractériser des textures réelles
  - ▶ attributs complémentaires → capacité à discriminer finement

## Bilan de la présentation

- Régularité et variance locale [ICIP, 2018]
  - ▶ aptes à caractériser des textures réelles
  - ▶ attributs complémentaires → capacité à discriminer finement
- Estimation et régularisation simultanées [ACHA, 2019]

# Bilan de la présentation

- Régularité et variance locale [ICIP, 2018]
  - ▶ aptes à caractériser des textures réelles
  - ▶ attributs complémentaires → capacité à discriminer finement
- Estimation et régularisation simultanées [ACHA, 2019]
  - ▶ forte diminution de l'erreur d'estimation

## Bilan de la présentation

- Régularité et variance locale [ICIP, 2018]
  - ▶ aptes à caractériser des textures réelles
  - ▶ attributs complémentaires → capacité à discriminer finement
- Estimation et régularisation simultanées [ACHA, 2019]
  - ▶ forte diminution de l'erreur d'estimation
  - ▶ contours précis et réguliers grâce à la pénalisation co-localisée

# Bilan de la présentation

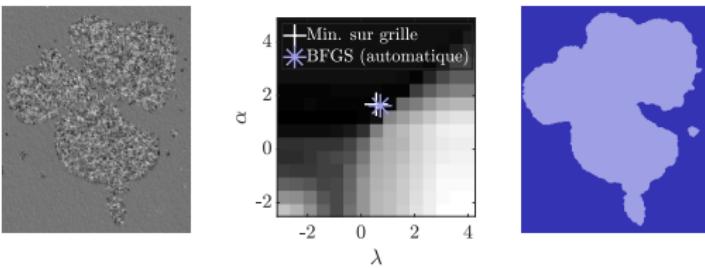
- Régularité et variance locale [ICIP, 2018]
  - ▶ aptes à caractériser des textures réelles
  - ▶ attributs complémentaires → capacité à discriminer finement
- Estimation et régularisation simultanées [ACHA, 2019]
  - ▶ forte diminution de l'erreur d'estimation
  - ▶ contours précis et réguliers grâce à la pénalisation co-localisée
- Algorithmes rapides et réglage automatique des paramètres [JMIV, 2020]

# Bilan de la présentation

- Régularité et variance locale [ICIP, 2018]
  - ▶ aptes à caractériser des textures réelles
  - ▶ attributs complémentaires → capacité à discriminer finement
- Estimation et régularisation simultanées [ACHA, 2019]
  - ▶ forte diminution de l'erreur d'estimation
  - ▶ contours précis et réguliers grâce à la pénalisation co-localisée
- Algorithmes rapides et réglage automatique des paramètres [JMIV, 2020]
  - ▶ possibilité de traiter de gros volumes de données

# Bilan de la présentation

- Régularité et variance locale [ICIP, 2018]
    - ▶ aptes à caractériser des textures réelles
    - ▶ attributs complémentaires → capacité à discriminer finement
  - Estimation et régularisation simultanées [ACHA, 2019]
    - ▶ forte diminution de l'erreur d'estimation
    - ▶ contours précis et réguliers grâce à la pénalisation co-localisée
  - Algorithmes rapides et réglage automatique des paramètres [JMIV, 2020]
    - ▶ possibilité de traiter de gros volumes de données
    - ▶ objectivité et reproductibilité
- En cours : traitement automatisé de séries temporelles issues de l'étude des écoulements multiphasiques [Ann. Telecom, 2020]



## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]

## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances

## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données

## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données
- Comparaison d'algorithmes proximaux [ACHA, 2019]

## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données
- Comparaison d'algorithmes proximaux [ACHA, 2019]
  - ▶ stratégie FISTA pour accélérer l'algorithme forward-backward

## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données
- Comparaison d'algorithmes proximaux [ACHA, 2019]
  - ▶ stratégie FISTA pour accélérer l'algorithme forward-backward
  - ▶ calcul du gap de dualité et choix d'un critère d'arrêt

## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données
- Comparaison d'algorithmes proximaux [ACHA, 2019]
  - ▶ stratégie FISTA pour accélérer l'algorithme forward-backward
  - ▶ calcul du gap de dualité et choix d'un critère d'arrêt
- Réseaux convolutionnels pour la segmentation de textures [EUSIPCO, 2020]

## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données
- Comparaison d'algorithmes proximaux [ACHA, 2019]
  - ▶ stratégie FISTA pour accélérer l'algorithme forward-backward
  - ▶ calcul du gap de dualité et choix d'un critère d'arrêt
- Réseaux convolutionnels pour la segmentation de textures [EUSIPCO, 2020]
  - ▶ performance et robustesse

## Autres contributions

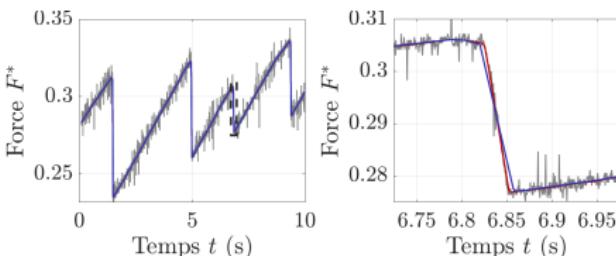
- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données
- Comparaison d'algorithmes proximaux [ACHA, 2019]
  - ▶ stratégie FISTA pour accélérer l'algorithme forward-backward
  - ▶ calcul du gap de dualité et choix d'un critère d'arrêt
- Réseaux convolutionnels pour la segmentation de textures [EUSIPCO, 2020]
  - ▶ performance et robustesse
  - ▶ comparaison coûts de calcul et mémoire

## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données
- Comparaison d'algorithmes proximaux [ACHA, 2019]
  - ▶ stratégie FISTA pour accélérer l'algorithme forward-backward
  - ▶ calcul du gap de dualité et choix d'un critère d'arrêt
- Réseaux convolutionnels pour la segmentation de textures [EUSIPCO, 2020]
  - ▶ performance et robustesse
  - ▶ comparaison coûts de calcul et mémoire
- Application à la physique du formalisme de Stein généralisé [Ann. Telecom, 2020]
  - ▶ segmentation de texture → écoulements multiphasiques

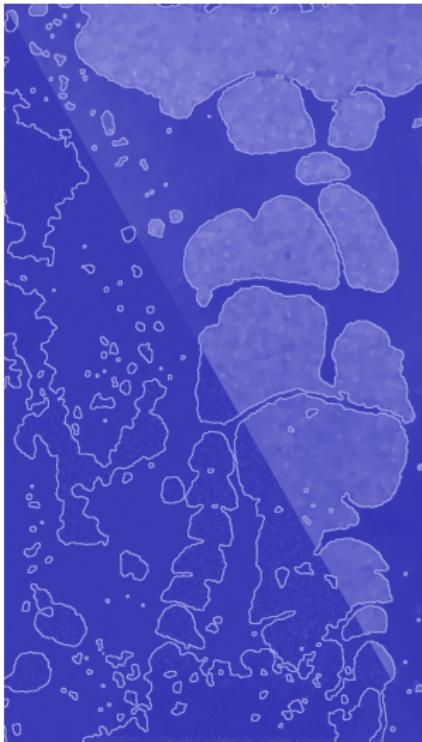
## Autres contributions

- Synthèse de textures monofractales par morceaux [ACHA, 2019]
  - ▶ segmentation et attributs prescrits → performances
  - ▶ possibilité de générer de grosses bases de données
- Comparaison d'algorithmes proximaux [ACHA, 2019]
  - ▶ stratégie FISTA pour accélérer l'algorithme forward-backward
  - ▶ calcul du gap de dualité et choix d'un critère d'arrêt
- Réseaux convolutionnels pour la segmentation de textures [EUSIPCO, 2020]
  - ▶ performance et robustesse
  - ▶ comparaison coûts de calcul et mémoire
- Application à la physique du formalisme de Stein généralisé [Ann. Telecom, 2020]
  - ▶ segmentation de texture → écoulements multiphasiques
  - ▶ débruitage linéaire par morceaux → frottement solide



Merci

Thank you



Grazie

Gracias

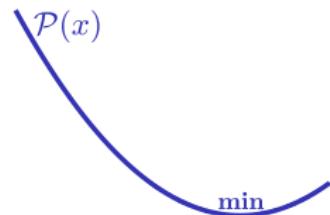
## Définition du gap de dualité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

non lisse



**Primal**     $\min_{\mathbf{x}} \text{MC}(\mathbf{x}) + \lambda \mathcal{Q}(\mathbf{D}\mathbf{x})$



# Définition du gap de dualité

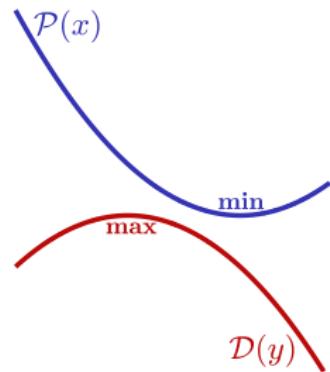
$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

non lisse



**Primal**  $\min_{\mathbf{x}} \text{MC}(\mathbf{x}) + \lambda \mathcal{Q}(\mathbf{D}\mathbf{x})$

**Dual**  $\max_{\mathbf{y}} -\text{MC}^*(-\mathbf{D}^\top \mathbf{y}) - (\lambda \mathcal{Q})^*(\mathbf{y})$



# Définition du gap de dualité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \frac{\lambda \mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

non lisse

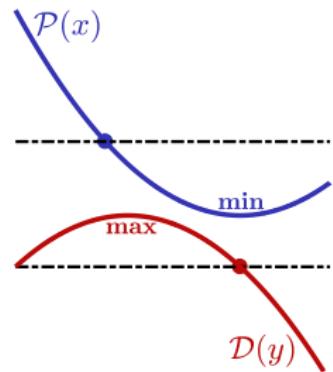


**Primal**  $\min_{\mathbf{x}} \text{MC}(\mathbf{x}) + \lambda \mathcal{Q}(\mathbf{D}\mathbf{x})$

**Dual**  $\max_{\mathbf{y}} -\text{MC}^*(-\mathbf{D}^\top \mathbf{y}) - (\lambda \mathcal{Q})^*(\mathbf{y})$

**Proposition (Bauschke, 2011)**

Soit  $\delta(\mathbf{x}; \mathbf{y}) \triangleq \mathcal{P}(\mathbf{x}) - \mathcal{D}(\mathbf{y})$  le gap de dualité,



## Définition du gap de dualité

$$\underset{\mathbf{h}, \mathbf{v}}{\text{minimiser}} \quad \sum_a \frac{\|\log \mathcal{L}_{a,.} - \log(a)\mathbf{h} - \mathbf{v}\|^2}{\text{Moindres Carrés}} + \lambda \frac{\mathcal{Q}(\mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}; \alpha)}{\text{Variation Totale}}$$

non lisse



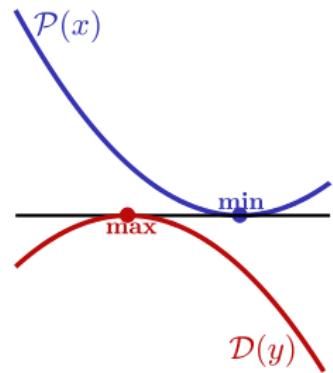
**Primal**  $\min_{\mathbf{x}} \text{MC}(\mathbf{x}) + \lambda \mathcal{Q}(\mathbf{D}\mathbf{x})$

**Dual**  $\max_{\mathbf{y}} -\text{MC}^*(-\mathbf{D}^\top \mathbf{y}) - (\lambda \mathcal{Q})^*(\mathbf{y})$

**Proposition (Bauschke, 2011)**

Soit  $\delta(\mathbf{x}; \mathbf{y}) \triangleq \mathcal{P}(\mathbf{x}) - \mathcal{D}(\mathbf{y})$  le gap de dualité,

$$\delta(\hat{\mathbf{x}}; \hat{\mathbf{y}}) = \mathcal{P}(\hat{\mathbf{x}}) - \mathcal{D}(\hat{\mathbf{y}}) = 0$$



## Conjuguée convexe des moindres carrés

$$\text{MC}^*(\mathbf{h}, \mathbf{v}) = \sup_{\tilde{\mathbf{h}}, \tilde{\mathbf{v}}} \langle \tilde{\mathbf{h}}, \mathbf{h} \rangle + \langle \tilde{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = \langle \bar{\mathbf{h}}, \mathbf{h} \rangle + \langle \bar{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\bar{\mathbf{h}}, \bar{\mathbf{v}}).$$

(si le sup est atteint)

## Conjuguée convexe des moindres carrés

$$\text{MC}^*(\mathbf{h}, \mathbf{v}) = \sup_{\tilde{\mathbf{h}}, \tilde{\mathbf{v}}} \langle \tilde{\mathbf{h}}, \mathbf{h} \rangle + \langle \tilde{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = \langle \bar{\mathbf{h}}, \mathbf{h} \rangle + \langle \bar{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\bar{\mathbf{h}}, \bar{\mathbf{v}}).$$

(si le sup est atteint)

### Condition d'optimalité

$$\begin{cases} \mathbf{h} - 2 \sum_a \log(a) (\bar{\mathbf{v}} + \log(a) \bar{\mathbf{h}} - \log \mathcal{L}_{a,.}) = 0 \\ \mathbf{v} - 2 \sum_a (\bar{\mathbf{v}} + \log(a) \bar{\mathbf{h}} - \log \mathcal{L}_{a,.}) = 0 \end{cases}$$

## Conjuguée convexe des moindres carrés

$$\text{MC}^*(\mathbf{h}, \mathbf{v}) = \sup_{\tilde{\mathbf{h}}, \tilde{\mathbf{v}}} \langle \tilde{\mathbf{h}}, \mathbf{h} \rangle + \langle \tilde{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = \langle \bar{\mathbf{h}}, \mathbf{h} \rangle + \langle \bar{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\bar{\mathbf{h}}, \bar{\mathbf{v}}).$$

(si le sup est atteint)

### Condition d'optimalité

$$\begin{cases} \mathbf{h} - 2 \sum_a \log(a) (\bar{\mathbf{v}} + \log(a) \bar{\mathbf{h}} - \log \mathcal{L}_{a,.}) = 0 \\ \mathbf{v} - 2 \sum_a (\bar{\mathbf{v}} + \log(a) \bar{\mathbf{h}} - \log \mathcal{L}_{a,.}) = 0 \end{cases} \iff \Phi^* \Phi \begin{pmatrix} \bar{\mathbf{h}} \\ \bar{\mathbf{v}} \end{pmatrix} = \begin{pmatrix} \mathbf{h}/2 + \mathcal{G} \\ \mathbf{v}/2 + \mathcal{T} \end{pmatrix}$$

$$\mathcal{T} = \sum_a \log \mathcal{L}_{a,.} \quad \text{et} \quad \mathcal{G} = \sum_a \log(a) \log \mathcal{L}_{a,.},$$

## Conjuguée convexe des moindres carrés

$$\text{MC}^*(\mathbf{h}, \mathbf{v}) = \sup_{\tilde{\mathbf{h}}, \tilde{\mathbf{v}}} \langle \tilde{\mathbf{h}}, \mathbf{h} \rangle + \langle \tilde{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = \langle \bar{\mathbf{h}}, \mathbf{h} \rangle + \langle \bar{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\bar{\mathbf{h}}, \bar{\mathbf{v}}). \\ (\text{si le sup est atteint})$$

### Condition d'optimalité

$$\begin{cases} \mathbf{h} - 2 \sum_a \log(a) (\bar{\mathbf{v}} + \log(a) \bar{\mathbf{h}} - \log \mathcal{L}_{a,.}) = 0 \\ \mathbf{v} - 2 \sum_a (\bar{\mathbf{v}} + \log(a) \bar{\mathbf{h}} - \log \mathcal{L}_{a,.}) = 0 \end{cases} \iff \Phi^* \Phi \begin{pmatrix} \bar{\mathbf{h}} \\ \bar{\mathbf{v}} \end{pmatrix} = \begin{pmatrix} \mathbf{h}/2 + \mathcal{G} \\ \mathbf{v}/2 + \mathcal{T} \end{pmatrix}$$

$$\mathcal{T} = \sum_a \log \mathcal{L}_{a,.} \quad \text{et} \quad \mathcal{G} = \sum_a \log(a) \log \mathcal{L}_{a,.},$$

$$\forall m = \{0, 1, 2\}, S_m = \sum_a (\log a)^m, \quad \Phi^* \Phi = \begin{pmatrix} S_2 \mathbf{I} & S_1 \mathbf{I} \\ S_1 \mathbf{I} & S_0 \mathbf{I} \end{pmatrix}$$

## Conjuguée convexe des moindres carrés

$$\text{MC}^*(\mathbf{h}, \mathbf{v}) = \sup_{\tilde{\mathbf{h}}, \tilde{\mathbf{v}}} \langle \tilde{\mathbf{h}}, \mathbf{h} \rangle + \langle \tilde{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\tilde{\mathbf{h}}, \tilde{\mathbf{v}}) = \langle \bar{\mathbf{h}}, \mathbf{h} \rangle + \langle \bar{\mathbf{v}}, \mathbf{v} \rangle - \text{MC}(\bar{\mathbf{h}}, \bar{\mathbf{v}}).$$

(si le sup est atteint)

### Condition d'optimalité

$$\begin{cases} \mathbf{h} - 2 \sum_a \log(a) (\bar{\mathbf{v}} + \log(a) \bar{\mathbf{h}} - \log \mathcal{L}_{a,.}) = 0 \\ \mathbf{v} - 2 \sum_a (\bar{\mathbf{v}} + \log(a) \bar{\mathbf{h}} - \log \mathcal{L}_{a,.}) = 0 \end{cases} \iff \Phi^* \Phi \begin{pmatrix} \bar{\mathbf{h}} \\ \bar{\mathbf{v}} \end{pmatrix} = \begin{pmatrix} \mathbf{h}/2 + \mathcal{G} \\ \mathbf{v}/2 + \mathcal{T} \end{pmatrix}$$

$$\mathcal{T} = \sum_a \log \mathcal{L}_{a,.} \quad \text{et} \quad \mathcal{G} = \sum_a \log(a) \log \mathcal{L}_{a,.},$$

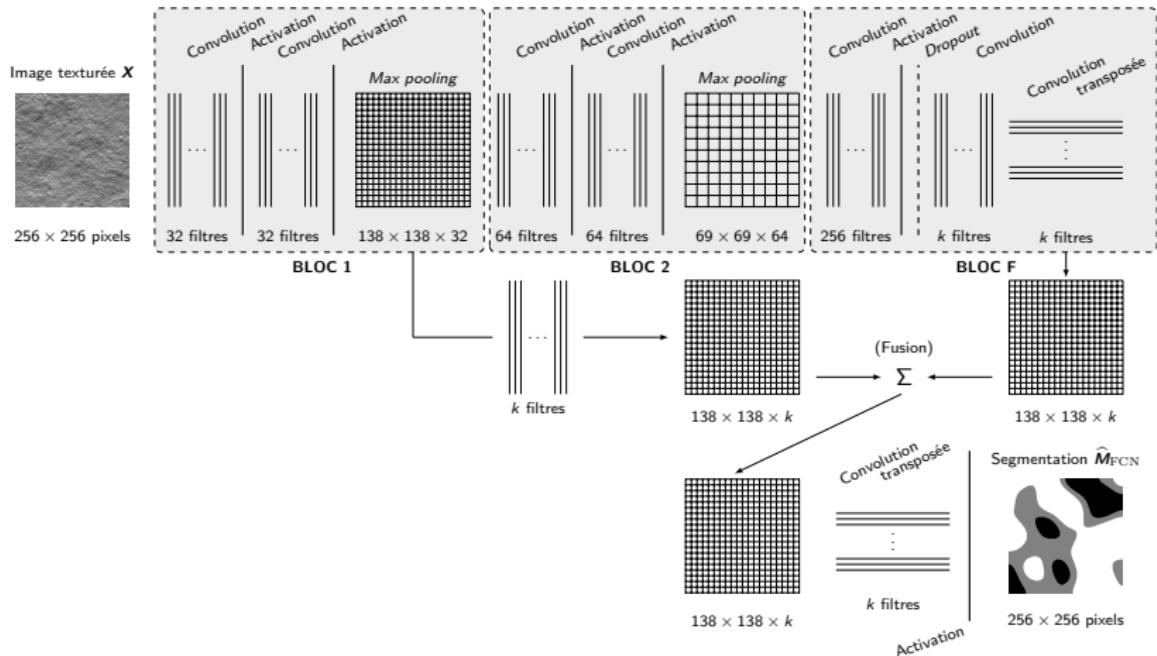
$$\forall m = \{0, 1, 2\}, S_m = \sum_a (\log a)^m, \quad \Phi^* \Phi = \begin{pmatrix} S_2 \mathbf{I} & S_1 \mathbf{I} \\ S_1 \mathbf{I} & S_0 \mathbf{I} \end{pmatrix}$$

$$\text{MC}^*(\mathbf{h}, \mathbf{v}) = \frac{1}{4} \langle (\mathbf{h}, \mathbf{v}), (\Phi^* \Phi)^{-1}(\mathbf{h}, \mathbf{v}) \rangle + \langle (\mathcal{G}, \mathcal{T}), (\Phi^* \Phi)^{-1}(\mathbf{h}, \mathbf{v}) \rangle + \mathcal{C}$$

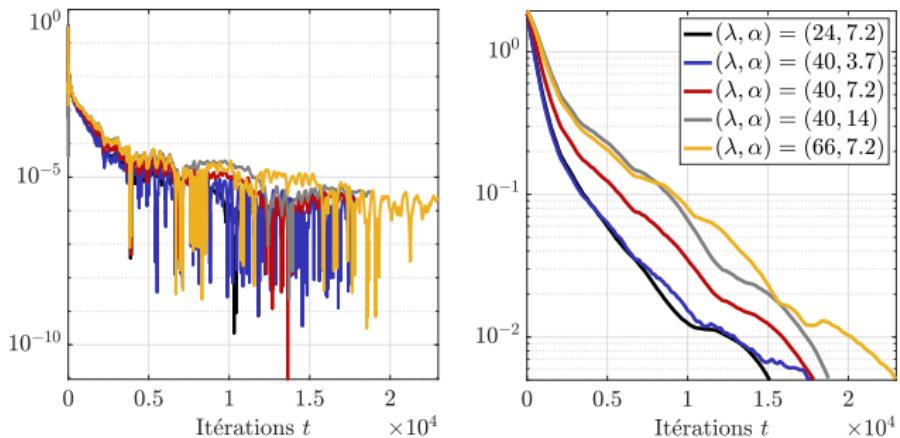
où  $\mathcal{C}$  est une constante dépendant uniquement de  $\mathcal{L}$ .

# Architecture pour la segmentation de texture

## Avec connexions résiduelles



## Critère d'arrêt



# Performances de segmentation

## Configuration I

	2 classes	3 classes	4 classes
<b>Entraîné sur la Config. I, testé sur la Config. I</b>			
Segmentation à contours « libres »	$93,2 \pm 0,8\%$	$69,3 \pm 2,8\%$	$58,6 \pm 1,5\%$
<b>Entraîné sur 2000 images</b>			
Réseau à $8 \cdot 10^7$ poids / $P = 2000$	$97,3 \pm 0,6\%$	$97,8 \pm 0,3\%$	$97,1 \pm 0,4\%$
Réseau à $2 \cdot 10^6$ poids / $P = 2000$	$97,4 \pm 0,6\%$	$98,1 \pm 0,3\%$	$96,8 \pm 0,5\%$
Réseau à $4 \cdot 10^5$ poids / $P = 2000$	$96,9 \pm 0,7\%$	$98,0 \pm 0,3\%$	$96,5 \pm 0,5\%$
<b>Entraîné sur 20 images</b>			
Réseau à $8 \cdot 10^7$ poids / $P = 20$	$95,5 \pm 0,9\%$	$97,5 \pm 0,4\%$	$95,4 \pm 0,8\%$
Réseau à $2 \cdot 10^6$ poids / $P = 20$	$95,4 \pm 1,1\%$	$97,4 \pm 0,5\%$	$95,9 \pm 0,7\%$
Réseau à $4 \cdot 10^5$ poids / $P = 20$	$96,6 \pm 0,7\%$	$98,0 \pm 0,4\%$	$96,5 \pm 0,5\%$

# Performances de segmentation

## Configuration II

	2 classes	3 classes	4 classes
<b>Entraîné sur la Config. II, testé sur la Config. II</b>			
Segmentation à contours « libres »	$97,8 \pm 0,2\%$	$95,2 \pm 3,1\%$	$64,9 \pm 1,4\%$
<b>Entraîné sur 2000 images</b>			
Réseau à $8 \cdot 10^7$ poids / $P = 2000$	$99,1 \pm 0,2\%$	$98,3 \pm 0,3\%$	$95,7 \pm 0,5\%$
Réseau à $2 \cdot 10^6$ poids / $P = 2000$	$99,0 \pm 0,2\%$	$98,5 \pm 0,3\%$	$95,6 \pm 0,5\%$
Réseau à $4 \cdot 10^5$ poids / $P = 2000$	$99,1 \pm 0,2\%$	$98,4 \pm 0,3\%$	$95,2 \pm 0,6\%$
<b>Entraîné sur 20 images</b>			
Réseau à $8 \cdot 10^7$ poids / $P = 20$	$98,8 \pm 0,2\%$	$97,9 \pm 0,3\%$	$94,5 \pm 0,7\%$
Réseau à $2 \cdot 10^6$ poids / $P = 20$	$98,6 \pm 0,3\%$	$97,4 \pm 0,4\%$	$93,0 \pm 0,9\%$
Réseau à $4 \cdot 10^5$ poids / $P = 20$	$98,8 \pm 0,3\%$	$98,3 \pm 0,3\%$	$94,8 \pm 0,6\%$

# Robustesse

Entraîné sur la Config. I, testé sur la Config. II

	2 classes	3 classes	4 classes
<b>Entraîné sur la Config. I, testé sur la Config. II</b>			
Segmentation à contours « libres »	$79,2 \pm 2,9\%$	$95,2 \pm 1,2\%$	$66,3 \pm 1,1\%$
<b>Entraîné sur 2000 images</b>			
Réseau à $8 \cdot 10^7$ poids / $P = 2000$	$91,2 \pm 2,1\%$	$65,7 \pm 7,2\%$	$55,6 \pm 3,4\%$
Réseau à $2 \cdot 10^6$ poids / $P = 2000$	$87,9 \pm 2,5\%$	$69,0 \pm 7,6\%$	$50,8 \pm 4,0\%$
Réseau à $4 \cdot 10^5$ poids / $P = 2000$	$81,8 \pm 3,8\%$	$65,2 \pm 7,2\%$	$46,4 \pm 3,7\%$
<b>Entraîné sur 20 images</b>			
Réseau à $8 \cdot 10^7$ poids / $P = 20$	$91,4 \pm 1,6\%$	$63,3 \pm 7,1\%$	$54,7 \pm 3,3\%$
Réseau à $2 \cdot 10^6$ poids / $P = 20$	$92,4 \pm 1,6\%$	$65,6 \pm 7,4\%$	$44,4 \pm 3,4\%$
Réseau à $4 \cdot 10^5$ poids / $P = 20$	$86,3 \pm 2,6\%$	$64,9 \pm 7,2\%$	$48,4 \pm 3,8\%$

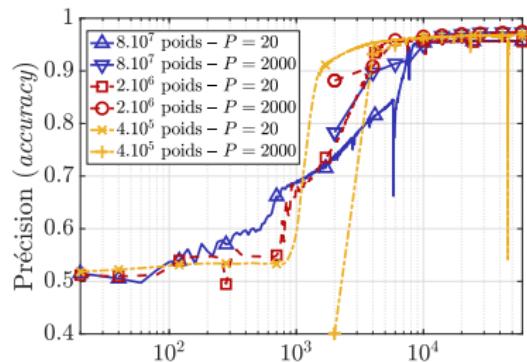
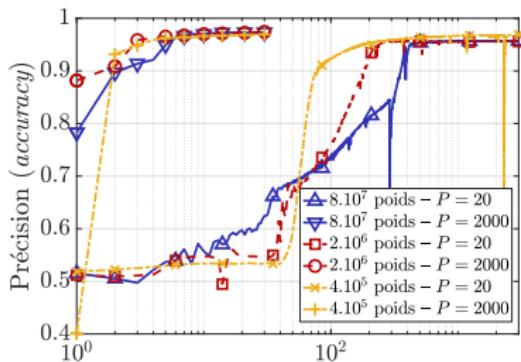
# Robustesse

## Entraîné sur la Config. II, testé sur la Config. I

	2 classes	3 classes	4 classes
<b>Entraîné sur la Config. II, testé sur la Config. I</b>			
Segmentation à contours « libres »	$90,9 \pm 2,8\%$	$66,7 \pm 2,5\%$	$52,0 \pm 1,5\%$
<b>Entraîné sur 2000 images</b>			
Réseau à $8 \cdot 10^7$ poids / $P = 2000$	$56,2 \pm 13,5\%$	$73,5 \pm 8,2\%$	$50,9 \pm 3,9\%$
Réseau à $2 \cdot 10^6$ poids / $P = 2000$	$55,1 \pm 14,0\%$	$74,9 \pm 8,2\%$	$51,3 \pm 4,3\%$
Réseau à $5 \cdot 10^5$ poids / $P = 2000$	$55,5 \pm 13,8\%$	$72,6 \pm 8,1\%$	$50,2 \pm 3,8\%$
<b>Entraîné sur 20 images</b>			
Réseau à $8 \cdot 10^7$ poids / $P = 20$	$57,1 \pm 13,3\%$	$71,1 \pm 8,2\%$	$52,6 \pm 3,8\%$
Réseau à $2 \cdot 10^6$ poids / $P = 20$	$55,3 \pm 14,0\%$	$71,7 \pm 8,4\%$	$49,6 \pm 4,2\%$
Réseau à $5 \cdot 10^5$ poids / $P = 20$	$62,3 \pm 11,5\%$	$71,0 \pm 8,2\%$	$54,1 \pm 3,7\%$

# Convergence de la phase d'entraînement

Évolution du score de segmentation des trois réseaux au cours de l'entraînement sur la Config. I, avec deux classes  $k = 2$

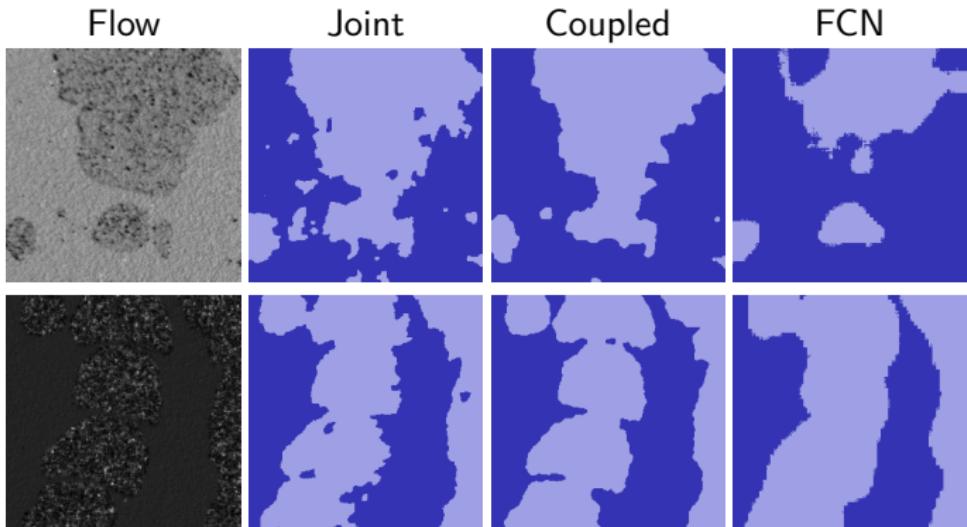


## Comparaison effort de calcul $\mathcal{C}$

	$\mathcal{W}$	$P$	$\mathcal{I}$	$\mathcal{C}$
Segmentation à contours « libres »	2	1	$10^7$	$2 \cdot 10^7$
Réseau à $8 \cdot 10^7$ poids / $P = \{20, 2000\}$	$8 \cdot 10^7$	$\{20, 2000\}$	$\{3000, 30\}$	$4,8 \cdot 10^{12}$
Réseau à $2 \cdot 10^6$ poids / $P = \{20, 2000\}$	$2 \cdot 10^6$	$\{20, 2000\}$	$\{3000, 30\}$	$1,2 \cdot 10^{11}$
Réseau à $4 \cdot 10^5$ poids / $P = \{20, 2000\}$	$4 \cdot 10^5$	$\{20, 2000\}$	$\{3000, 30\}$	$2,4 \cdot 10^{10}$

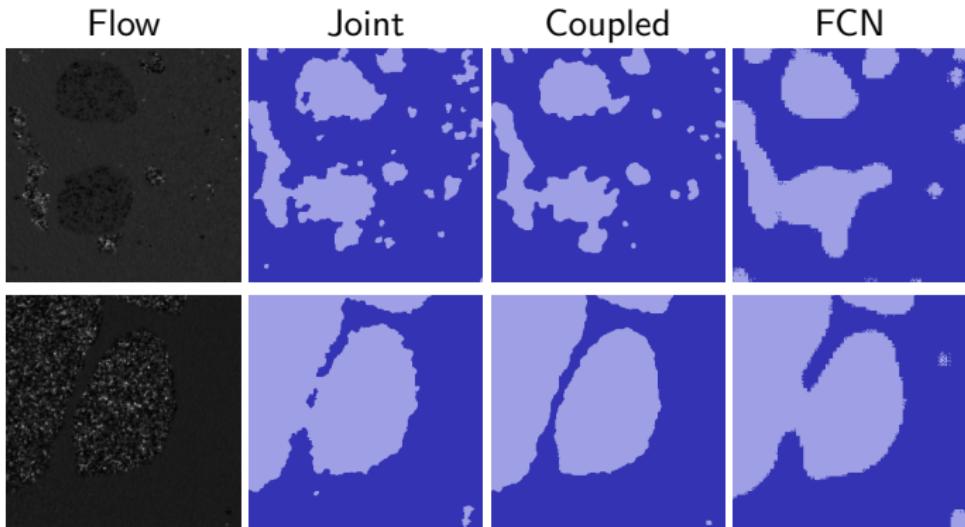
- $\mathcal{W}$  : nombre de poids
- $P$  : taille base d'entraînement
- $\mathcal{I}$  : nombre d'*epochs*

# Réseaux de neurones convolutionnels<sup>†</sup>



<sup>†</sup> V. Andriarczyk, <https://arxiv.org/abs/1703.05230>

# Réseaux de neurones convolutionnels<sup>†</sup>



<sup>†</sup> V. Andriarczyk, <https://arxiv.org/abs/1703.05230>

## *Stein Unbiased Risk Estimate (Principe)*

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \boldsymbol{\zeta} \in \mathbb{R}^P$ ,     $\bar{\mathbf{x}}$  : vérité et  $\boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

## *Stein Unbiased Risk Estimate (Principe)*

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \boldsymbol{\zeta} \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \| \mathbf{y} - \mathbf{x} \|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{x}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_\zeta \| \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}} \|^2 = \mathbb{E}_\zeta \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \| \mathbf{y} - \mathbf{x} \|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{x}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_\zeta \| \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}} \|^2 = \mathbb{E}_\zeta \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$R(\lambda) = \mathbb{E}_\zeta \| \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}} \|^2$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \boldsymbol{\zeta} \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \| \mathbf{y} - \mathbf{x} \|^2 + \lambda \mathcal{Q}(\mathbf{D}\mathbf{x}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_{\boldsymbol{\zeta}} \| \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}} \|^2 = \mathbb{E}_{\boldsymbol{\zeta}} \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$\begin{aligned} R(\lambda) &= \mathbb{E}_{\boldsymbol{\zeta}} \| \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}} \|^2 \\ &= \mathbb{E}_{\boldsymbol{\zeta}} \| \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} \|^2 + 2\mathbb{E}_{\boldsymbol{\zeta}} \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_{\boldsymbol{\zeta}} \| \mathbf{y} - \bar{\mathbf{x}} \|^2 \end{aligned}$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 = \mathbb{E}_\zeta \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$\begin{aligned} R(\lambda) &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - 2\mathbb{E}_\zeta \langle \bar{\mathbf{x}} + \zeta, \zeta \rangle + \mathbb{E}_\zeta \|\zeta\|^2 \end{aligned}$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 = \mathbb{E}_\zeta \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$\begin{aligned} R(\lambda) &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - 2\mathbb{E}_\zeta \langle \zeta, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\zeta\|^2 \end{aligned}$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 = \mathbb{E}_\zeta \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$\begin{aligned} R(\lambda) &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - 2\mathbb{E}_\zeta \langle \zeta, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\zeta\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - \mathbb{E}_\zeta \|\zeta\|^2 \end{aligned}$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \boldsymbol{\zeta} \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\boldsymbol{\zeta} \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_{\boldsymbol{\zeta}} \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 = \mathbb{E}_{\boldsymbol{\zeta}} \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$\begin{aligned} R(\lambda) &= \mathbb{E}_{\boldsymbol{\zeta}} \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_{\boldsymbol{\zeta}} \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_{\boldsymbol{\zeta}} \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_{\boldsymbol{\zeta}} \|\mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_{\boldsymbol{\zeta}} \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_{\boldsymbol{\zeta}} \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \boldsymbol{\zeta} \rangle - 2\mathbb{E}_{\boldsymbol{\zeta}} \langle \boldsymbol{\zeta}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_{\boldsymbol{\zeta}} \|\boldsymbol{\zeta}\|^2 \\ &= \mathbb{E}_{\boldsymbol{\zeta}} \underbrace{\|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2}_{\text{accessible}} + 2\mathbb{E}_{\boldsymbol{\zeta}} \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \boldsymbol{\zeta} \rangle - \underbrace{\mathbb{E}_{\boldsymbol{\zeta}} \|\boldsymbol{\zeta}\|^2}_{\text{accessible}} \end{aligned}$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 = \mathbb{E}_\zeta \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$\begin{aligned} R(\lambda) &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - 2\mathbb{E}_\zeta \langle \zeta, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\zeta\|^2 \\ &= \mathbb{E}_\zeta \underbrace{\|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2}_{\text{accessible}} + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - \frac{\mathbb{E}_\zeta \|\zeta\|^2}{\rho^2 P} \end{aligned}$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 = \mathbb{E}_\zeta \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$\begin{aligned} R(\lambda) &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - 2\mathbb{E}_\zeta \langle \zeta, \zeta \rangle + \mathbb{E}_\zeta \|\zeta\|^2 \\ &= \mathbb{E}_\zeta \underbrace{\|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2}_{\text{accessible}} + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - \frac{\mathbb{E}_\zeta \|\zeta\|^2}{\rho^2 P} \end{aligned}$$

$$\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle = \int \langle \hat{\mathbf{x}}(\bar{\mathbf{x}} + \zeta; \lambda), \zeta \rangle \exp(-\frac{\|\zeta\|^2}{2\rho^2}) d\zeta$$

## Stein Unbiased Risk Estimate (Principe)

**Observations**  $\mathbf{y} = \bar{\mathbf{x}} + \zeta \in \mathbb{R}^P$ ,  $\bar{\mathbf{x}}$  : vérité et  $\zeta \sim \mathcal{N}(\mathbf{0}, \rho^2 \mathbf{I})$

**Estimateur paramétrique**  $(\mathbf{y}; \lambda) \mapsto \hat{\mathbf{x}}(\mathbf{y}; \lambda)$

$$\text{Ex. } \hat{\mathbf{x}}(\mathbf{y}; \lambda) = \begin{cases} (\mathbf{I} + \lambda \mathbf{D}^\top \mathbf{D})^{-1} \mathbf{y} & \text{(linéaire)} \\ \underset{\mathbf{x}}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{x}\|^2 + \lambda \mathcal{Q}(\mathbf{Dx}) & \text{(non linéaire)} \end{cases}$$

**Erreur quadratique**  $R(\lambda) \triangleq \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \bar{\mathbf{x}}\|^2 = \mathbb{E}_\zeta \widehat{R}(\mathbf{y}; \lambda)$   $\bar{\mathbf{x}}$  inconnue

$$\begin{aligned} R(\lambda) &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y} + \mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\mathbf{y} - \bar{\mathbf{x}}\|^2 \\ &= \mathbb{E}_\zeta \|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2 + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - 2\mathbb{E}_\zeta \langle \zeta, \mathbf{y} - \bar{\mathbf{x}} \rangle + \mathbb{E}_\zeta \|\zeta\|^2 \\ &= \mathbb{E}_\zeta \underbrace{\|\hat{\mathbf{x}}(\mathbf{y}; \lambda) - \mathbf{y}\|^2}_{\text{accessible}} + 2\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle - \frac{\mathbb{E}_\zeta \|\zeta\|^2}{\rho^2 P} \end{aligned}$$

$$\mathbb{E}_\zeta \langle \hat{\mathbf{x}}(\mathbf{y}; \lambda), \zeta \rangle = \int \langle \hat{\mathbf{x}}(\bar{\mathbf{x}} + \zeta; \lambda), \zeta \rangle \exp\left(-\frac{\|\zeta\|^2}{2\rho^2}\right) d\zeta \stackrel{\text{I.P.P.}}{=} \rho^2 \mathbb{E}_\zeta \operatorname{tr}(\partial_{\mathbf{y}} \hat{\mathbf{x}}(\mathbf{y}; \lambda))$$

# Estimateur séquentiel et différentiation récursive

$$\boldsymbol{\Lambda} \triangleq (\lambda, \alpha), \quad \mathbf{U}_{\boldsymbol{\Lambda}} : (\mathbf{h}, \mathbf{v}) \mapsto \lambda[\alpha \mathbf{D}\mathbf{h}, \mathbf{D}\mathbf{v}]$$

## Primal-dual accéléré

$$\tilde{\mathbf{z}}^n = \mathbf{z}^n + \tau_n \mathbf{U}_{\boldsymbol{\Lambda}} \mathbf{w}^n$$

$$\mathbf{z}^{n+1} = \text{prox}_{\tau_n(\|\cdot\|_{2,1})^*}(\tilde{\mathbf{z}}^n)$$

$$\tilde{\mathbf{x}}^n = \mathbf{x}^n - \sigma_n \mathbf{U}_{\boldsymbol{\Lambda}}^* \mathbf{z}^{n+1}$$

$$\mathbf{x}^{n+1} = \text{prox}_{\sigma_n \|\mathbf{D}\mathcal{L} - \Phi \cdot\|_2^2}(\tilde{\mathbf{x}}^n)$$

$$\theta_n = (1 + 2\mu\sigma_n)^{-\frac{1}{2}},$$

$$\tau_{n+1} = \tau_n / \theta_n, \quad \sigma_{n+1} = \theta_n \sigma_n$$

$$\mathbf{w}^{n+1} = \mathbf{x}^n + \theta^n (\mathbf{x}^{n+1} - \mathbf{x}^n)$$

## Primal-dual accéléré différentié

$$\partial_{\boldsymbol{\Lambda}} \tilde{\mathbf{z}}^n = \partial_{\boldsymbol{\Lambda}} \mathbf{z}^n + \tau_n \mathbf{U}_{\boldsymbol{\Lambda}} \partial_{\boldsymbol{\Lambda}} \mathbf{w}^n + \tau_n \partial_{\boldsymbol{\Lambda}} \mathbf{U}_{\boldsymbol{\Lambda}} \mathbf{w}^n$$

$$\partial_{\boldsymbol{\Lambda}} \mathbf{z}^{n+1} = \partial_{\tilde{\mathbf{z}}} \text{prox}_{\tau_n(\|\cdot\|_{2,1})^*}(\tilde{\mathbf{z}}^n) [\partial_{\boldsymbol{\Lambda}} \tilde{\mathbf{z}}^n]$$

$$\partial_{\boldsymbol{\Lambda}} \tilde{\mathbf{x}}^n = \partial_{\boldsymbol{\Lambda}} \mathbf{x}^n - \sigma_n \mathbf{U}_{\boldsymbol{\Lambda}}^* \partial_{\boldsymbol{\Lambda}} \mathbf{z}^{n+1} - \sigma_n \partial_{\boldsymbol{\Lambda}} \mathbf{U}_{\boldsymbol{\Lambda}} \mathbf{z}^{n+1}$$

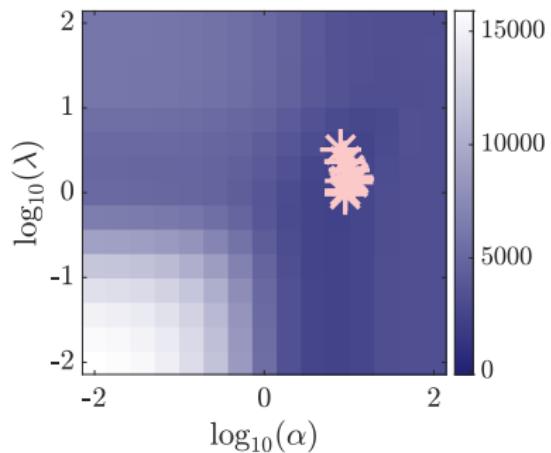
$$\partial_{\boldsymbol{\Lambda}} \mathbf{x}^{n+1} = \partial_{\tilde{\mathbf{x}}} \text{prox}_{\sigma_n \|\mathbf{D}\mathcal{L} - \Phi \cdot\|_2^2}(\tilde{\mathbf{x}}^n) [\partial_{\boldsymbol{\Lambda}} \tilde{\mathbf{x}}^n]$$

$$\partial_{\boldsymbol{\Lambda}} \mathbf{w}^{n+1} = \partial_{\boldsymbol{\Lambda}} \mathbf{x}^n + \theta^n (\partial_{\boldsymbol{\Lambda}} \mathbf{x}^{n+1} - \partial_{\boldsymbol{\Lambda}} \mathbf{x}^n)$$

# Recherche automatique des paramètres de régularisation

Moyenne sur dix réalisations de texture

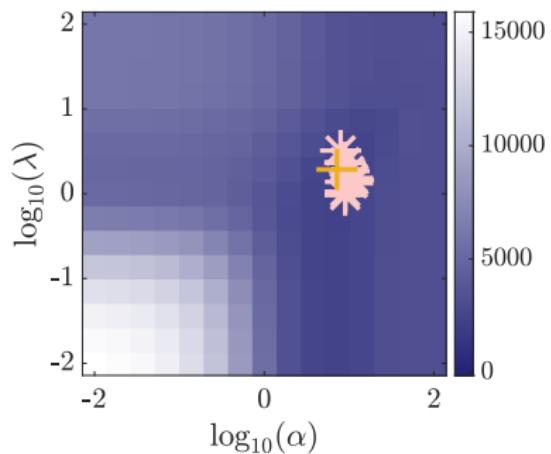
Matrice de covariance estimée  $\mathcal{S}$



# Recherche automatique des paramètres de régularisation

Moyenne sur dix réalisations de texture

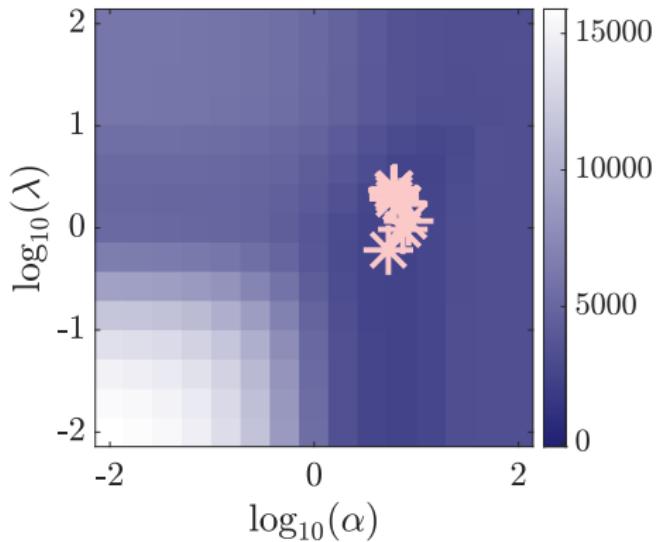
Matrice de covariance estimée  $\mathcal{S}$



# Recherche automatique des paramètres de régularisation

Moyenne sur dix réalisations de texture

Matrice de covariance estimée  $\hat{\mathcal{S}}$

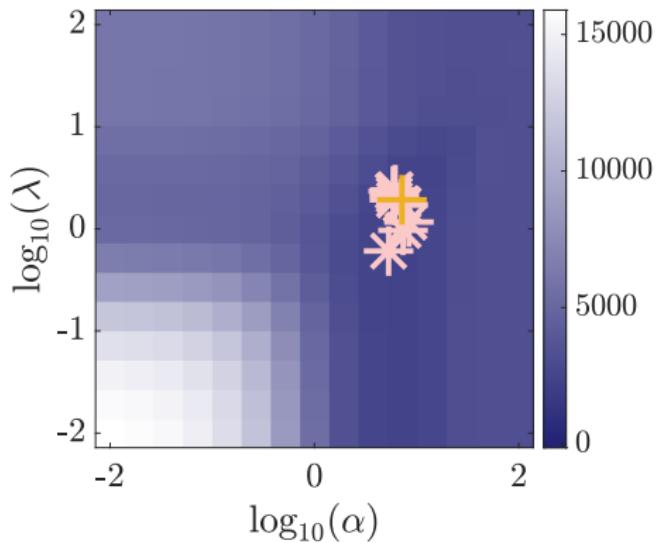


$$\hat{\lambda}^{qN} = 1,68 \pm 0,37 \quad \hat{\alpha}^{qN} = 6,70 \pm 0,58$$

# Recherche automatique des paramètres de régularisation

Moyenne sur dix réalisations de texture

Matrice de covariance estimée  $\hat{\mathcal{S}}$



$$\hat{\lambda}^{qN} = 1,68 \pm 0,37 \quad \hat{\alpha}^{qN} = 6,70 \pm 0,58$$

## Initialisation quasi-Newton

- Hyperparamètres  $\Lambda^{[0]} = (\lambda^{[0]}, \alpha^{[0]})$ , avec

$$\lambda^{[0]} = \frac{\text{tr}(\mathcal{S})}{2 \text{TV}(\widehat{\mathbf{v}}^{\text{RL}}(\mathcal{L}))}, \quad \text{et} \quad \alpha^{[0]} = \frac{\text{TV}(\widehat{\mathbf{v}}^{\text{RL}}(\mathcal{L}))}{\text{TV}(\widehat{\mathbf{h}}^{\text{RL}}(\mathcal{L}))}.$$

- Approximation de l'inverse de la hessienne

$$\mathbf{H}^{[0]} = \text{diag} \left( \left| \frac{\kappa \lambda^{[0]}}{\partial_\lambda \widehat{R}_{\nu, \epsilon}(\mathcal{L}; \Lambda^{[0]} | \mathcal{S})} \right|, \left| \frac{\kappa \alpha^{[0]}}{\partial_\alpha \widehat{R}_{\nu, \epsilon}(\mathcal{L}; \Lambda^{[0]} | \mathcal{S})} \right| \right).$$